

# Masterarbeit

## Maschinelle Erkennung Altägyptischer Hieroglyphen - Vom Bild zu maschinenlesbarem Text

David Konieczny

Oktober 2024 – März 2025

Matrikelnummer: 3671011  
Studiengang: Data Science

**Betreuer:**  
Professor Dr.-Ing. Torsten Zesch




**FernUniversität in Hagen**  
Center of Advanced Technology for Assisted Learning and Predictive Analytics  
Research Professorship Computational Linguistics  
58097 Hagen



## Erklärung

Hiermit erkläre ich, dass ich die vorliegende Arbeit ohne fremde Hilfe selbstständig verfasst und nur die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere weiterhin, dass ich diese Arbeit noch keinem anderen Prüfungsgremium vorgelegt habe.

Hagen, im März 2025

.....  
  
David Konieczny





## Zusammenfassung



Das Alte Ägypten zählt zu den bedeutendsten Hochkulturen der Geschichte, deren schriftliches Erbe bis heute fasziniert. Das Wissen um die Hieroglyphenschrift, über Jahrtausende im Einsatz, ging nach dem Ende des Pharaonenreichs verloren und wird erst seit der Entschlüsselung 1822 Schritt für Schritt rekonstruiert. Während in der Ägyptologie zahlreiche Inschriften dokumentiert wurden, fehlt eine umfassende digitale Erfassung, die moderne KI-Technologien nutzen könnte. Diese Arbeit befasst sich mit der maschinellen Erkennung ägyptischer Hieroglyphen und entwickelt ein System, das Bilder hieroglyphischer Inschriften in eine maschinenlesbare Repräsentation transformiert.

Das vorgestellte Verfahren kombiniert Objekterkennung, Sequenzierung und Klassifikation, um Hieroglyphen automatisiert zu erkennen, gemäß der intendierten Leserichtung zu sortieren und die etwa 1000 gängigsten Zeichen nach ihrem Gardiner-Code zu klassifizieren. Dabei werden Herausforderungen wie unterschiedliche Anordnungen der Schriftzeichen, variierende Materialien und beschädigte Inschriften berücksichtigt. Die Implementierung zeigt vielversprechende Ergebnisse, insbesondere für die Digitalisierung bisher nur handschriftlich dokumentierter Texte, während noch Optimierungsbedarf für eine vollständige Fehlerreduktion besteht.

Die entwickelten Algorithmen erleichtern nicht nur die wissenschaftliche Arbeit von Ägyptologen, sondern könnten zukünftig auch in breiteren Anwendungen, etwa für Touristen oder Museen, genutzt werden. Durch die Bereitstellung aller relevanten Datensätze und Codes als Open-Source-Beitrag leistet diese Arbeit einen wichtigen Schritt zur Digitalisierung und automatisierten Analyse altägyptischer Schriftkultur.



# Inhaltsverzeichnis

|          |                                                                                                              |           |
|----------|--------------------------------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Einleitung</b>                                                                                            | <b>1</b>  |
| <b>2</b> | <b>Grundlegendes zur Ägyptischen Hieroglyphenschrift</b>                                                     | <b>5</b>  |
| 2.1      | Sprachstufen und Schriftsysteme . . . . .                                                                    | 5         |
| 2.2      | Umfang der Hieroglyphenschrift und Funktionen der Schriftzeichen . . .                                       | 7         |
| 2.3      | Leserichtungen . . . . .                                                                                     | 11        |
| 2.4      | Vom Bild zu maschinenlesbarem Text - Die Prozessschritte im Überblick                                        | 12        |
| <b>3</b> | <b>Stand der Forschung</b>                                                                                   | <b>15</b> |
| 3.1      | Erster Ansatz zur Hieroglyphenerkennung in den Pyramidentexten durch Franken und van Gemert (2013) . . . . . | 15        |
| 3.2      | Maschinelle Auswertung hieroglyphischer Handschriften durch Nederhof (2016) . . . . .                        | 16        |
| 3.3      | Projekt Fabricius . . . . .                                                                                  | 18        |
| 3.4      | Implementierung des Gesamtprozesses durch Hossam et al. (2018) . . . .                                       | 19        |
| 3.5      | Verwendung von CNNs für Segmentierung und Klassifizierung durch Barucci et al. (2021) . . . . .              | 20        |
| 3.6      | Hieroglyphenerkennung und -übersetzung durch Sobhy et al. (2023) . . .                                       | 23        |
| 3.7      | Kartuschenanalyse durch Duque-Domingo et al. (2017) mit Folgeprojekt                                         | 26        |
| 3.8      | Weitere Beiträge . . . . .                                                                                   | 30        |
| 3.9      | Entwicklung von mobilen Apps als Übersetzungshilfe . . . . .                                                 | 31        |
| 3.10     | Übersetzung mithilfe eines Sprachmodells nach Wiesenbach und Riezler (2019) . . . . .                        | 36        |
| 3.11     | Übersetzungsarbeit von De Cao et al. (2024) . . . . .                                                        | 38        |
| 3.12     | Zusammenfassender Vergleich der Ansätze . . . . .                                                            | 40        |
| <b>4</b> | <b>Datensammlung</b>                                                                                         | <b>43</b> |
| 4.1      | Datensatz hieroglyphischer Inschriften . . . . .                                                             | 43        |
| 4.2      | Datensatz für die Segmentierung . . . . .                                                                    | 44        |
| 4.3      | Datensatz für den Klassifikator . . . . .                                                                    | 46        |
| 4.4      | Datensatz für die Links-Rechts-Leserichtung . . . . .                                                        | 50        |
| 4.5      | Datensatz für den Gesamtprozess . . . . .                                                                    | 52        |
| <b>5</b> | <b>Experimente</b>                                                                                           | <b>55</b> |
| 5.1      | Segmentierung . . . . .                                                                                      | 55        |
| 5.2      | Links-Rechts-Leserichtung . . . . .                                                                          | 62        |

---

|          |                                                                                  |              |
|----------|----------------------------------------------------------------------------------|--------------|
| 5.3      | Sequenzierung . . . . .                                                          | 63           |
| 5.4      | Klassifikation . . . . .                                                         | 66           |
| 5.5      | Gesamter Einleseprozess . . . . .                                                | 68           |
| 5.6      | Übersetzungsvergleiche . . . . .                                                 | 72           |
| <b>6</b> | <b>Zusammenfassung und Ausblick</b>                                              | <b>75</b>    |
| 6.1      | Zusammenfassung . . . . .                                                        | 75           |
| 6.2      | Ausblick . . . . .                                                               | 76           |
| <b>A</b> | <b>Kurzfassung der Gardinerliste, Original aus Gardiner (1957)</b>               | <b>iii</b>   |
| <b>B</b> | <b>Häufigkeitsverteilung der 300 häufigsten Hieroglyphen</b>                     | <b>vii</b>   |
| <b>C</b> | <b>Beispielhafte Anwendung von Fabricius</b>                                     | <b>xi</b>    |
| <b>D</b> | <b>Klassifikator Glyphnet von Barucci et al. (2021) mit Kurztest</b>             | <b>xv</b>    |
| <b>E</b> | <b>Grundlagen zu CNNs und darauf aufbauenden Architekturen</b>                   | <b>xvii</b>  |
| <b>F</b> | <b>Klassenverteilungen der Datensätze</b>                                        | <b>xxi</b>   |
| F.1      | Verteilung im Trainingsdatensatz für die Segmentierung (Top90 Klassen)           | xxi          |
| F.2      | Verteilung im Trainingsdatensatz für die Klassifizierung . . . . .               | xxii         |
| <b>G</b> | <b>Klassenweise Evaluation des Klassifikators</b>                                | <b>xxvii</b> |
| <b>H</b> | <b>Segmentierung, Sequenzierung und Klassifikation für ausgewählte Beispiele</b> | <b>xxix</b>  |
| H.1      | Sethe, <i>Urkunden III</i> , S. 886 unten (aus Sethe (1909)) . . . . .           | xxx          |
| H.2      | Sethe, <i>Urkunden III</i> , S. 887 Mitte (aus Sethe (1909)) . . . . .           | xxxi         |
| H.3      | Der beredte Bauer (Version R, Episode 1, Teil 2, aus Allen (2014b)) . .          | xxxiii       |
| H.4      | Die Geschichte des Schiffbrüchigen (Episode 1, Teil 2, aus Allen (2014b))        | xxxiv        |
| H.5      | Stele des Maati (Ausschnitt) . . . . .                                           | xxxv         |
| H.6      | Stele des Antef (Ausschnitt) . . . . .                                           | xxxvi        |
| H.7      | Stele des Amenemhet (Ausschnitt) . . . . .                                       | xxxvii       |
| H.8      | Stele des Ameny (Ausschnitt) . . . . .                                           | xxxviii      |
| H.9      | Stele des Dedusobek (Ausschnitt) . . . . .                                       | xxxix        |
| H.10     | Stele des Nebipusenwosret (Ausschnitt) . . . . .                                 | xl           |
| H.11     | Stele des Qemnen (Ausschnitt) . . . . .                                          | xli          |
| H.12     | Pyramidentext aus der Unas-Pyramide (Ausschnitt) . . . . .                       | xlii         |
|          | <b>Abbildungsverzeichnis</b>                                                     | <b>xliii</b> |
|          | <b>Tabellenverzeichnis</b>                                                       | <b>xlvi</b>  |
|          | <b>Literaturverzeichnis</b>                                                      | <b>xlix</b>  |

# Kapitel 1

## Einleitung

Das Alte Ägypten gilt als eine der ersten Hochkulturen der Menschheitsgeschichte, die das breite Publikum insbesondere nach der Entdeckung des Schatzes von Pharao Tutanchamun fortwährend fasziniert. Seine Historie begann etwa 3100 v. Chr. und währte über drei Jahrtausende bis zum Verlust der Eigenstaatlichkeit nach dem Tod Kleopatras VII. 30 v. Chr. Das Ägypten des Altertums zeichnete sich durch eine komplexe Gesellschaft mit bemerkenswerten Leistungen in Architektur, Kunst, Schrift, Religion und Verwaltung aus. Das Vermächtnis dieser Kultur ist in ihren Bauwerken und allem voran in ihrer Schrift überliefert. Die Hieroglyphenschrift des Alten Ägyptens war über die gesamte Zeitspanne der Hochkultur in Gebrauch und zierte heute noch u.a. etliche Bauwerke, Stelen und Grabbeigaben. Die Kenntnis um die Schrift ging kurze Zeit nach dem Ende des Pharaonenreiches verloren. Erst durch ihre Entzifferung 1822 wurde der gesamte überlieferte Textkorpus den Wissenschaftlern der Neuzeit zugänglich. In den vergangenen 200 Jahren der Ägyptologie wurden hieroglyphische Inschriften hauptsächlich in Form von Abschriften oder Photographien dokumentiert und der Öffentlichkeit zugänglich gemacht. Lediglich ein Teil des gesamten Textkorpus liegt zum Zeitpunkt dieser Arbeit digitalisiert vor. Daher ist die Ägyptologie noch immer eine Wissenschaft, die für Anwendungen der künstlichen Intelligenz schwer zugänglich ist, da diese auf maschinenlesbare Repräsentationen der hieroglyphischen Inschriften angewiesen sind.

Die Programmierung eines maschinellen Modells zum Einlesen der ägyptischen Hieroglyphenschrift aus Abbildungen begegnet insbesondere folgenden Herausforderungen:

- *Eingeschränkter Textkorpus:* Die vorliegenden archäologischen Textfunde erstrecken sich über einen Zeitraum von mehr als 3000 Jahren. Laut einer Schätzung von Wolfgang Schenkel aus dem Jahre 1995 erstreckte sich der damalige vorliegende Textkorpus für das antike Ägypten auf über fünf Millionen Wörter. Geschätzt wurde lediglich das damals analysierte und publizierte Material. Außerdem wurden Textkopien nicht eingeschlossen und allerlei grammatikalische Bausteine nicht mitgezählt (Schenkel (1995)). 30 Jahre später muss sich das verfügbare Material aufgrund etlicher Neufunde erheblich erweitert haben. Dennoch bleibt der Textkorpus für das Ägyptische als seit mehreren Jahrhunderten ausgestorbene Sprache begrenzt und ist mitnichten mit Textkorpora moderner Sprachen, deren Textmaterial sich insbesondere über das Internet verteilt, vergleichbar.
- *Berücksichtigung mehrerer Sprachstufen:* Das verfügbare Textmaterial gliedert sich in mehrere Sprachstufen, sodass die Beleglage für jede einzelne Stufe noch ge-

---

ringer ausfällt. Zudem müssen die Eigenheiten jeder Entwicklungsstufe des Ägyptischen beim maschinellen Lesen berücksichtigt werden.

- *Variable Leserichtung*: Bei der Hieroglyphenschrift gibt es vier verschiedene Leserichtungen, die jeweils erkannt werden müssen.
- *Zeichenumfang*: Die Hieroglyphenschrift kennt mehrere tausend Zeichen. Gerade seltene Hieroglyphen sind ausschlaggebend für eine korrekte Übersetzung. Daher ist ein leistungsstarker Klassifikator erforderlich.
- *Verwendung unterschiedlicher Materialien*: Hieroglyphen wurden in Stein, Holz oder Metalle geritzt. Zudem wurden die Zeichen auf Papyrus, Tonscherben, Stein, Holz und weitere Materialien gemalt, sodass i.A. unterschiedlich stark ausgeprägte Kontraste den Text vom Hintergrund abheben.
- *Abnutzungserscheinungen*: Viele Textfragmente sind beschädigt aufgrund ihres erheblichen Alters. Beschädigte Hieroglyphen sollten ebenso gut erkannt werden.

In dieser Arbeit wird zunächst eine ausführliche Literaturrecherche bzgl. der maschinellen Erkennung von Hieroglyphen und ein Vergleich der publizierten Arbeiten erarbeitet. Auf der Grundlage des Stands der Forschung wird ein System erarbeitet, mit dessen Hilfe Abbildungen von hieroglyphischen Inschriften in einen maschinenlesbaren Code transformiert werden sollen. Dabei werden die Hieroglyphen mithilfe eines Objekterkennungsalgorithmus zunächst vom Hintergrund segmentiert, anschließend werden die erkannten Zeichen nach Ermittlung der Schreibrichtung sequenziert und schließlich durch ein maschinelles Modell klassifiziert. Die etwa 1000 verschiedenen, üblicherweise verwendeten Hieroglyphen werden digital durch ihren sog. Gardiner-Code repräsentiert. Die Art der digitalen Repräsentation der einzelnen Zeichen ist dabei unerheblich, da eine Maschine alle Repräsentationen problemlos ineinander umrechnen kann. Die Güte der Segmentierung bzw. Klassifikation wird jeweils auf Testdatensätzen mithilfe entsprechender Metriken getestet. Zudem wird der Gesamtprozess des maschinellen Einlesens sowohl durch automatische als auch manuelle Auswertung auf seine praktische Anwendbarkeit hin geprüft. Die aus diesem Verfahren erhaltene digitale Darstellung von hieroglyphischen Texten erlaubt eine weiterführende maschinelle Analyse, wie z.B. Altersbestimmungen von Texten anhand sprachlicher Merkmale, Bestimmung von Urheberschaften von Textstücken, tiefergreifende linguistische Analysen bspw. hinsichtlich der heute weiterhin teilweise umstrittenen Grammatik, bis hin zu automatischen Übersetzungen. Unter Verwendung des bis dato leistungsstärksten in der Literatur verfügbaren Modells zur Übersetzung von Gardiner-Code-Sequenzen nach Deutsch/Englisch wird zudem der End-to-End-Prozess von Abbildungen hieroglyphischer Inschriften bis zur Übersetzung in eine moderne Sprache getestet.

Die maschinelle Erkennung altägyptischer Hieroglyphen unterstützt nicht nur die tägliche Arbeit von Ägyptologen, sondern hilft auch dem interessierten Amateur und voraussichtlich in Zukunft - etwa durch Applikationen auf Smartphones - Touristen

---

bzw. Museumsbesuchern, leichter Zugang zum Verständnis der faszinierenden altägyptischen Texte zu finden. Aus der Sicht des Autors der vorliegenden Arbeit als Amateur-Ägyptologe fehlt aber vor allem ein Tool, dass ein fachkundiges Publikum zuverlässig bei der Digitalisierung ägyptischer Inschriften unterstützt. Bei der Lektüre des Stands der Forschung wird klar, dass die bisherigen Ansätze entweder wegen Überanpassung nur auf Bildern aus bestimmten Quellen funktionieren oder in Form von Smartphone-Apps anstatt auf eine fundierte Implementierung eher Wert auf eine breite Zielgruppe legen, der durch Nutzung dieser Anwendungen jedoch nur ein sehr oberflächlicher und didaktisch fragwürdiger Einstieg in das Thema „Hieroglyphen“ ermöglicht wird. Zudem fehlt eine gewinnbringende Fusion der bisher erarbeiteten Materialien weitestgehend, da die meisten Autoren ihre Datensätze und Codes nicht frei verfügbar machen. Daher werden alle in dieser Arbeit verwendeten Datensätze und jeglicher relevante Programmiercode im eigens dafür erstellten Github-Repository öffentlich zugänglich gemacht:

<https://github.com/davimon23/MAHieroglyphenOCR>





## Kapitel 2


# Grundlegendes zur Ägyptischen Hieroglyphenschrift

Sofern nicht anderweitig vermerkt sind die im Folgenden angerissenen Grundlagen aus der Einführung zur mittellägyptischen Grammatik von Allen (2014a) übernommen.

### 2.1 Sprachstufen und Schriftsysteme

„Altägyptisch“ ist in weiterem Sinne ein Sammelbegriff für die verschiedenen Entwicklungsstadien der ursprünglichen Schriftsprache Ägyptens in der Antike. Da im heutigen Ägypten Arabisch die Amtssprache darstellt (gesprochen in der Form des lokalen Dialekts Ägyptisch-Arabisch), kann die im gleichen geografischen Raum verwendete Altertumssprache eindeutig mit „Ägyptisch“ referenziert werden. Im engeren Sinne wird mit „Altägyptisch“ die älteste Sprachstufe des Ägyptischen bezeichnet, die im Zeitraum von 2700-2100 v. Chr. Verwendung fand. Darauf folgte das „Mittelägyptische“, das aufgrund des begrenzten Zeichenumfangs sowie einer relativ gut erkennbaren grammatikalischen Strukturierung beim Studium üblicherweise zuerst gelernt wird. Weitere wichtige Sprachstufen sind „Neuägyptisch“, „Demotisch“ und „Koptisch“. Für Letzteres sind muttersprachliche Texte bis in das 11. Jh. n. Chr. attestiert. Die Entwicklungsstufen werden zeitlich grob in dieser Reihenfolge durchlaufen. Gleichwohl überschneiden sich deren Verwendungen im Hinblick auf unterschiedliche Kommunikationsbereiche („Register“). Eine Übersicht über die Sprachstufen in Abhängigkeit von Zeit und Register findet man in der Einführung von Werning (2015), vergleiche Abb. 2.1.

Im Alten Ägypten können vier Schriftsysteme unterschieden werden. Die Zeichen der allgemein bekannten hieroglyphischen Schrift wurden hauptsächlich in Stein oder Holz graviert oder auf verputzte Wände gemalt. In Abb. 2.2 stellen die linke Spalte in Abschnitt A bzw. die untere Zeile in Abschnitt B je einen Beispielttext dar. Hieroglyphen können von rechts nach links oder von links nach rechts, in Zeilen oder in Spalten geschrieben werden (in jedem Fall ist ein Text von oben nach unten zu lesen). Dieses Schriftsystem wurde für Inschriften auf Statuen, Geschichtsschreibung auf Wänden oder religiöse Texte wie Hymnen oder Ritualsprüche verwendet, die für die Ewigkeit gedacht waren. Der Begriff „Hieroglyphe“ leitet sich aus dem Griechischen ab und bedeutet dem Verwendungszweck gemäß soviel wie „heilige, eingravierte (Schrift)“.



**Abbildung 2.1:** Überblick über die Sprachstufen des Ägyptischen abhängig von der zeitlichen Dimension und vom Register, aus Werning (2015).

Wurden in handgeschriebenen Dokumenten Hieroglyphen verwendet, so wurde eine kursiv-hieroglyphische Variante (Abschnitt A, rechte Spalte) genutzt. Üblicherweise war für handgeschriebene Texte auf Papyrus, Leder, Holz oder Tonscherben (Ostraca) jedoch die hieratische (griech. „priesterliche“) Schrift in Gebrauch. Hieratisch wird in Zeilen oder Spalten stets von rechts nach links geschrieben und hauptsächlich für religiöse, literarische oder administrative Texte oder Briefe verwendet. Abb. 2.2 zeigt in Abschnitt B einen direkten Vergleich zwischen einer hieratischen Zeile oben und der entsprechenden Umschreibung („Transliteration“, vgl. Begriffsdefinition nach Werning (2015)) in Hieroglyphen darunter. Hieroglyphisch und Hieratisch fanden analog zu heutigen Druck- und Schreibschriften parallele Anwendung. In der Spätphase der altägyptischen Kultur entwickelte sich aus dem Hieratischen heraus das noch kursivere Demotisch (griech. „volkstümlich“), das das führende Schriftsystem für administrative und sonstige im Alltag gebräuchliche Texte wurde. Demotisch wird in Zeilen und von rechts nach links geschrieben. Abb. 2.2 C zeigt ein Textbeispiel. Eine zeichengenaue Transliteration in Hieroglyphen ist meist nicht mehr möglich. Daher wird Demotisch normalerweise wortweise gelernt und in Lautschrift umgeschrieben („transkribiert“). Im 1. Jh. n. Chr. entwickelte sich mit dem Aufkommen des Christentums in Ägypten schließlich das koptische Alphabet, das 32 Buchstaben enthält, die hauptsächlich aus dem Griechischen übernommen wurden. Koptisch wurde üblicherweise in Zeilen von links nach rechts geschrieben. In Abb. 2.2 D ist eine Textprobe samt Umschrift in lateinischen Buchstaben wiedergegeben.

Ägyptisch ist mittlerweile eine tote Sprache, wird aber in Form ihrer letzten Entwicklungsstufe, dem Koptischen, immer noch als Liturgiesprache in der koptischen Kirche, einer Konfession des Christentums, verwendet. Obwohl das Wissen um die Lesung der ägyptischen Schrift in den ersten Jahrhunderten nach Christus verloren ging, konnten die ägyptischen Schriftsysteme mithilfe des Steins von Rosette, auf dem ein Dekret in Hieroglyphen, in Demotisch und in Griechisch eingraviert ist, sowie mithilfe des Koptischen, das die ursprüngliche ägyptische Sprache mit dem griechischen Alphabet ausdrückt, durch die Pionierarbeit des Franzosen Jean-François Champollion ab 1822 entziffert werden.



**Abbildung 2.2:** Textproben für die verschiedenen Schriftsysteme im Alten Ägypten aus Allen (2014a). A: Auszug aus einem Sargtext (CT IV, 255b-257a T1Be), linke Spalte in Hieroglyphisch, rechte Spalte in Kursiv-Hieroglyphen, Lesung jeweils von rechts nach links und von oben nach unten. B: Aus der Lehre des Ptahhotep (Ptahhotep 277-278), obere Zeile in Hieratisch, untere Zeile in hieroglyphischer Transliteration, Lesung von rechts nach links. C: Demotischer Text (Erichsen, Lesestücke I, 73), Lesung von rechts nach links. D: Beginn des „Vater Unser“ in Koptisch, Lesung von links nach rechts mit lateinischer Umschrift.

## 2.2 Umfang der Hieroglyphenschrift und Funktionen der Schriftzeichen

Der Fokus dieser Arbeit liegt auf der maschinellen Erkennung der Hieroglyphenschrift. Daher werden im Folgenden grundlegende Eigenschaften dieses Schriftsystems sowie vor allem für das Mittelägyptische gültige quantitative Aspekte vorgestellt. Das Mittelägyptische nutzt etwa 700 verschiedene Zeichen. In den späteren Epochen steigt die Zahl der Symbole durch Variationen auf über 5000 an. Unicode enthält aktuell 1072 Standardhieroglyphen im Bereich U+13000 bis U+1342F<sup>1</sup> sowie 3995 seltenere bzw. spezifischere Hieroglyphen im Bereich U+13460 bis U+143FF<sup>2</sup>. Nachdem die Ägyptologie bereits eine über 200 Jahre alte Disziplin ist, mussten zum Zweck einer systematischen Erforschung in der Vergangenheit Zeichenlisten verwaltet werden. Die gängigste Liste ist der von Sir Alan Gardiner 1927 veröffentlichte Gardiner-Code in Gardiner (1927). Hierin sind 763 Zeichen gemäß ihrer bildlichen Darstellung in 26 Gruppen eingeteilt. In Allen (2014a) findet man beispielsweise auf den Seiten 467-507 eine ausführliche Auflistung aller Hieroglyphen nach Gardiner-Code inklusive einer Beschreibung der Darstellung sowie den häufigsten Funktionen des jeweiligen Symbols. In Abb. 2.3 ist beispielhaft die Gruppe L *Insekten und Wirbellose* gezeigt. In Anhang A ist eine Kurzfassung der Gardinerliste aus der Originalpublikation Gardiner (1957) gegeben, die - als Schnell-

<sup>1</sup><https://www.unicode.org/charts/PDF/U13000.pdf>, Version 16.0, besucht am 21.01.2025

<sup>2</sup><https://www.unicode.org/charts/PDF/U13460.pdf>, Version 16.0, besucht am 21.01.2025

überblick gedacht - lediglich die Zuordnung des Gardiner-Codes zur Hieroglyphe wiedergibt. Ergänzend sei an dieser Stelle erwähnt, dass sich Ägyptologen je nach Tradition unterschiedlicher alphabetischer Transkriptionssysteme bedienen (vgl. Allen (2014a), S. 15ff), deren Anwendung auf die Hieroglyphenschrift zum Einen eine Behelfsaussprache für die eigentlich tote ägyptische Sprache ermöglicht. Zum Anderen werden basierend auf der Transkription Wörterbücher erstellt, sodass ägyptisches Vokabular nicht nach Hieroglyphen, sondern nach Lautung sortiert ist, wie beispielsweise das unvergleichliche *Handwörterbuch Ägyptisch-Deutsch* (Hannig (1995)). Die Hieroglyphe  (L1) in Abb. 2.3 kann beispielweise den Lautwert *hpr* (sprich: „cheper“) repräsentieren.

## L. INSECTS AND INVERTEBRATES

|   |                                                                                     |                     |                                                                                                                                                                              |
|---|-------------------------------------------------------------------------------------|---------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1 |    | scarab beetle       | Phonogram <i>hpr</i> . Determinative in or ideogram for <i>hpr</i> “scarab beetle.”                                                                                          |
| 2 |    | bee or wasp         | Ideogram for <i>bjt</i> “bee; honey,” and <i>bjtj</i> “hereditary king.”                                                                                                     |
| 3 |    | fly                 | Determinative in <i>ꜥff</i> “fly.”                                                                                                                                           |
| 4 |    | locust              | Determinative in <i>znḥm</i> “locust.”                                                                                                                                       |
| 5 |    | centipede           | Ideogram in <i>sp3</i> “Sepa” (place near Heliopolis). Determinative in <i>zp3</i> “centipede.”                                                                              |
| 6 |   | shell               | Phonogram <i>ḥ3</i> in <i>ḥ3wt</i> “offering table.”                                                                                                                         |
| 7 |  | emblematic scorpion | Variant  (L7a). Determinative in <i>srqt</i> “Selket” (a goddess), also ideogram for same. |

**Abbildung 2.3:** Gruppe L der Gardinerliste, aus Allen (2014a).

Aufgrund des Umfangs von etwa 700 bis 800 standardmäßig verwendeten Zeichen ist klar, dass die Hieroglyphenschrift nicht rein alphabetisch sein kann. Die folgende Auflistung beschreibt die drei möglichen Funktionen einer Hieroglyphe in einem Wort:


- Mit einem „Ideogramm“ wird das Wort für das Objekt geschrieben, das die Hieroglyphe bildlich darstellt (diese Funktion wird häufig durch das Begleitzeichen  (Z1) signalisiert). Beispielsweise kann das Zeichen  (L2) das Wort *bjt* für „Biene“ ausdrücken.
- Ein „Phonogramm“ drückt Laute aus, jedoch nur Konsonanten, also keine Vokale, analog z.B. zum Arabischen oder Hebräischen (daher kann die korrekte Aussprache eines ägyptischen Worts i.d.R. nicht mehr zweifelsfrei rekonstruiert werden). Es gibt etwa zwei Dutzend Einkonsonantenzeichen, die eine Art „Alphabet“ darstellen (z.B.  *n* (N35)) sowie weitaus mehr Zwei- (z.B.  *šm* (N40)) und Mehrkonsonantenzeichen (z.B.  *cnḥ* (S34)). Phonogramme, die mehr als einen Konsonanten repräsentieren, werden oft durch Einkonsonantenzeichen als „Lesehilfe“ komplementiert. Beispielsweise kann das Wort *cnḥ* statt nur mit dem Zeichen  auch mit der Kombination   *cnḥ* ausgedrückt werden, wobei  *n* (N35) und  *ḥ* (Aa1) nochmal die letzten beiden Konsonanten wiederholen, ohne, dass diese erneut ausgesprochen werden sollen. Für ein Wort gibt es also mehrere gleichwertige

---

Schreibweisen und die Wortlänge variiert abhängig vom verfügbaren Platz auf dem Schreibmaterial.

- Ein „Determinativ“ wird an das Ende eines Wortes gesetzt, um dessen generelle Bedeutung zu spezifizieren. Beispielsweise kann die Konsonantenfolge  $^c n h$  je nach Determinativ unterschiedliche Bedeutungen haben: Ohne Determinativ repräsentiert die Zeichenfolge  $\text{𐤏} \text{𐤍}$  u.a. das Verb „leben“, mit dem Determinativ  $\text{𐤁}$  (A2) ergibt sich das Verb  $\text{𐤏} \text{𐤍} \text{𐤁}$  „schwören“, mit den beiden Determinativen  $\text{𐤃}$  (M2) und  $\text{𐤄}$  (Z2) ergibt sich das Wort  $\text{𐤏} \text{𐤍} \text{𐤃} \text{𐤄}$  „Blumenstrauß“. Da die Hieroglyphenschrift keine Leerzeichen kennt, eignen sich Determinative als gute Indikatoren für die Worttrennung.

Dieselbe Hieroglyphe kann je nach Kontext unterschiedliche Funktionen haben, siehe Abb. 2.3. Die Wortbeispiele sind dem *Thesaurus Linguae Aegyptiae* (TLA)<sup>3</sup> entnommen, der im Auftrag der Berlin-Brandenburgischen Akademie der Wissenschaften sowie der Sächsischen Akademie der Wissenschaften zu Leipzig gepflegt wird und das weltweit größte elektronische Korpus an lemmatisierten ägyptischen Texten, transliteriert aus hieroglyphischen, hieratischen, demotischen und künftig auch koptischen Schriftzeugnissen, darstellt (Richter et al. (2024)).




**Abbildung 2.4:** Doppelt logarithmische Auftragung der relativen Häufigkeit eines Wortes als Funktion seines Rangs für die Werke fünf europäischer alphabetischer Sprachen (links) sowie der Häufigkeit der Schriftzeichen für die Werke dreier asiatischer syllabischer Sprachen (rechts)<sup>4</sup>.

---

<sup>3</sup><https://thesaurus-linguae-aegyptiae.de>, Korpus-Ausgabe 19, Web-App-Version 2.2.0 vom 05.11.2024, besucht am 03.02.2025

<sup>4</sup>Stolfi, J., Zipf Law plot for German, Russian, French, Italian, and Medieval English texts (commons.wikimedia.org) & Zipf Law plots for three East Asian languages: Tibetan, Chinese, Vietnamese, (commons.wikimedia.org), Versionen vom 09.05.2023, besucht am 04.02.2025

Auf der Basis des Textmaterials im TLA sowie der sog. Pyramiden-Texte wurde von Werning (2021) eine repräsentative Zählung von ca. 1,7 Mio. Hieroglyphen vorgenommen, sodass daraus eine Häufigkeitsverteilung erstellt werden kann. Aus der Linguistik ist bekannt, dass für eine Sprache die Häufigkeit ihrer Wörter grob dem relativ einfachen Zipfschen Gesetz folgt. Sortiert man die Wörter absteigend nach ihrer Häufigkeit und betrachtet ihren Rang  $r$  auf solch einer Häufigkeitsliste, so ist die Wahrscheinlichkeit  $p$  ihres Auftretens umgekehrt proportional zu ihrem Rang, also  $p(r) \sim \frac{1}{r}$  (Piantadosi (2014)). Zum Zwecke der Normierung kann bei insgesamt  $N$  Elementen in der Liste der Faktor  $H_N = \sum_{r=1}^N \frac{1}{r}$  berechnet werden und die relative Häufigkeit eines Wortes in einem Korpus annähernd mit  $p(r) = \frac{1}{H_N} \cdot \frac{1}{r}$  abgeschätzt werden. Trägt man den Rang auf der  $x$ -Achse und die relative Häufigkeit auf der  $y$ -Achse auf, so ergibt sich eine hyperbolische Trendkurve. Verwendet man eine doppelt logarithmische Auftragung, so erhält man eine fallende Trendgerade.




**Abbildung 2.5:** Doppelt logarithmische Auftragung der relativen Häufigkeit einer Hieroglyphe als Funktion ihres Rangs auf Basis der Absolutwerte in Werning (2021). Es wurden nur Hieroglyphen im Ranking behalten, die unter den etwa 1,7 Mio. gezählten Zeichen mind. zehn Mal vorkamen.

Abb. 2.4 links zeigt den erwarteten, annähernd linearen Verlauf bei der Auswertung von Worthäufigkeiten für Textkorpora aus fünf europäischen Sprachen. Asiatische Sprachen wie z.B. Chinesisch, die keine alphabetische Schrift haben, zeigen einen analogen Verlauf, wie u.a. von Liu et al. (2017) gezeigt wurde. Wenn aber Zeichenhäufigkeiten für Sprachen wie Chinesisch oder Vietnamesisch, deren Schrift auf Silben basiert, analysiert werden, ergibt sich an beiden Enden des Rankings eine signifikante Abweichung von der Trendgerade, siehe Abb. 2.4 rechts. Eine Auswertung der relativen Häufigkeiten der ägyptischen Hieroglyphen in Abb. 2.5 auf Basis von Werning (2021) zeigt ein hierzu



analoges Ergebnis, was den Charakter der Hieroglyphenschrift als Spezialfall einer Mischung aus alphabetischer, Silben- und Bildschrift unterstreicht. Die Tabelle in Anhang B listet die 300 häufigsten Zeichen dieser Auswertung auf. Auf Basis dieser Liste können grundsätzliche Entscheidungen bzgl. der Konstruktion eines Klassifikators getroffen werden. Obwohl auf den vorderen Rängen hauptsächlich die alphabetischen Einkonsonantenzeichen zu finden sind, ist die zuverlässige Erkennung der selteneren Hieroglyphen, die hauptsächlich Determinative darstellen, eine Kernaufgabe im Rahmen dieser Arbeit, da diese Zeichen maßgeblich die Bedeutung einer Lautfolge bestimmen.

## 2.3 Leserichtungen




**Abbildung 2.6:** Abbildung aus Allen (2014a) mit eigenen farbigen Markierungen, die alle vier möglichen Schreibrichtungen der Hieroglyphenschrift darstellt. Gelb markierte Zeichen sind gute Indikatoren zur Erkennung der Links-Rechts-Leserichtung.

Die losgelöste Erkennung von Hieroglyphen ist noch nicht ausreichend für eine darauf aufbauende Übersetzung. Essenziell ist an dieser Stelle auch die Ermittlung der korrekten Reihenfolge der Zeichen. Abb. 2.6 zeigt alle vier üblichen Schreibrichtungen der Hieroglyphenschrift. Die Textabschnitte B (horizontaler Teil) und D sind horizontal von rechts nach links geschrieben, die Abschnitte A (horizontaler Teil) und C analog von links nach rechts. Die vertikalen Abschnitte von B und A sind spaltenweise zu lesen (B: rechts-links, A: links-rechts). Ob von rechts nach links oder umgekehrt gelesen werden soll, kann meist auf einen Blick anhand von Hieroglyphen, die Menschen, Tiere oder

deren Gliedmaßen darstellen, ermittelt werden: Solche Hieroglyphen blicken immer zum Textanfang. In Abb. 2.6 sind einige aussagekräftige Zeichen gelb markiert. Dies genügt jedoch noch nicht zur Bestimmung der genauen Lesereihenfolge, da Zeichen bei horizontaler Schreibweise auch übereinander bzw. bei vertikaler Schreibung nebeneinander stehen können. Werden die Zeichen in Zeilen geschrieben, so versucht man zunächst, die Zeichengruppen in aufrechte Rechtecke oder Quadrate zu rahmen, siehe z.B. die orangen Boxen für den horizontalen Teil von Text B. Die Boxen werden dann in Leserichtung von oben nach unten ausgelesen. Sollte dies wie bei dem Quadrat mit den Zeichen 6, 7 und 8 noch nicht möglich sein, so muss diese Box zunächst noch in liegende Rechtecke zerlegt werden (grüne Linie), die dann von oben nach unten und intern in Leserichtung zu lesen sind. Werden Hieroglyphen andererseits in Spalten geschrieben, so verfährt man analog und segmentiert den Text in liegende Rechtecke oder Quadrate, die dann von oben nach unten und intern in Leserichtung ausgelesen werden (siehe violette Boxen des 2. Teils von B). Ggf. müssen Boxen noch in stehende Rechtecke zerlegt und dann in Leserichtung und intern von oben nach unten wiedergegeben werden (beispielsweise die Box mit den Zeichen 32-35). Auf diese Weise wurden die Textbeispiele A und B aus Abb. 2.6 vollständig segmentiert und entsprechend der Leserichtung nummeriert. Der gesamte Prozess der Bestimmung der Zeichenreihenfolge wird im Folgenden als „Sequenzierung“ bezeichnet. Die einzelnen Hieroglyphen können anschließend klassifiziert werden.

## 2.4 Vom Bild zu maschinenlesbarem Text - Die Prozessschritte im Überblick



**Abbildung 2.7:** Darstellung des Gesamtprozesses von der Inschrift hin zur Übersetzung. Die Schritte i) bis iii) beschreiben den Einleseprozess, die Schritte iv) und v) den Übersetzungsprozess.

Der Gesamtprozess des maschinellen Einlesens einer hieroglyphischen Inschrift bis hin zur Übersetzung ist in Abb. 2.7 anhand eines Beispiels in Teilschritten skizziert. Die Schritte i) bis iii) umfassen den Einleseprozess, d.h. die Transformation vom Bild in



---

maschinenlesbaren Text, beginnend mit der Segmentierung der Hieroglyphen, über die Sequenzierung bis hin zur Klassifikation der einzelnen Zeichen. Das Ergebnis dieses Teilprozesses könnte eine Repräsentation der Zeichenfolge in Gardiner- oder auch Unicode sein. Die Schritte iv) und v) deuten den anschließenden Übersetzungsprozess an, bei dem zunächst die Wörter segmentiert werden sollten und schließlich darauf aufbauend eine Übersetzung in eine beliebige Sprache erfolgen kann.

Nach der Darstellung der Grundlagen zur ägyptischen Hieroglyphenschrift oben sind für die einzelnen Prozessschritte folgende technische Komplikationen absehbar:

- i) Bei der Hieroglyphenschrift sind die einzelnen Zeichen strikt voneinander abgegrenzt, was eine Segmentierung erleichtert. Allerdings gibt es einige Zeichen, die aus mehreren „Einzelteilen“ bestehen. In Abb. 2.7 sind die drei Striche als ein Zeichen  (Z2) und NICHT dreimal als das Zeichen  (Z1) zu erkennen. Weitere absehbare Problembeispiele sind , ,  und vor allem  (O3). Zudem muss gewährleistet werden, dass Beschädigungen des Schreibmaterials, wie ausgeschlagene Stellen einer Steintafel oder Löcher im Papyrus, von einem Modell nicht als potentielle Schriftzeichen erkannt werden. Auch Trennlinien für Spalten bzw. Zeilen sowie die Namen einrahmende Kartusche müssen ignoriert werden.
- ii) Ein maschinelles Modell muss bei der Bestimmung der Leserichtung ggf. mit mehreren Richtungen pro Bild zurecht kommen, wie der Extremfall von Abb. 2.6 zeigt.
- iii) Der Klassifikator der Einzelglyphen muss mehr als 1000 Klassen unterscheiden können. Zwar sind etwa 200 Zeichen besonders häufig, aber die korrekte Erkennung seltener Zeichen ist gerade für den Übersetzungsvorgang besonders wichtig. Beim Training des Klassifikators ist die Sammlung von ausreichend vielen Beispielen für seltene Hieroglyphen eine absehbare Herausforderung. Zudem gibt es Gruppen von Hieroglyphen, die sich optisch wenig voneinander unterscheiden, wie z.B. die Gardiner-Gruppe A oder G, was eine scharfe Trennung durch den Klassifikator erschwert.
- iv) Nachdem es keine expliziten Worttrenner in der Hieroglyphenschrift gibt wie z.B. Leerzeichen im Deutschen, stellen die erkannten Determinative eine gute Hilfestellung zur Wortsegmentierung dar. Verkürzung oder alternative Schreibungen können hier schnell Probleme verursachen. Beispielweise kann das Wort *ntr.w* „Götter“ durch die Schreibungen  (dreimal R8) oder  (R8, Z3) ausgedrückt werden. Ein Worttrenner muss die Pluralschreibungen in beiden Fällen richtig erkennen.
- v) Die Übersetzung einer (korrekten) Zeichensequenz kann durch Abgleich mit einem Wörterbuch erfolgen. An dieser Stelle kommt aber erschwerend hinzu, dass die Wortlänge im Ägyptischen variabel ist (siehe phonetische Komplementierung oben). Bei der Erstellung eines Wörterbuchs müssen also theoretisch alle denkbaren Varianten berücksichtigt werden. Ebenso sorgt das Auslassen von gramma-

---

tikalischen Bausteinen, die ggf. vom Leser über den Kontext erschlossen werden müssen, für Probleme bei einer sinnvollen Übersetzung.

Die maschinelle Verarbeitung der einzelnen Prozessschritte wurde bisher nur durch einige wenige Forschergruppen analysiert. Im nächsten Kapitel wird der Stand der Forschung präsentiert, wobei jeder Ansatz in den oben skizzierten Gesamtprozess eingeordnet wird.

# Kapitel 3

## Stand der Forschung

Jede der Teilaufgaben des in Abb. 2.7 dargestellten Gesamtprozesses ist für sich herausfordernd und bedarf einer eigenen Methodik für eine auf möglichst viele Beispiele anwendbare Lösung. Dieses Kapitel beschreibt die Bearbeitung der unterschiedlichen Teilaufgaben durch einige Forschergruppen in den letzten 10 Jahren.

### 3.1 Erster Ansatz zur Hieroglyphenerkennung in den Pyramidentexten durch Franken und van Gemert (2013)

Franken und van Gemert (2013) haben die Segmentierung über einen Retrieval-Ansatz mithilfe von Saliency Maps gelöst, die potentiell als Text relevante Abschnitte eines Bildes hervorheben. Die so erkannten Zeichen wurden rechteckig über Bounding Boxen ausgeschnitten. Die Leserichtung wurde als konstant von rechts nach links und in Spalten vorgegeben und die Bounding Boxen entsprechend sortiert. Zum Zweck der Klassifikation der Einzelglyphen haben die Autoren einen ersten Datensatz von 3993 Einzelbildern von insgesamt 161 verschiedenen Hieroglyphen erarbeitet, die aus 10 Fotografien der Pyramidentexte in der Pyramide des Pharaos Unas in Sakkara manuell ausgeschnitten, mit dem Gardiner-Code gelabelt und ggf. retuschiert wurden, bspw. im Falle sich überlappender Hieroglyphen. Für die einzelnen Patches sind die Pixelkoordinaten dokumentiert, sodass die ausgeschnittenen Boxen auch in den Gesamtbildern der Inschriften wiedergefunden werden können. In späteren Arbeiten wurde dieser Datensatz vielfach wiederverwendet. Für die Merkmalsextraktion wurden fünf verschiedene Bilddeskriptoren getestet, von denen HOG (Histogram of Oriented Gradients) und HOOSC (Kombination von HOG und Shape Context) die besten Ergebnisse lieferten. HOG erzeugt ein Histogramm orientierter Kantengradienten im Bild<sup>1</sup>, wohingegen der Shape Context ein von Belongie und Malik (2000) vorgestellter Shape Descriptor ist, der wichtige Merkmale einer Zeichenform in der Umgebung eines Punktes extrahiert und auf diese Weise Punktkorrespondenzen erkennt (z.B. bei der Handschrifterkennung). Anschließend wurden verschiedene Matching-Schemata auf die Bildausschnitte angewendet, um die Ähnlichkeit mit gelabelten Patches zu quantifizieren. Als beste Methode stellte sich hier das paarweise Patch-Matching, bei dem Bildausschnitte durch den Vergleich ihrer markanten Merkmale (Interest Points) miteinander abgeglichen werden, heraus, wobei die

---

<sup>1</sup>[de.wikipedia.org](http://de.wikipedia.org), besucht am 10.02.2025

räumliche Beziehung der Punkte im Bild berücksichtigt wird, um die Genauigkeit der Übereinstimmungen zu erhöhen. Die Anwendung des gängigen Bag-of-Words-Modells mit 200 visuellen Wörtern lieferte das ungenaueste Matching. Beide Methoden wurden bereits von Roman-Rangel et al. (2011) bei der Klassifikation von Maya-Glyphen verwendet. Der Output des Klassifikators umfasste ein Ranking der Top 10 Ergebnisse, aus denen mit Unterstützung durch ein Large Language Model (LLM) die wahrscheinlichste Klasse ausgewählt wurde. Das LLM wurde auf 158 Pyramidentexten aus dem JSesh-Projekt<sup>2</sup> trainiert und nutzte  $N$ -grams mit  $N = 3$ , um die Wahrscheinlichkeit von Teilsequenzen der Länge  $N$  miteinzubeziehen. Im Schnitt wurden manuell ausgeschnittene Hieroglyphen mithilfe der verschiedenen Methoden zu 74% korrekt klassifiziert, bei automatisch ausgeschnittenen Hieroglyphen wurde eine Klassifikationsrate von etwa 53% erzielt. Die Verwendung des LLM verbesserte die Genauigkeit der einzelnen Verfahren nur um jeweils etwa 1%. Die gesamte Pipeline ist in Abb. 3.1 wiedergegeben. Da der Code für den Klassifikator<sup>3</sup> veraltet war und in aktuellen Umgebungen aufgrund einer unzureichenden Dokumentation nicht lauffähig war, konnten keine eigenen Experimente durchgeführt werden. Der Code für die Segmentierung wurde nicht bereitgestellt. Aufgrund der optisch relativ einheitlichen Bilder, die als Referenz für den Vergleich verwendet wurden, ist fragwürdig, ob auch gute Klassifikationsergebnisse bei variablerem Bildmaterial erzielt worden wären.




Abbildung 3.1: Pipeline für die Hieroglyphenerkennung nach Franken und van Gemert (2013).

## 3.2 Maschinelle Auswertung hieroglyphischer Handschriften durch Nederhof (2016)

Nederhof (2016) hatte zum Ziel, einige Bände der handgeschriebenen *Urkunden IV* von Sethe (1909) zu digitalisieren (siehe beispielsweise Abb. 3.2 links). Die handgeschriebenen Hieroglyphen waren per Optical Character Recognition (OCR) bis dato noch nicht zugänglich und sollten in großem Umfang in maschinenlesbaren Text umgewandelt werden. Das Tool (Abb. 3.2 rechts) arbeitet mit Schwarz-Weiß-Abbildungen und erlaubt bei jedem der im Folgenden beschriebenen Schritte eine manuelle Bearbeitung. In der

<sup>2</sup><http://jsesh.qenherkhopeshef.org/>, besucht am 10.02.2025

<sup>3</sup><https://github.com/morrisfranken/glyphreader>, besucht am 15.11.2024

Anwendung können Zeilen von Text manuell ausgewählt oder auch automatisch mithilfe von nicht näher beschriebenen Text-Retrieval-Heuristiken erkannt werden. Die einzelnen Hieroglyphen werden als eine Menge zusammenhängender schwarzer Pixel („Blobs“) erkannt. Offensichtlich wird wie in Sethes Manuskript vorgegeben die Leserichtung stets von links nach rechts angenommen. Zur Klassifikation einer Glyphe wird diese mit gelabelten „Prototypen“ gleicher Größe mithilfe des Algorithmus Image Distortion Model verglichen. Zur Reduktion der Laufzeit wird die Schnelle Fourier-Transformation auf die zu vergleichenden Bilder angewendet und die 2252 Prototypen (490 verschiedene Zeichen repräsentierend) nach unterschiedlichen Aspekten gerankt, um nicht alle möglichen Vergleiche durchführen zu müssen. Der Klassifikator gibt die Top 5 wahrscheinlichsten Klassen zurück. Tests auf Sethes *Urkunden IV* ergaben eine Klassifikationsgenauigkeit von ca. 91% und eine Top-2-Genauigkeit von 95,5%, was im Hinblick auf das initial formulierte Ziel als Erfolg zu bewerten ist, nachdem nur noch 9% aller handgeschriebenen Zeichen im Manuskript manuell zugeordnet werden müssten. Hervorzuheben ist an dieser Stelle noch, dass das Tool nicht nur die Zeichen erkennt, sondern auch die Zeichenanordnung extrahiert. Der Code zum Tool ist frei zugänglich<sup>4</sup>, war jedoch aufgrund von Kompatibilitätsproblemen nicht lauffähig und damit auch nicht auf andere Abbildungen anwendbar. Die Autoren räumten aber im Paper ein, dass bereits ein Test auf einer anderen Handschrift schlechte Resultate lieferte, da die Prototypen eines Manuskripts nicht allgemeingültig sind. Die Anwendung ist daher stark auf Sethes *Urkunden IV* zugeschnitten. Eine gute Generalisierung erforderte wie bei Franken und van Gemert (2013) eine ausreichend starke Variation in den gelabelten Prototypen, wobei der Rechenaufwand der Vergleiche dann ebenfalls stark anstiege.





Abbildung 3.2: Links: Auszug aus *Urkunden IV* von Sethe (1909), S. 998. Rechts: OCR-Anwendung von Nederhof (2016).

<sup>4</sup><https://mjn.host.cs.st-andrews.ac.uk/egyptian/align/>, besucht am 15.11.2024

---

### 3.3 Projekt Fabricius

Das *Fabricius-Projekt*<sup>5</sup> war eine Kollaboration zwischen Google Arts & Culture, dem Australian Centre of Egyptology an der Macquarie Universität und dem Spieleentwickler Ubisoft. Das Projekt begann mit *The Hieroglyphics Initiative* von Ubisoft, die zeitgleich mit dem Launch des im Alten Ägypten angesiedelten Computerspiels *Assassin's Creed Origins* zusammenfiel. Das Ergebnis dieser Zusammenarbeit war die Anwendung *Fabricius*<sup>6</sup>, die das erste einer breiten Öffentlichkeit zugängliche Tool für die maschinelle Erkennung und Bearbeitung von Hieroglyphentexten darstellte (Abb. 3.3). Ziel des Projekts war es, Ägyptologen als auch dem breiten Publikum eine computergestützte Übersetzung von den bislang nur manuell durch Experten untersuchten Hieroglyphentexten bereitzustellen<sup>7</sup>. Der Code ist open source<sup>8</sup>.



**Abbildung 3.3:** Startseite der Anwendung Fabricius von Google Arts & Culture.

Das Tool arbeitet mit drei APIs im Hintergrund. Die erste API extrahiert die einzelnen Hieroglyphen als Pixelcluster mithilfe von DBSCAN. Im Code sind alle möglichen Leserichtungen berücksichtigt, jedoch geht aus der Dokumentation nicht hervor, wie die Anwendung die Leserichtung erkennt. Bei Tests wurde durch das Tool stets eine Leserichtung von links nach rechts angenommen. Die zweite API ist ein auf einem neuronalen Netz basierender Klassifikator, der bei Google Cloud AutoML Vision trainiert wurde und gehostet wird. Der Klassifikator wurde auf 80.000 handgeschriebenen Hieroglyphen aus über 1000 Klassen trainiert, die im Rahmen von *The Hieroglyphics Initiative* über das Internet gesammelt wurden. Die letzte API macht Übersetzungsvorschläge auf der Grundlage einer Gardiner-Code-Sequenz durch Abgleiche mit einem

---

<sup>5</sup>[artsandculture.google.com](https://artsandculture.google.com/), besucht am 11.02.2025

<sup>6</sup><https://fabriciusworkbench.withgoogle.com/>, besucht am 11.02.2025

<sup>7</sup>[youtube.de](https://youtube.de), besucht am 11.02.2025

<sup>8</sup><https://github.com/googleartsandculture/workbench>, besucht am 11.02.2025

---

Wörterbuch, das auf Daten aus dem TLA basiert. Die browserbasierte Anwendung ist ansprechend und benutzerfreundlich gestaltet. Zunächst wird ein Projekt erstellt und ein Bild geladen. Die Verarbeitung eines per Font generierten Beispiels ist in Anhang C zu sehen. Im Schritt 1 wird der zu analysierende Bereich ausgewählt und automatisch in eine Schwarz-Weiß-Abbildung transformiert mit der Möglichkeit einer Anpassung des Helligkeitsgrads. In Schritt 2 muss jegliches Rauschen ausradiert und fehlerhafte Hieroglyphen sollen nachgezeichnet werden. Über einen Konturregler kann der Detailgrad des Ausschnitts weiter angepasst werden. In Schritt 3 erfolgt nach Auswahl des interessanten Bildbereichs eine automatische Analyse. Hierbei werden die Hieroglyphen segmentiert, sequenziert und klassifiziert. Die Klassifikation des Fonts-Textes ergab etwa eine Trefferquote von 50%. Der Nutzer kann an dieser Stelle Zeichen entfernen und die Klassifikationsergebnisse korrigieren. Anschließend stellt ein automatischer Übersetzer für alle möglichen Teilsequenzen Übersetzungsvorschläge bereit. Danach kann das Bild noch annotiert und schließlich kann das Projekt exportiert werden. Das Tool besitzt im Großen und Ganzen viele hilfreiche Funktionalitäten bei der Bearbeitung von Bildern hieroglyphischer Texte, erfordert jedoch gerade bei Fotografien von Inschriften ein hohes Maß an manueller Vorverarbeitung des Bildes. Das Klassifikationsergebnis ist schon bei einem Font-Beispiel nicht zufriedenstellend und auch wenn das Klassifikationsergebnis manuell nachjustiert wurde, wird keine passende Gesamtübersetzung ausgegeben, sondern es werden nur einzelne Teilsequenzen ohne Einbezug ihres Kontextes für sich übersetzt. Bei der Analyse eines handgeschriebenen Beispiels versagt der Klassifikator schließlich komplett, wie man im letzten Bild in Anhang C sehen kann. Für eine universellere Einsetzbarkeit muss die Anwendung offenbar nachtrainiert werden.

### **3.4 Implementierung des Gesamtprozesses durch Hossam et al. (2018)**

Hossam et al. (2018) verfolgten das Ziel des maschinellen Einlesens in Spalten geschriebener hieroglyphischer Inschriften mit vertikalen Trennlinien wie in Abb. 3.4 links. In ihrem Verfahren werden bei einer Vorprozessierung schräg aufgenommene Bilder nach diesen Trennlinien ausgerichtet. Nach einer Konvertierung in Greyscale wird Canny Edge Detection angewendet, um relevante Kanten im Bild zu extrahieren. Mithilfe einer Hough-Transformation werden die vertikalen Trennlinien als Geraden einer von der Bildhöhe abhängigen Mindestlänge erkannt und das Bild anschließend in Spalten geschnitten. Zur Segmentierung innerhalb der Spalte wird erneut Canny Edge Detection angewendet und aus dem erhaltenen Kantenbild werden die Hieroglyphen als Zusammenhangskomponenten mithilfe von 8-Connectivity extrahiert. Pixel sind 8-connected, wenn sie eine gemeinsame Ecke oder Kante haben. Die Minimal- bzw. Maximalkoordinaten der Komponenten definieren eine Bounding Box für die Hieroglyphe. Die Boxen werden dann anhand ihrer Oberkante von oben nach unten sortiert, wobei bei nebeneinanderliegenden Zeichen ggf. die Leserichtung mit einfließt. Die Leserichtung wird mithilfe von HOG ermittelt, indem die auf gleicher Höhe liegenden Patches mit ge-

labelten Einzelbildern, die eine Links- oder Rechtsorientierung aufweisen, verglichen werden. Die so ermittelte Leserichtung wird für den Rest der Spalte angewendet. Mit diesem Verfahren wurde eine Segmentierungsrate von ca. 84% bezogen auf manuelle Segmentierung erreicht. Beim Nachprozessieren der segmentierten Hieroglyphen werden zu kleine Patches als Rauschen verworfen und alle Bilder auf eine einheitliche Größe skaliert. Für die Klassifikation mit Gardinercode erfolgt eine Merkmalsextraktion auf dem zu klassifizierenden Bild und den ca. 700 gelabelten Vergleichsbildern von 197 verschiedenen Hieroglyphen mithilfe von HOG. Die Feature-Vektoren werden bzgl. der euklidischen Distanz verglichen. Zusätzlich zum wahrscheinlichsten Gardiner-Code wird eine englische Übersetzung der Hieroglyphe ausgegeben. Die Autoren räumen ein, dass diese Art der Übersetzung nur eine grundlegende Idee der eigentlichen Bedeutung eines Texts wiedergibt, wie das Beispiel in Abb. 3.4 rechts aus dem Paper zeigt. Der nicht weiter geprüfte Übersetzungsvorgang trägt also nur wenig zum Gesamtwert der Arbeit bei. Für eigene Experimente ist der Code zum Paper nicht bereitgestellt worden und die Autoren beantworteten keine Anfragen. Bis auf einige Ergänzungen sind keine großen Neuerungen im Vergleich zu der Arbeit von Franken und van Gemert (2013) erkennbar.



**Abbildung 3.4:** Links: Ausschnitt aus der durch vertikale Trennlinien strukturierten Inschrift aus der Pyramide des Unas aus dem Datensatz von Franken und van Gemert (2013). Rechts: Beispiel eines Übersetzungsversuchs Hieroglyphe für Hieroglyphe aus dem Paper von Hossam et al. (2018).


### 3.5 Verwendung von CNNs für Segmentierung und Klassifizierung durch Barucci et al. (2021)

Barucci et al. (2021) erarbeiteten neuartige Ansätze für die Segmentierung hieroglyphischer Texte und Klassifizierung der Einzelbilder mithilfe von Deep-Learning-Algorithmen. Für die Segmentierung verwendete die Gruppe den Mask R-CNN der Plattform *Detec-tron2*, die von Facebook AI Research unterhalten wird und Implementierungen zahlreicher Objekterkennungsalgorithmen bereitstellt<sup>9</sup>. Der Mask R-CNN basiert auf ei-

<sup>9</sup><https://ai.meta.com/tools/detectron2/>, besucht am 12.02.2025



nem Convolutional Neuronal Network (CNN). Grundlagen zu CNNs und den darauf aufbauenden Architekturen, die für die Beschreibungen in dieser Arbeit relevant sind (R-CNN, Fast R-CNN, Faster R-CNN, FPN, Mask R-CNN), sind in Anhang E zusammengetragen. Das Standard-Backbone bei den Objekterkennungsalgorithmen der Detectron2-Plattform ist ResNet50 mit einem Feature Pyramid Network (FPN). ResNet50 ist ein CNN mit 50 Layern und 25,6 Mio. Parametern, das residuelle Verbindungen (Skip Connections) nutzt, um eine oder mehrere Schichten überspringen zu können und so das Vanishing-Gradient-Problem (Gradienten werden auf Null abgerundet) zu reduzieren, das häufig bei sehr tiefen Netzwerken auftritt. Die API von Detectron2 bietet eine Reihe von Parametern<sup>10</sup> zur Konfiguration der Algorithmen. Barucci et al. variierten bei der Nutzung von Detectron2 für die Segmentierung lediglich die Parameter `SOLVER.MAX_ITER` für die Anzahl der Iterationen beim Training und `ROI_HEADS.SCORE_THRESH_TEST` für die Festlegung des Thresholds für die Sicherheit einer erkannten Instanz (solche mit geringerer Wahrscheinlichkeit werden verworfen). Für das Training des Algorithmus wurden 100 annotierte Bilder von Stelen und Papyri eingesetzt (Training, Validierung und Testing im Verhältnis 59:14:27). In dem annotierten Bildmaterial wurden die Hieroglyphen mithilfe der Software *VGG Image Annotator* (VIA)<sup>11</sup> manuell polygonal eingerahmt, vgl. Abb. 3.5 links. VIA wurde von Dutta und Zisserman (2019) entwickelt und ermöglicht eine benutzerfreundliche Annotation von Bildern oder polygonalen bzw. rechteckigen Bounding Boxen darin, deren Ecken in einer JSON-Datei gespeichert werden. Auf diese Weise annotierten die Autoren 2198 Hieroglyphen für das Training und 564 für die Validierung. Zur Evaluation der Objekterkennung wurden von Detectron2 bereitgestellte Standardmetriken eingesetzt, wie bspw. die durchschnittliche Genauigkeit (Average Precision, AP) und die Intersection over Union (IoU), die angibt, zu welchem Prozentsatz sich die Fläche des manuell ausgeschnittenen Polygons mit der Fläche der vom Algorithmus berechneten Bounding Box überlappen.



**Abbildung 3.5:** Links: Polygonale Einrahmung der Hieroglyphen mit dem Tool VIA. Rechts: Ergebnis der Objekterkennung durch das Mask R-CNN. Aus Barucci et al. (2021).

<sup>10</sup><https://detectron2.readthedocs.io/en/latest/modules/config.html>, besucht am 14.02.2025

<sup>11</sup><https://www.robots.ox.ac.uk/~vgg/software/via/via.html>, besucht am 14.02.2025

---

Für die Segmentierung wurde sowohl ein von Grund auf trainiertes Mask R-CNN als auch ein bereits auf dem COCO-Datensatz vortrainiertes Modell getestet. COCO ist ein large-scale Datensatz für die Objekterkennung mit über 330.000 Bildern und 1,5 Mio. gelabelten Instanzen darin<sup>12</sup>. Letzteren Ansatz bezeichnet man im maschinellen Lernen als Transfer Learning (TL), einer Technik, bei der ein Modell, das auf einer großen Menge an Daten für eine bestimmte Aufgabe vortrainiert wurde, auf eine andere, oft ähnliche Aufgabe angewendet wird. Anstatt ein Modell von Grund auf neu zu trainieren, nutzt man das Wissen, das das Modell aus der ersten Aufgabe erlernt hat, um schneller und effizienter eine neue Aufgabe zu lösen. Hierbei wird das vortrainierte Modell für die neue Aufgabe meist nur feinjustiert (fine-tuned), indem nur die Gewichte der letzten Schichten des Modells angepasst werden. Diese Technik ist besonders nützlich, wenn für die neue Aufgabe nur begrenzte Daten zur Verfügung stehen.

Die Autoren testeten eine Iterationsanzahl von 300 bis 3000 Durchläufen, wobei bei wachsender Anzahl an Iterationen eine monoton steigende AP bzgl. der IoU beobachtet wurde, die ab etwa 1000 Iterationen ein Plateau bei einer AP von etwa 70% erreichte. Die manuell erstellten Polygone und die vom Modell ausgegebenen deckten sich also zu diesem Anteil. Im Paper gehen die Autoren nicht darauf ein, ob und wie die erkannten Hieroglyphen in die richtige Reihenfolge gebracht wurden. Der Aspekt der Leserichtung wurde hier komplett weggelassen. Der Code zur Segmentierung sowie der zugehörige Datensatz konnten von den Autoren nicht bereitgestellt werden, da diese durch einen Hardwaredefekt verloren gegangen waren.

Als CNNs für die Klassifikationsaufgabe wendeten die Autoren TL auf die neuronalen Netze ResNet50, Inception-v3<sup>13</sup> und Xception<sup>14</sup> an. Letztere haben mit ca. 23 Mio. Parametern eine mit ResNet50 vergleichbare Parameteranzahl. Zudem wurde ein eigenes, auf Hieroglyphen spezialisiertes Netzwerk *Glyphnet* designt, das mit nur 500.000 Parametern auskommt. Zum Training wurde der Datensatz von Franken und van Gemert (2013) angereichert um einen eigenen Datensatz der Autoren, der leider nicht veröffentlicht wurde. Die Einzelbilder wurden unter Beibehaltung des Seitenverhältnisses und Auffüllen mit weißem Hintergrund auf ein Format 100x100 Pixel gebracht. In einem zweiten Schritt wurden die weißen Bereiche durch eine pseudorandomisierte Gaußtextur ersetzt, die der ursprünglichen Umgebung rund um die Hieroglyphe entspricht. Der finale Datensatz enthielt 4309 Beispiele aus 40 Klassen. Die Bilder wurden im Verhältnis 70%, 15% und 15% in Trainings-, Validierungs- und Testbeispiele aufgeteilt. Data Augmentation - eine Strategie zur Reduzierung der Heterogenität eines Datensatzes, bspw. hervorgerufen durch eine unausgeglichene Repräsentation der Klassen - wurde angewendet, um den Trainingsdatensatz durch unterschiedliche Bildbearbeitungstechniken anzureichern<sup>15</sup>, weitere Patches wurden zu dünn besetzten Klassen hinzugefügt und Datenumfänge in Klassen mit vielen Beispielen reduziert. Nach diesen Prozessie-

---

<sup>12</sup><https://cocodataset.org/#home>, besucht am 15.02.2025

<sup>13</sup><https://keras.io/api/applications/inceptionv3/>, besucht am 15.02.2025

<sup>14</sup><https://keras.io/api/applications/xception/>, besucht am 15.02.2025

<sup>15</sup>horizontaler Flip, zufällige Translationen um max. 10 Pixel, Rotationen um max. 10 Grad und Zooming mit einem Faktor zwischen 0.95 und 1.05

---

rungsschritten enthielt der Trainingsdatensatz 7340 Patches. Das Training von Glyphnet lieferte bessere Ergebnisse als das Fine-Tuning der vortrainierten Architekturen. Letztere erreichten eine Klassifikationsgenauigkeit von etwa 95%, Glyphnet dagegen eine Genauigkeit von 97,6%. Der Code für Glyphnet wurde in einem Git Repository bereitgestellt<sup>16</sup>. Ein Blick in das Notebook `utils.ipynb` bestätigte, dass Glyphnet nur 40 der häufigeren Hieroglyphen kennt (vgl. auch Anhang B), was für eine umfassende Zeichenerkennung deutlich zu wenig ist. Bei unbekannten Labels bricht der Algorithmus direkt ab. Außerdem akzeptiert Glyphnet nur das Format 100x100 Pixel. Ein Kurztest mit fünf Font-Bildern und fünf Ausschnitten einer Inschrift wurde zur Überprüfung der Lauffähigkeit des Codes durchgeführt und ergab eine Genauigkeit von 90%, siehe Anhang D.

### 3.6 Hieroglyphenerkennung und -übersetzung durch Sobhy et al. (2023)

Sobhy et al. (2023) hatten nicht nur eine effiziente und möglichst genaue Hieroglyphenerkennung zum Ziel, sondern wollten auch einen Meilenstein in der Teilaufgabe der Übersetzung erreichen. Die Autoren verwendeten abermals den Datensatz von Franken und van Gemert (2013). Für die Hieroglyphenerkennung wurden die Gesamtbilder mithilfe von Albumentations<sup>17</sup> durch Erzeugung zufälliger Bildausschnitte (Random Cropping) auf 2000 Beispiele unterschiedlicher Auflösung erweitert. Die annotierten Bilder wurden für das Training<sup>18</sup> einem R-CNN mit ResNet-Backbone übergeben, das auf dem ImageNet-Datensatz<sup>19</sup> vortrainiert war. Das R-CNN sollte die Hieroglyphen vom Hintergrund mithilfe von rechteckigen Bounding Boxen heraussegmentieren. Auf dem Testdatensatz ergab sich eine AP von 95,9% und ein Average Recall (AR) von 74,4% bei einer IoU von 0,5, d.h. bei einer 50%-Box-Überlappung hat das Modell 74,4% der relevanten Objekte korrekt identifiziert.

Für die Klassifikationsaufgabe wurden die ca. 4000 Patches ebenfalls durch Data Augmentation auf 8226 Beispiele vervielfältigt<sup>20</sup>. Beim ersten Ansatz wurde ResNet50 mit drei zusätzlichen Layern verwendet, u.a. einem Input-Layer für die 75x70 Pixel großen Patches des Klassifikationsdatensatzes<sup>21</sup>. Unter Verwendung der angepassten ResNet50-Architektur wurde in einem zweiten Ansatz ein hierarchisches ResNet50-Modell programmiert, bei dem zunächst die Gardiner-Klasse und im zweiten Schritt dann mit weiteren Modellkopien das eigentliche Element aus der Gardiner-Klasse vorhergesagt wurde. Schließlich wurde als dritter Ansatz noch ein Siamese Network ge-

---

<sup>16</sup><https://github.com/GAIA-IFAC-CNR/Glyphnet>, besucht am 15.02.2025

<sup>17</sup><https://albumentations.ai/>, besucht am 17.02.2025

<sup>18</sup>Warmup mit 100 Epochen, 1000 Epochen Training, Lernrate 0,01, die bei der 400., 600. und 800. Iteration auf ein Zehntel reduziert wurde

<sup>19</sup><https://www.image-net.org/>, besucht am 17.02.2025

<sup>20</sup>Random Zoom bis 15%, Rotation bis  $\pm 11^\circ$ , Helligkeitsvariation bis  $\pm 21\%$ , Hinzufügen von Rauschpixeln

<sup>21</sup>Modellparameter: Stochastic Gradient Descent (SGD) als Optimizer mit Momentum 0,9, Lernrate 0,001, Batch Size 64, 400 Epochen und Categorical Cross-Entropy als Loss-Funktion

testet, da der Datensatz klein und unausgewogen ist und damit weniger vertretene Klassen schlechter erkannt werden. Ein Siamese Network ist eine spezielle Architektur von neuronalen Netzwerken, die vor allem für Aufgaben verwendet wird, bei denen die Ähnlichkeit oder Unterschiedlichkeit zwischen zwei Eingaben mithilfe einer gelernten Vergleichsfunktion zu messen ist. Das Siamese Network gehört zum One-Shot Learning, bei dem eine Vorhersage auf Basis von nur einem Beispiel pro neuer Klasse getroffen wird (Koch et al. (2015)). Konkret wird für die Klassenvorhersage jedes zu klassifizierende Bild mit einem oder mehreren gelabelten Ankerbildern verglichen, um die passendste Klasse zu identifizieren. Das Modell wurde zunächst mit dem Datensatz ohne Augmentierung auf allen Klassen trainiert<sup>22</sup> und anschließend mit Klassen mit weniger als 10 Bilder im Trainingsdatensatz feinabgestimmt<sup>23</sup>, um die Generalisierungsfähigkeit des Modells für die weniger vertretenen Klassen zu verbessern. Dem Siamese Network wurde zudem ein Sprachmodell auf Zeichenebene hinzugefügt, dass unter den Top3-Vorhersagen des Netzwerks die wahrscheinlichste Klasse auswählte. Das Sprachmodell basierte auf 3-Grams aus Gardiner-Code, die durch entsprechende Zerlegung der verfügbaren Sätze im zugrundeliegenden Datensatz erzeugt wurden. Die beste Performance erzielte die Kombination von Siamese Network und Sprachmodell mit einer Genauigkeit von 88,5%, wobei das Sprachmodell wie schon bei Franken und van Gemert (2013) nur 1% an Genauigkeit beitrug. Die ResNet50-Architekturen lieferten deutlich geringere Genauigkeiten, jedoch könnte eine ResNet50-Architektur bei einer größeren Datenbasis besser performen, da der paarweise Bildervergleich beim Siamese Network schnell sehr ressourcenintensiv wird.

|  |                         |       |                                                                             |                               |
|--|-------------------------|-------|-----------------------------------------------------------------------------|-------------------------------|
|  | Aa5-O34-U33-M17-A40     | imsti | Imseti                                                                      | one of the Four sons of Horus |
|  | M17-Aa5-G17-M36-D21-O36 | imDr  | rampart                                                                     |                               |
|  | M17-N35                 | in    | by, so says                                                                 |                               |
|  | M17-S3                  | in    | by, so says                                                                 |                               |
|  | W25-N35                 | ini   | bring, fetch, carry off, remove, overcome, reach, attain, buy, appoint, use |                               |
|  | W25                     | ini   | bring, fetch, carry off, bring away, bring about, remove something          |                               |

**Abbildung 3.6:** Auszug aus dem Wörterbuch von *Ancient Egypt and Archaeology*. Von links nach rechts: Hieroglyphische Schreibung, Gardiner-Sequenz, Transkription, englische Übersetzung, Kommentar.

Wie die einzelnen erkannten Hieroglyphen unter Beachtung der Leserichtung in die richtige Reihenfolge gebracht wurden, ist im Paper nicht beschrieben. Da aber nur auf dem Franken-Datensatz gearbeitet wurde, wurde die Leserichtung offenbar als konstant angenommen. Die sortierte Gardinersequenz wird über zwei unterschiedliche Ansätze zunächst in Wörter zerlegt. Beim einem Wörterbuch-basierten Algorithmus mit Maximum-Forward Matching wird zunächst für die längste Zeichensequenz in einem

<sup>22</sup>Adam-Optimizer, Lernrate von 0,001, Binary Cross Entropy als Loss-Funktion, 20.000 Iterationen, Batch-Größe von 128

<sup>23</sup>1.500 Iterationen mit einer reduzierten Lernrate von 0,000001 und Batch-Größe von 32

---

Wörterbuch eine Übereinstimmung gesucht. Als Wörterbuch wurde die Zusammenstellung auf der Webseite von *Ancient Egypt and Archaeology* verwendet<sup>24</sup>, die Hieroglyphentext, Gardiner-Code, Transkription und englische Übersetzung enthält, siehe Beispiel in Abb. 3.6. Bei einem Treffer im Wörterbuch wird die Sequenz entfernt, ansonsten wird das letzte Zeichen entfernt und die kürzere Sequenz gesucht. Der Algorithmus wiederholt sich, bis alle Zeichen oder Wörter entsprechend segmentiert sind. Beim Reverse-Maximum Matching wird analog bei fehlender Übereinstimmung ein Zeichen vom Anfang der Sequenz entfernt. Als zweiter Ansatz wurde der Subword-Tokenizer SentencePiece verwendet. SentencePiece ist ein unüberwachter Text-Tokenizer, der hauptsächlich für neuralnetzwerk-basierte Textgenerierungssysteme verwendet wird, bei denen die Wortschatzgröße vor dem Training des neuronalen Modells festgelegt wird<sup>25</sup>. Die beiden Matching-Algorithmen performten annähernd gleich gut mit jeweils einer Segmentierungsrate von etwa 60% und etwa dreimal so gut wie der Tokenizer.

Für die Übersetzung der segmentierten Transkription nach Englisch wurde die Tensorflow Transformer-Architektur<sup>26</sup> mit denselben Parametern wie bei Wiesenbach und Riezler (2019) verwendet. Der Transformer wurde dabei auf unterschiedlichen Datensatzvarianten trainiert. Als Textkorpus für das Training des Übersetzers diente einerseits der Fayrose-Datensatz in Github<sup>27</sup>, der u.a. 12.938 Paare aus mittelägyptischer Transkription und englischer Übersetzung beinhaltet, sowie andererseits der von Wiesenbach und Riezler (2019) vorbereitete Datensatz auf HuggingFace<sup>28</sup>, der 100.708 Tripel aus durch Gardiner-Code repräsentierte Hieroglyphen, deren Transkription sowie einer Übersetzung in Deutsch (teils auch Englisch) enthält<sup>29</sup>. In einer Vorverarbeitung wurden die deutschen Passagen des HuggingFace-Datensatzes in Englisch übersetzt und die Transkriptionssymbole beider Quellen angeglichen. Durch Data Augmentation mithilfe der Bibliothek *nlpaug*<sup>30</sup> wurden weitere Varianten des Fayrose-Datensatzes für das Modelltraining erzeugt. Mit BERT wurden zusätzliche Wörter eingefügt, die die Bedeutung des Satzes nicht beeinflussen. BERT (Bidirectional Encoder Representations from Transformers)<sup>31</sup> ist ein vortrainiertes sprachtechnologisches Modell von Google, das für verschiedene Natural Language Processing (NLP)-Aufgaben entwickelt wurde und das Computer beim Verständnis der Bedeutung mehrdeutiger Sprache in Texten unterstützen, indem der umgebende Text dazu verwendet wird, den Kontext herzustellen. Als weitere Variante wurde ein Datensatz erstellt, in dem unter Verwendung von WordNet<sup>32</sup> einzelne Wörter durch ihre Synonyme ersetzt wurden. Ein dritter Datensatz wurde durch Rückübersetzung erstellt, indem die Zielphrase in eine andere Sprache übersetzt und dann wieder ins Englische zurückübersetzt wurde, sodass sich

---

<sup>24</sup><https://www.ancient-egypt.co.uk/transliteration/dictionary.htm>, besucht am 17.02.2025

<sup>25</sup><https://github.com/google/sentencepiece>, besucht am 18.02.2025

<sup>26</sup>[https://www.tensorflow.org/api\\_docs/python/tfm/nlp/layers/Transformer](https://www.tensorflow.org/api_docs/python/tfm/nlp/layers/Transformer), besucht am 18.02.2025

<sup>27</sup><https://github.com/fayrose/EgyptianTranslation>, besucht am 17.02.2025

<sup>28</sup>[https://huggingface.co/datasets/phiwi/bbaw\\_egyptian](https://huggingface.co/datasets/phiwi/bbaw_egyptian), besucht am 17.02.2025

<sup>29</sup>Nur 35.503 Beispiele enthalten tatsächlich die hieroglyphische Codierung

<sup>30</sup><https://github.com/makcedward/nlpaug>, besucht am 17.02.2025

<sup>31</sup><https://arxiv.org/abs/1810.04805>, besucht am 17.02.2025

<sup>32</sup><https://wordnet.princeton.edu/>, besucht am 17.02.2025

---

bei gleichbleibender Bedeutung nur die Formulierung ändert. Schließlich wurde ein All-augmented-Datensatz erzeugt, der die drei Erweiterungsdatensätze zusammenführt. Für die Evaluation der Übersetzung wurden verschiedene BLEU-Scores verwendet. BLEU (Bilingual Evaluation Understudy) ist ein Verfahren zur automatischen Bewertung der Qualität von maschinellen Übersetzungen. Es basiert auf der  $N$ -gram-Übereinstimmung zwischen der maschinellen Übersetzung und einer oder mehreren Referenzübersetzungen, wobei hier ein  $N$ -gram eine Sequenz von  $N$  aufeinander folgenden Wörtern ist. Bei BLEU und corpusBLEU schnitt das auf dem Fayrose-Datensatz trainierte Übersetzungsmodell am besten ab. Das Modell basierend auf den um Synonyme angereicherten Datensatz erreichte bei GLEU den höchsten Score. Vor allem die Datensätze, bei denen eine Deutsch-zu-Englisch-Übersetzung sowie das Verfahren der Rückübersetzung angewendet wurden, lieferten Modelle mit schwächerer Performance. Die Autoren erklären das mit dem Unterschied zwischen dem Wording der alten ägyptischen Sprache und dem modernen Englisch, das von Übersetzungsalgorithmen verwendet wird und nicht gut zu den vorliegenden Beispielen aus alter Zeit passt.

Programmcode und Datensätze wurden nicht veröffentlicht. Leider wurde zudem kein einziges Beispiel bzgl. Klassifikation und Übersetzung im Paper abgebildet, sodass für den Leser unklar blieb, wie gut das vorgestellte System in der Praxis wirklich arbeitet. Bei der Fülle der bei diesem Projekt verwendeten Ansätze wären eigene Tests und eine genauere Analyse des Codes daher besonders interessant gewesen. Auf Kontaktanfragen antworteten die Autoren leider nicht.


### 3.7 Kartuschenanalyse durch Duque-Domingo et al. (2017) mit Folgeprojekt

Die Forschungsgruppe rund um J. Duque-Domingo veröffentlichte gleich zwei Paper zum Thema Hieroglyphenerkennung. Duque-Domingo et al. (2017) konzentrierten sich zunächst auf die Erkennung von Kartuschen, einem charakteristischen ovalen Rahmen, der nur Königsnamen beinhaltet, vgl. Abb. 3.7 erste Zeile. Als Use Case für die Kartuschenerkennung stellten sich die Autoren einen Einsatz in Museen in Form einer App vor, um dem Besucher Information zum jeweiligen Pharao zur Verfügung zu stellen. Die Autoren stellten einen Datensatz von 261 Kartuschenbildern zusammen, der sich aus Beispielen aus der Königsliste von Abydos<sup>33</sup>, aus dem Datensatz von Franken und van Gemert (2013) sowie Fotografien weiterer Inschriften zusammensetzt. Alle Beispiele umfassten insgesamt 1785 Hieroglyphen. Bei der Bildverarbeitung muss zunächst die Kartusche lokalisiert werden. Dazu wurde das Bild in Greyscale gesetzt, mit einem Medianfilter wurde Rauschen reduziert, mit Canny Edge Detection wurden die Kanten lokalisiert und mit ISODATA (Iterative Self-Organizing Data Analysis Technique) wurden die wichtigsten Kanten extrahiert. Das Ergebnis ist in Zeile 2 von Abb. 3.7 zu sehen. Ggf. wurde die Kartusche noch anhand ihrer längeren Kante in eine vertikale Position gedreht. Anschließend wurden die vier Ecken der Kartusche lokalisiert (Abb. 3.7, 3. Zeile)

---

<sup>33</sup>[de.wikipedia.org](https://de.wikipedia.org), besucht am 18.02.2025

und die Hieroglyphen in diesem Rechteck als RoIs (Regions of Interest) durch komplexe Berechnungen mithilfe der Chamfer- sowie Hausdorff-Distanz (Abb. 3.7, 4. und 5. Zeile) extrahiert und durch Vergleich mit gelabelten Beispielen klassifiziert. Jeder Hieroglyphe war dabei ein Lautwert in Transkription zugeordnet. Für die Erkennung des Könignamens wurde eine vertikale Anordnung angenommen und die Lesung von links nach rechts oder umgekehrt in Betracht gezogen. Mithilfe der Levenshtein-Distanz, die angibt, welche Minimalanzahl an Wortmodifikationen einen Satz in einen zweiten überführt, wurde die erhaltene Transkription mit den Datenbankeinträgen verglichen und der passendste Königsname ausgegeben (Abb. 3.7, letzte Zeile).

|                            | Sekhemkhet                                                                          | Djedefre                                                                            | Thutmose III                                                                        | Thutmose IV                                                                         | Amenhotep III                                                                         | Ramesses I                                                                            |
|----------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| Original picture           |    |    |    |    |    |    |
| Edge detection             |   |   |   |   |   |   |
| Cartouche localization     |  |  |  |  |  |  |
| Hieroglyphs extraction     |  |  |  |  |  |  |
| Hieroglyphs identification |  |  |  |  |  |  |
| Corresponding cartouche    |  |  |  |  |  |  |

**Abbildung 3.7:** Originalbilder ausgewählter Kartuschen sowie deren Zwischenstufen bei der Bildverarbeitung bis hin zur Erkennung der Kartusche, aus Duque-Domingo et al. (2017).


Bei dem Lokalisierungsschritt wurde eine durchschnittliche Trefferquote von 95,4% erreicht. Der Extraktions- und Identifikationsprozess lieferte eine Trefferquote von 87,1%



---

und die Genauigkeit der Erkennung lag bei durchschnittlich 92,3%. Code und Datensatz wurden zwar angefragt, aber nicht bereitgestellt, da beides laut den Autoren zu jenem Zeitpunkt in Überarbeitung für ein später folgendes Paper war.

In Fuentes-Ferrer et al. (2025) veröffentlichten die Autoren kürzlich den bisher größten manuell zusammengestellten Satz an Hieroglyphen-Patches von 13.729 Beispielen aus 310 Klassen. Neben etwa 9700 eigenen Bildern, extrahiert als rechteckige Boxen aus diversen Fotografien von Inschriften aus unterschiedlichen Epochen, enthält dieser auch die ca. 4000 Patches aus dem Datensatz von Franken und van Gemert (2013). Das Ziel der Arbeit war neben dem Einlesen von Hieroglyphen eine möglichst exakte Transliteration von hieroglyphischen Inschriften.



**Abbildung 3.8:** Segmentierungsprozess mithilfe des SAM an einem Beispiel, aus Fuentes-Ferrer et al. (2025).

Für die Segmentierung der Hieroglyphen wurden zwei Ansätze ausprobiert, die ohne Training auskommen (Zero-Shot-Segmentierung). Im ersten Ansatz wurden klassische Computer-Vision-Techniken verwendet. Mit Canny Edge Detection wurden aufgrund des Unterschieds zwischen der Farbe der Hieroglyphen und des Hintergrunds Kanten gefunden, die die RoIs der einzelnen Zeichen separieren. Auf dieser Grundlage wurden dann Bounding Boxes der Hieroglyphen in den jeweiligen RoIs bestimmt. Bei einem zweiten Ansatz wurde ein fokussiertes, generisches SAM-typisches Segmentierungsmodell verwendet. Das Segment Anything Model (SAM) ist ein generisches Segmentie-



---

rungsnetzwerk, das in einem Zero-Shot-Lernproblem arbeiten kann und basierend auf verschiedenen Arten von Eingabeaufforderungen bekannte und unbekannte Objekte sowie auch nur Bildausschnitte segmentieren kann. Als spezifische Anforderungen fokussieren die Autoren das SAM auf eine Reihe von Visionstechniken, damit es auf diese reagiert und Hieroglyphen segmentiert, anstatt eine globale Segmentierung aller Objekte durchzuführen. Das Bild wurde zunächst durch Otsu Thresholding - einer Technik, die eine optimale Schwellenwertbestimmung (Threshold) für die Trennung von Bildpixeln in Hintergrund und Vordergrund basierend auf ihrer Intensität vornimmt - binarisiert und sehr kleine Objekte wurden als Rauschen entfernt. Aus jeder zusammenhängenden Pixelmenge wurden etwa 10 zufällige Punkte ausgewählt und ein solches vormarkiertes Bild dem SAM übergeben. Zusätzlich wurde der Non-Maximum-Suppression-Algorithmus (NMS) verwendet, um zusammenhängende Komponenten zu identifizieren, die nach der Binarisierung getrennt vorliegen und sonst eine mehrfache Detektion verursachen würden. Der Prozess ist in Abb. 3.8 anhand eines Beispiels skizziert. Die Leserichtung in allen Beispielen wurde von rechts nach links angenommen und die Vertikal- bzw. Horizontalausrichtung wurde aus dem Seitenverhältnis des Bildes geschlossen.

Die separierten Bilder werden durch das Cross-Validation Voting (CVV) klassifiziert. Bei dieser Technik wird ein Modell-Ensemble verwendet, das aus ähnlichen Klassifikatoren mit ConvNeXt-Architektur<sup>34</sup> besteht, die mit verschiedenen Validierungsdatensätzen trainiert wurden. Dazu wird der Gesamtdatensatz im Vorfeld in  $k$  disjunkte Validierungsdatensätze zerlegt und der  $i$ -te Klassifikator wird auf dem  $i$ -ten Teildatensatz validiert und auf den übrigen Daten trainiert. Die Trainingsdaten wurden durch Data Augmentation auf ca. 19.000 Beispiele angereichert.<sup>35</sup> Außerdem wurden unterrepräsentierte Klassen stärker angereichert und überrepräsentierte Klassen in ihrem Umfang reduziert. Jeder Klassifikator gibt einen Wahrscheinlichkeitsvektor bzgl. der möglichen Klassen zurück. Das Klassifikator-Ensemble votet dann für die Klasse des Patches. Beim Soft Voting werden die ausgegebenen Wahrscheinlichkeitsvektoren addiert und die Klasse mit dem höchsten akkumulierten Wahrscheinlichkeitswert ausgegeben. Beim Hard Voting wird in jedem Wahrscheinlichkeitsvektor zunächst die wahrscheinlichste Klasse auf 1 gesetzt und die übrigen auf 0, anschließend werden die so ermittelten „Punkte“ addiert. Nach der Evaluation durch die Autoren lieferte Soft Voting ein etwas besseres Ergebnis. In jeder der Gardiner-Klassen wurden Klassifikationsraten nahe 100% erreicht. Schließlich können die Hieroglyphen auf Basis des Gardiner-Codes mit JSesh rekonstruiert werden, um ein digitales Abbild der ursprünglichen Inschrift zu erhalten. Die Segmentierer wurden in Kombination mit dem Klassifikator im Hinblick auf die Gesamtperformance getestet. Dazu wurden die Texte von fünf Stelen unter Verwendung des Gesamtprozesses komplett ausgewertet. Die Stele des Maati<sup>36</sup> wurde für die im Paper abgebildeten Beispiele verwendet. Die Segmentierung mit SAM lieferte dabei insgesamt bessere Ergebnisse als die Computer-Vision-Techniken mit Genauigkei-

---

<sup>34</sup><https://github.com/facebookresearch/ConvNeXt>, besucht am 18.02.2025

<sup>35</sup>Translation um max. 10 Pixel, Rotation um max. 5°, Random Zoom mit einem Faktor zwischen 0,9 und 1,1, horizontales Flipping

<sup>36</sup>[metmuseum.org](http://metmuseum.org), besucht am 22.03.2025

ten von über 90%. Besonders bemerkenswert an den vorgestellten Beispielen ist, dass Hieroglyphen wie  (O3) oder  (D60), die in der Stele aus mehreren Einzelkomponenten bestehen, korrekt als Einheit segmentiert wurden. Das Paper wurde kurz vor dem Ende des Bearbeitungszeitraums der vorliegenden Arbeit veröffentlicht, sodass nur der Datensatz von Fuentes-Ferrer et al. (2025) für eigenen Experimente verwendet werden konnte, aber keine Zeit mehr blieb, den Programmiercode anzufordern und diesen zu analysieren.

### 3.8 Weitere Beiträge

Aneesh et al. (2024) bearbeiteten isoliert das Problem der Klassifikation. Hierfür verwendeten sie keine Datensätze vorheriger Arbeiten, sondern erzeugten einen eigenen Datensatz 4578 handgeschriebener Hieroglyphen aus 763 verschiedenen Klassen und erweiterten diesen durch Data Augmentation auf 59.514 Beispiele (Rotation, Hinzufügen von Rauschen, Änderung der Auflösung). Die Verwendung handgeschriebener Zeichen sollte für ausreichend Variation im Datensatz sorgen, wie in Abb. 3.9 beispielhaft gezeigt.

|     |                                                                                     |                                                                                     |                                                                                     |                                                                                     |                                                                                      |                                                                                       |
|-----|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| I9  |  |  |  |  |  |  |
| I10 |  |  |  |  |  |  |
| I11 |  |  |  |  |  |  |
| I12 |  |  |  |  |  |  |
| I13 |  |  |  |  |  |  |
| I14 |  |  |  |  |  |  |
| I15 |  |  |  |  |  |  |
| K1  |  |  |  |  |  |  |
| K2  |  |  |  |  |  |  |

**Abbildung 3.9:** Tabelle handgeschriebener Beispiele aus Aneesh et al. (2024).

An dieser sei kritisch angemerkt, dass die Hieroglyphen aus dem Altertum meist von ausgebildeten Schreibern gezeichnet wurden, die mit der exakten Zeichenform vertraut waren und in gewissem Sinne auch Künstler waren. Daher macht es ggf. wenig Sinn, ein Modell auf Handschriften zu trainieren, die nicht „schön“ sind. Außerdem macht das Training auf zu stark verdrehten Hieroglyphen bei einem Gesamtansatz keinen Sinn, da dann die Leserichtung nicht mehr vernünftig bestimmt und die Inschrift nicht mehr korrekt sequenziert werden kann. Stattdessen sollte das Bild in einer Vorprozessierung

---

besser in eine definierte Ausrichtung gebracht werden. Das CNN Vanilla ConvNet<sup>37</sup> sowie vier weitere vortrainierte Modelle wurden für das Training getestet: ResNet50, Inceptionv3, VGG16 und DenseNet12. ResNet50 erreichte dabei mit Abstand die höchste Genauigkeit von 98%.

### 3.9 Entwicklung von mobilen Apps als Übersetzungshilfe

Diverse Gruppen verfolgten das Ziel, leichtgewichtige Modelle für Anwendungsmöglichkeiten auf mobilen Endgeräten zu programmieren. Die im Folgenden vorgestellten Apps wurden in keinem App Store oder Git Repository gefunden und konnten somit nicht getestet werden.



**Abbildung 3.10:** Von links nach rechts: Hauptmenü, Scan-Funktion und Übersetzung-Fenster der App Scriba, aus Moustafa et al. (2022).

Moustafa et al. (2022) entwickelten zum Zweck der Hieroglyphenerkennung und -übersetzung die App *Scriba*, eine auf Flutter basierende mobile Deep-Learning-Anwendung. Flutter ist ein Open-Source-Framework von Google, das zur Entwicklung von nativ kompilierbaren Anwendungen für mobile Geräte, Webanwendungen und Desktop verwendet wird.<sup>38</sup> Mit Scriba setzten sich die Autoren das Ziel, dem breiten Publikum ein leicht zugängliches Tool für die Lesung von Inschriften der ägyptischen Monumente zur Verfügung zu stellen, ohne einen Reiseleiter zu benötigen. Die besondere Herausforderung war hier ein, ein leichtgewichtiges, aber leistungsstarkes CNN zu finden,

<sup>37</sup><https://arxiv.org/pdf/2305.12972>, besucht am 18.02.2025

<sup>38</sup><https://flutter.dev/>, besucht am 17.02.2025

---

das auf einem Smartphone lauffähig ist und die multiplen Herausforderungen im Kontext der Hieroglyphenerkennung bewältigt. Zudem musste abgewogen werden zwischen einer schnellen und leichtgewichtigen, aber dafür datenintensiven Onlineprozessierung und einem appzentrierten Offline-Ansatz. Scriba scannt, erkennt und übersetzt Hieroglyphen. Nach dem Scannen der Hieroglypheninschrift wählt der Benutzer die Sprache aus, in die die Inschrift übersetzt werden soll. Anschließend werden die erkannten Hieroglyphen einer Bildvorverarbeitung unterzogen, um Rauschen zu reduzieren. Zur Extraktion der Glyphen wurden unterschiedliche Ansätze getestet: Adaptive Histogram Equalization (AHE), die den Kontrast eines Bildes erhöht; Otsu Thresholding (s. oben); Gaussian Blur und Image Dilation, um das Bild zu glätten und damit Rauschen zu reduzieren; Canny Edge Detection (s. oben); Edge-based Contour Detection zur Erkennung von Kanten im Bild, die Übergänge zwischen verschiedenen Bereichen mit unterschiedlicher Helligkeit oder Farbe darstellen zusammen mit Hierarchical Segmentation, die das Bild in eine Reihe von verschiedenen Segmentierungsebenen unterteilt, die von groben zu feinen Details reichen, um Objekte im Bild auf verschiedenen Abstraktionsebenen zu erkennen und zu analysieren. Wie gut die einzelnen Methoden im Vergleich performten, bleibt offen. Schlussendlich wurde eine Kombination aus Canny Edge Detection, Edge-based Contour Detection und Hierarchical Segmentation für die App verwendet.

Nach der Extraktion der Hieroglyphen wird das Bild durch ein leichtgewichtiges CNN-Klassifikationsmodell verarbeitet. Getestet wurden hier MobileNet, das speziell für mobile und eingebettete Bildverarbeitungsanwendungen entwickelt wurde<sup>39</sup>, ShuffleNet<sup>40</sup>, das aufgrund geringer erforderlicher Rechenleistung häufig in kostengünstigen Geräten wie Mobiltelefonen eingesetzt wird, sowie EfficientNet, das eine effiziente Skalierung durch schrittweise Erhöhung der Modelltiefe, -breite und -auflösung basierend auf dem zusammengesetzten Skalierungskoeffizienten erreicht<sup>41</sup>. Es wurden drei verschiedene Datensätze für das Training und die Evaluation des Klassifikators verwendet: Zum Einen ein reduzierter Datensatz der Sammlung von Franken und van Gemert (2013), zum Anderen ein von den Autoren eigens zusammengestellter Scriba-Datensatz aus 5000 Hieroglyphenpatches aus unterschiedlichen Quellen sowie eine Sammlung von 1000 farbigen Bildern von 10 verschiedenen Kartuschen mit Königsnamen. Der bzgl. der 161 verfügbaren Klassen stark unbalancierte Gemert-Datensatz wurde durch Data Augmentation homogenisiert. Die Anzahl der Bilder wuchs dabei von etwa 3500 auf etwa 11000. Anschließend wurden MobileNet und ShuffleNet auf dem originalen sowie dem angereicherten Datensatz bei gleichbleibenden Modellparametern<sup>42</sup> trainiert und getestet. Wie erwartet verlängerte sich die Trainingszeit auf dem Datensatz mit Data Augmentation um den Faktor 4-5, wobei gleichzeitig die Klassifikationsrate von 65% auf 86% bei ShuffleNet und von 73% auf 95% bei MobileNet anstieg. Der Scriba-Datensatz beinhaltete 87 verschiedene Klassen. Nach Data Augmentation wurden alle drei o.g. Modelle

---

<sup>39</sup><https://keras.io/api/applications/mobilenet/>, besucht am 17.02.2025

<sup>40</sup><https://arxiv.org/abs/1707.01083>, besucht am 17.02.2025

<sup>41</sup><https://keras.io/api/applications/efficientnet/>, besucht am 17.02.2025

<sup>42</sup>Lernrate 0,01, Batch Size 128, 30 Epochen

---

angewendet<sup>43</sup>, die Genauigkeiten von 97% (ShuffleNet), 99% (MobileNet) bzw. 100% (EfficientNet) erreichten. Der Kartuschen-Datensatz wurde vor dem Training ebenfalls durch Data Augmentation erweitert und es wurde mit ähnlichen Modellparametern trainiert. Für MobileNet und EfficientNet geben die Autoren eine Genauigkeit von 100% an, für ShuffleNet 90%.

Laut den Autoren wird dem Benutzer schließlich in der App nach der Erkennung der einzelnen Hieroglyphen die Übersetzung ins Englische oder Arabische angezeigt, die über eine Sprachausgabe auch angehört werden kann. Wenn die gescannten Hieroglyphen den Namen eines Königs enthalten, kann der User über eine Funktion mehr über diesen erfahren. Eine Anfrage bzgl. der Datensätze wurde von den Autoren abgelehnt mit der Begründung, dass dieser noch nicht bereit für eine Veröffentlichung sei. Leider ist bzgl. der Übersetzung kein Beispiel im Paper gegeben, sodass man nur vermuten kann, dass diese wieder nur zeichenweise erfolgt. Hinsichtlich der beiden von den Autoren erstellen Datensätzen ist gerade der Kartuschen-Datensatz kritisch zu hinterfragen, da er nur 10 verschiedene Königsnamen repräsentiert, obwohl es über 170 Pharaonen in der Geschichte des Alten Ägyptens gab.

Plecher et al. (2020) entwickelten die App *ARsinoë*, wobei die Anfangsbuchstaben AR auf Augmented Reality hinweisen. Die Autoren designten die App im Hinblick auf „Gamification“ (d.h. der Verwendung von spielerischen Elementen in einem nicht-spielerischen Kontext), was den User durch spielerischen Umgang mit dem Thema zusätzlich motivieren sollte. Als Datengrundlage für das Training diente einerseits der Datensatz von Franken und van Gemert (2013). Aus diesem wurden annotierte Bilder der Pyramidentexte erstellt, wobei die Bounding Boxen und Gardiner-Code-Labels der Hieroglyphen in einem XML File gespeichert wurden. Die Autoren beschränkten ihre Arbeit auf 35 verschiedene Hieroglyphen, die die Einkonsonantenzeichen sowie einige weitere häufig auftretende Glyphen beinhalteten. Nach Filterung des Franken-Datensatzes auf diese 35 Klassen blieben etwa 3000 gelabelte Patches übrig. Daher erstellten die Autoren noch eigens annotierte Bilder unter Verwendung von Fotografien aus dem Lepsius-Projekt<sup>44</sup>. Dadurch wurden weitere 6800 Beispiele generiert. Für die Klassifikation musste im Hinblick auf das Augmented-Reality-Feature ein neuronales Netz verwendet werden, dass in Echtzeit arbeitet. Außerdem musste es für die Anwendbarkeit auf Smartphones leichtgewichtig sein. Die Wahl fiel auf die API für Objekterkennung mit Single Shot Multibox Detector (SSD) von TensorFlow<sup>45</sup>, die speziell für die effiziente Objekterkennung auf verschiedenen Plattformen, von Desktops bis zu mobilen Geräten, optimiert ist und Echtzeit-Objekterkennung ermöglicht. Als Single Shot-Ansatz erkennt SSD im Gegensatz zu älteren Methoden alle Objekte in einem Bild in einem einzigen Durchgang. Es verwendet mehrere Ankerboxen (vorgegebene, standardisierte Boxen), um Objekte in verschiedenen Größen und Aspekten zu lokalisieren. Das Modell passt


---

<sup>43</sup>Lernrate 0,01 für ShuffleNet/MobileNet und Lernrate 0,0001 für EfficientNet, Batch Size 32, 20 Epochen

<sup>44</sup><https://edoc3.bibliothek.uni-halle.de/lepsiuss/start.html>, besucht am 17.02.2025

<sup>45</sup><https://github.com/balancap/SSD-Tensorflow>, besucht am 17.02.2025

die Position und Größe dieser Boxen während des Trainings an, um die tatsächlichen Objekte besser zu umschließen. Genauer wurde eine auf dem COCO-Datensatz vortrainierte MobileNetV2-Architektur für das Transfer Learning verwendet. Um das Gewicht des Faktors Belichtung aus den relativ einheitlich ausgeleuchteten Bildern der Pyramidentexte zu reduzieren, wurde Data Augmentation bzgl. Kontrast, Sättigung und Helligkeit eingesetzt. Bei Beispiel für die Anwendung des AR-Features per Smartphonekamera ist in Abb. 3.11 links oben gegeben, wo pro Hieroglyphe der Gardiner-Code inkl. seiner Wahrscheinlichkeit angegeben ist.



**Abbildung 3.11:** Oben von links nach rechts: Erkennung von Hieroglyphen in Echtzeit durch die App über die Kamera des Smartphones, Vereinigung zu Sätzen, Zerlegung in Wörter. Unten von links nach rechts: Die beiden unterschiedlichen Erkennungsmodi in der App mit den Details, die im unteren Teil des Bildschirms angezeigt werden, wenn das erkannte Wort/der erkannte Satz angetippt wird. Aus Plecher et al. (2020).


Die Leserichtung wurde stets von rechts nach links in Zeilen angenommen. Hieroglyphen, die horizontal auf einer Ebene liegen, werden zu Sätzen zusammengefasst. Diese werden dann durch Erkennung ausreichend großer Lücken in Wörter zerlegt (Abb. 3.11 oben, mittleres Bild). Sätze und Wörter werden auf der Grundlage der erkannten Gardiner-Sequenz in einem eigens erstellten Wörterbuch nachgeschlagen. Aufgrund



---

nicht erkannter oder im Vergleich zu den Wörterbucheinträgen fehlender Hieroglyphen gibt es häufig kein 1:1-Matching. Stattdessen wird die wahrscheinlichste Übereinstimmung bzgl. der Levenshtein-Distanz gewählt. Diese wird jedoch nicht direkt auf die Gardiner-Sequenz angewendet, sondern erst nach Substitution der einzelnen Gardiner-Codes durch eindeutige Symbole. Andernfalls würden Zeichen wie G17 und M17 als relativ ähnlich gewertet werden, obwohl diese nichts miteinander zu tun haben. Ein erkanntes Wort oder ein erkannter Satz in der App können vom Benutzer angeklickt werden und die englische Übersetzung sowie Details zur Wortzusammensetzung werden bereitgestellt (Abb. 3.11 unten). Die App beinhaltet ein Lernkonzept, das dem Benutzer das „Alphabet“ (Einkonsonantenzeichen) sowie einige Worte beibringt. Der Lernerfolg wird per Multiple-Choice-Test überprüft.

Eine weitere mobile App *Aegyptos* wurde von Mohsen et al. (2023) entworfen. Das Ziel dieser Anwendung war die Erkennung von Hieroglyphen und - im Hinblick auf die Vieldeutigkeit von Hieroglyphen je nach Kontext - darauf aufbauend deren akkurate Übersetzung in unterschiedliche Sprachen unter Ausnutzung der Google Translate API<sup>46</sup>. Zudem bietet die App eine Behelfsaussprache der Hieroglyphen mithilfe der Text-zu-Sprache-Funktion von Flutter an.



**Abbildung 3.12:** Von links nach rechts: Startbildschirm, zwei Beispiele für die direkte Übersetzung von Hieroglyphen, aus Mohsen et al. (2023).

---

<sup>46</sup><https://cloud.google.com/translate/docs/reference/rest>, besucht am 17.02.2025

---

Nach der Bildaufnahme per Smartphone-Kamera wird das erfasste Bild zur Verbesserung der Genauigkeit des Übersetzungsprozesses verschiedenen Vorverarbeitungstechniken unterzogen, die das Rauschen im Bild reduzieren und die Gesamtqualität verbessern. Anschließend wird das Bild per Otsu Thresholding segmentiert, d.h. die hieroglyphischen Symbole werden vom Hintergrund getrennt sowie voneinander isoliert. Die resultierenden Patches werden dann dem Klassifikator übergeben, der 1072 Klassen unterscheiden kann. Der gesamte Aegyptos-Datensatz für das Training des Klassifikators umfasste nach Data Augmentation etwa 60.000 Einzelbilder (vermutlich aus Font-Abbildungen generiert, der Unicode-Satz für Standardhieroglyphen umfasst genau 1072 Zeichen). Als dem Klassifikationsmodell zugrundeliegendes CNN wurde SqueezeNet gewählt, ein effizientes, leichtgewichtiges CNN, das mit geringem Speicherverbrauch und geringer Rechenleistung eine hohe Genauigkeit bei der Bildklassifikation erreichen kann<sup>47</sup>. Hierbei wurde im Sinne des Transfer Learnings ein auf dem ImageNet-Datensatz vortrainiertes Modell gewählt und lediglich auf die Hieroglyphenerkennung im Klassifikations-Layer feingetuned. Der Klassifikator gibt den wahrscheinlichsten Gardiner-Code pro Patch zurück. Laut den Autoren wird bei den Tests mit diesem Modell eine Genauigkeit von 96% erreicht. Schließlich soll die resultierende Übersetzung in Englisch und Arabisch sowie die Aussprache dem Benutzer auf dem Bildschirm seines mobilen Geräts angezeigt werden. Wie die Übersetzung genau funktioniert, wird im Paper nicht beschrieben. Auch das Thema der Kontextbetrachtung bei der Übersetzung wurde offensichtlich nicht mehr ausgearbeitet. Im Paper wird lediglich die Idee beschrieben, die nächstgelegene semantische Übersetzung durch einen Levenshtein-Abgleichalgorithmus zu ermitteln. Weitere Details bleiben die Autoren den Lesern schuldig. Zudem wurde weder der verwendete Datensatz noch der Code frei verfügbar gemacht. Das einzige Beispiel aus dem Datensatz im Paper lässt vermuten, dass dieser auf Basis von Fonts erzeugt wurde.

Des Weiteren gibt es noch Apps, die von Privatpersonen programmiert wurden und nicht im Detail dokumentiert sind, wie z.B. die App *Pharaoh Finder - Cartouche ID*, die einen Könignamen in einer Kartusche auslesen kann<sup>48</sup> oder die Anwendung *Hieroglyphs AI*, mit der man einzelne Hieroglyphen per Kamera anvisieren und klassifizieren lassen kann<sup>49</sup>.

### 3.10 Übersetzung mithilfe eines Sprachmodells nach Wiesenbach und Riezler (2019)

Gänzlich auf die maschinelle Übersetzung der ägyptischen Schriftsprache als Sprache mit begrenzten Ressourcen fokussierte sich Wiesenbach und Riezler (2019). Dazu extrahierten die Autoren etwa 100.000 Tupel aus hieroglyphischer Schreibung (Gardiner-Code, teilweise inkl. Anordnungssyntax), Transkription, POS-Tags (beim Part-of-Speech-

---

<sup>47</sup><https://arxiv.org/abs/1602.07360>, besucht am 17.02.2025

<sup>48</sup>[play.google.com](https://play.google.com), besucht am 17.02.2025

<sup>49</sup>[play.google.com](https://play.google.com), besucht am 17.02.2025



---

Tagging wird jedem Wort die passende Wortart zugeordnet) und deutscher (in wenigen Fällen englischer) Übersetzung für Sätze aus dem TLA im Rahmen des Projekts *Strukturen und Transformationen des Wortschatzes der ägyptischen Sprache*<sup>50</sup> aus dem Jahr 2018. Nach Bereinigung und Einschränkung auf die Beispiele mit vorhandener Gardiner-Sequenz blieben 29.296 Beispielsätze für die weitere Arbeit übrig, die das Ziel hatte, eine Gardiner-Sequenz direkt in eine Übersetzung zu transformieren, vgl. folgendes Beispiel (ohne POS-Tags):

**Gardinersequenz:** M17-D21 E34-N35-X1-H8-B1-N35-X1-M27-X1-Z5-Z1 R8-X1-H8-B1 Q3-Z7 V30-X1-D34-G1-Z7-Z9-T33A-G37 N35-D46-M17-M17-X1-01 N35-X1-Z4 01-Z1 N35-Aa1-N35-W24-X1 -N1-X1-H8-B1 N29-M17-M17-X1-N23-Z1-Z2-049-N29-G1-A28-Y1 N35 Z2-Z1-Z2-Z1-S29-S29-W24-Z7-G7-Z2-049 N35-X1-Q7-Z2-N5 M17-Z7 D46-D21-M17-Z7-Z9 M17-S29-I9-Z4-M17-M17-G37-Z2-T33A G17 E34-R12-N24-Z1-049-049

**Transkription:** *jr Wnw, t-n, tj-T<sup>3</sup>-šm<sup>c</sup> ntr, t pw nb, t-<sup>c</sup>h<sup>3</sup>w ndy, t n, t pr N 'n, t ⟨hr⟩ Q<sup>3</sup>, yt-q<sup>3</sup> n Hmn, w [n, tj] [hr] [Jw]-[nsrsr] jw drjw jsfy m Wnw*

**Übersetzung:** Was Unut von Oberägypten anbetrifft, sie ist die Göttin (mit dem Namen) 'Herrin des Kampfes' (in) der Kammer(?) des Tempels der Naunet auf dem 'erhabenen Hügel' von Hermopolis, der [auf der] Flammen[insel] ist, um das Unrecht aus dem Gau von Hermopolis zu vertreiben.

Klammern in der Transkription deuten generell auf verlorene oder beschädigte Passagen, Auslassungen oder überschüssige Zeichen hin. Das Problem der beschränkten Datenmenge wurde durch den Austausch von Informationen zwischen verwandten Aufgaben mithilfe von Multi-Task-Learning(MTL)-Techniken gelöst. Dabei können Aufgaben wie die Hieroglyphentranskription und die Hauptaufgabe der direkten Übersetzung von Hieroglyphen voneinander profitieren, indem sie gemeinsam lernen. Beide Aufgaben erfordern eine Segmentierung und Disambiguierung<sup>51</sup> der Hieroglyphen. Weitere mögliche unterstützende Aufgaben sind die Übertragung von Hieroglyphen in die POS-Tag-Sequenz sowie die Übersetzung ausgehend von der Transkription. Der Wechsel zwischen Haupt- und Nebenaufgaben wird durch ein Scheduling festgelegt. Zur Evaluation des Erfolgs des MTL-Ansatzes wurden zunächst BLEU-Scores für unterschiedliche Baseline-Settings berechnet. Die direkte Hieroglyphenübersetzung ohne MTL erreichte einen BLEU von 19,77. Das System, das die Transkription in eine Übersetzung überführt, erreichte einen BLEU von 27,67. Die Autoren sahen diesen Wert als obere Schranke für das Problem an, da die Transkription bereits erheblich näher an einer Übersetzung ist im Vergleich zur Gardiner-Sequenz, da diese bereits Worttrennung, Rechtschreib- und Defektkorrekturen sowie syntaktische Information beinhaltet. Außerdem wurden weitere Beispiele durch Rückübersetzung generiert. Dies erhöhte den BLEU-Score der Hauptaufgabe jedoch nur geringfügig. Anschließend wurden unterschiedliche MTL-Experimente

---

<sup>50</sup><https://edoc.bbaw.de/frontdoor/index/docId/2919>, besucht am 18.02.2025

<sup>51</sup>Auflösung sprachlicher Mehrdeutigkeiten

durchgeführt. Beim Many-2-One-Ansatz wurde die Hauptaufgabe *Hieroglyphen - Übersetzung* mit der gleichgerichteten Aufgabe *Transkription - Übersetzung* gekoppelt. Die beste Parameterwahl lieferte einen Gewinn von zwei BLEU. Beim One-2-Many-System wurde die eigentliche Aufgabe mit der Zusatzaufgabe *Hieroglyphen - Transkription* gekoppelt, d.h. die Hieroglyphen wurden parallel in zwei „Sprachen“ übersetzt. Auch hier wurden maximal zwei BLEU gewonnen. Wird zusätzlich die Aufgabe *Hieroglyphen - POS-Tags* hinzugenommen, konnten insgesamt bis zu drei BLEU dazugewonnen werden. Transkription und POS-Tags enthalten also ähnlich viel syntaktische Information, sodass kein übermäßiger Fortschritt erzielt wird. Ein Many-2-Many-Ansatz lieferte keine noch besseren Ergebnisse. Insgesamt zeigten die Experimente, dass ein Zusatz von 30% an Nebenaufgaben im Rahmen des MTL das Gesamtergebnis um bis zu drei BLEU verbessern konnte. Der Code für den Übersetzer wurde nicht zur Verfügung gestellt.

### 3.11 Übersetzungsarbeit von De Cao et al. (2024)

Eine aktuellere Arbeit zum Thema Übersetzung der ägyptischen Sprache auf Basis des Gardiner-Codes oder der Transkription ist von De Cao et al. (2024), die in einem Git-Repository frei zugänglich ist<sup>52</sup>.

| Source                                                                               |                                            |                                           |                                        |
|--------------------------------------------------------------------------------------|--------------------------------------------|-------------------------------------------|----------------------------------------|
|  |                                            |                                           |                                        |
| D21 Aa1 Y1 V31 G43 A1 V13 G43 D21 Aa1 Y1 V31 G43 A1 D21 N35 V31                      |                                            |                                           |                                        |
| Target                                                                               | Prediction<br>(from hieroglyphic)          | Prediction<br>(from transliteration)      | Reference                              |
| DE                                                                                   | Ich kenne dich, ich kenne deinen Namen     | Ich kenne dich und ich kenne deinen Namen | Ich kenne dich, ich kenne deinen Namen |
| EN                                                                                   | You know me, I know your name              | I know you, I know your name              | I know you, I know your name           |
| τ                                                                                    | r.kwj tw r.kwj rn =k                       | –                                         | rh.kw tw rh.kw rn =k                   |
| lkey                                                                                 | 95620 44000 174900 95620 44000 94700 10110 | 95620 174900 95620 94700 10110            | 95620 174900 95620 94700 10110         |
| pos                                                                                  | verb_2-lit personal_pronoun                | verb_2-lit personal_pronoun               | verb_2-lit personal_pronoun            |
|                                                                                      | noun personal_pronoun                      | verb_2-lit substantive_masc               | verb_2-lit substantive_masc            |
|                                                                                      | verb_2-lit personal_pronoun                | personal_pronoun                          | personal_pronoun                       |
|                                                                                      | personal_pronoun substanti                 |                                           |                                        |

**Abbildung 3.13:** Beispiel einer manuellen Überprüfung auf unterschiedlichen Ebenen, aus De Cao et al. (2024).

Die Autoren fokussierten sich auf die Übersetzung des Alt- und Mittelägyptischen als klassische Sprachen der monumentalen Inschriften. Als Quelle für ihren Datensatz diente der TLA, der aus den beiden Hauptkomponenten *Textkorpus*, dessen Einträge aus

<sup>52</sup><https://github.com/mattia-decao/hiero-transformer>, besucht am 19.02.2025

Hieroglyphentext, Transkription, Übersetzung, Metadaten usw. bestehen, und *Lemma-liste*, die einer Vokabelliste entspricht und deren Einträge ähnlich aufgebaut sind, aber zusätzlich POS-Tags enthalten, besteht. Die Autoren extrahierten aus dem Textkorpus des TLA 61.605 passende Einträge. Für die Übersetzung nutzte die Arbeitsgruppe das vortrainierte M2M-100 Multilingual Model<sup>53</sup>, das von Fan et al. (2020) entwickelt wurde und Übersetzungen zwischen 100 modernen Sprachen ermöglicht, ohne dass Englisch als Zwischenmedium erforderlich ist. Für das Modelltraining wurden unterschiedliche Mischungen aus Source-Target-Paaren ähnlich dem MTL-Ansatz von Wiesenbach und Riezler (2019) verwendet. Als Source dienten die Gardiner-Sequenz sowie die Transkription, als Target die deutsche Übersetzung, die englische Übersetzung, die Liste der Lemma-IDs und die Liste der POS-Tags, wobei zusätzlich noch die Transkription als Target für die Gardiner-Sequenz eingesetzt wurde. Damit ergaben sich neun verschiedene Paarungen. Insgesamt wurden 11 verschiedene Modelle trainiert. Da die englischen Übersetzungen im TLA eher die Ausnahme sind, wurde das M2M-100 verwendet, um alle deutschen Übersetzungen in englische Texte zu überführen.

```
sentence_input = 'mA.n =s rmt m Hw,t-nTr'

{'de': 'Sie hat die Menschen im Tempel gesehen.',
 'en': 'He has seen people in the temple.',
 'lkey': '66270 10090 94530 400007 99940',
 'wordClass': 'verb_3-lit personal_pronoun substantive_masc preposition substantive'}

sentence_input = 'U2 G1 N35 I9 D21 V13 A1 B1 Z2 G17 R8 O6 X1 O2'

{'de': 'für den sich die Menschen im Tempel untersuchten,',
 'en': 'for whom people were in the temple;',
 'tnt': 'm n =f rmt m hw,t ntr',
 'lkey': '66270 10050 94530 400007 99940',
 'wordClass': 'verb_3-lit preposition personal_pronoun substantive_masc preposition substantive'}
```

**Abbildung 3.14:** Beispielhafte Anwendung des Codes aus dem Git-Repository von De Cao et al. (2024), einerseits bei Eingabe der Transkription (oben), andererseits der Gardiner-Sequenz (unten). Die korrekte Übersetzung lautet: „*Sie hat (die) Menschen im Tempel gesehen.*“

Neben einer automatischen Evaluation der Modellperformance mit den Metriken SacreBLEU<sup>54</sup> und RougeL<sup>55</sup> wurde auch eine manuelle Sichtung bei 16 Beispielen durchgeführt, siehe Abb. 3.13. Bzgl. der Übersetzung der Hieroglyphen nach Deutsch und Englisch erzielten die beiden Metriken die höchsten Werte auf dem gemeinsamen Datensatz aus deutschen und englischen Beispielen mit Rückübersetzung. Überraschenderweise verschlechterte sich die Leistung des Modells, wenn die Transkription, Lemma-IDs oder POS-Tags als Target mitgenommen wurden. Dagegen wurden hohe Scores durch

<sup>53</sup>[https://huggingface.co/docs/transformers/model\\_doc/m2m\\_100](https://huggingface.co/docs/transformers/model_doc/m2m_100), besucht am 19.02.2025

<sup>54</sup><https://github.com/mjpost/sacrebleu>, besucht am 19.02.2025

<sup>55</sup>[https://keras.io/api/keras\\_nlp/metrics/rouge\\_l/](https://keras.io/api/keras_nlp/metrics/rouge_l/), besucht am 19.02.2025

---

Einbeziehung von Lemma-IDs und POS-Tags erzeugt, wenn die Transkription als Source verwendet wurde. Dies macht Sinn, da die Struktur der Lemmata und POS-Tags auf die Transkription abgestimmt ist. Außerdem stellten die Autoren fest, dass die Modellperformance ab einer gewissen Textlänge (ab etwa drei Sätzen) abnahm.

Der Code zum Paper wurde erfolgreich hinsichtlich der Übersetzung ab Gardiner-Sequenz bzw. ab Transkription getestet, siehe Abb. 3.14. Zudem wurde der Code für eigene Experimente verwendet, siehe Kapitel 5.6.

### 3.12 Zusammenfassender Vergleich der Ansätze

Tabelle 3.1 vergleicht die Beiträge der oben beschriebenen Arbeiten im Hinblick auf die Teilschritte des Gesamtprozesses aus Abb. 2.4. In der Spalte „Gruppe“ ist in Klammern der entsprechende Abschnitt mit dem jeweiligen detaillierten Überblick angegeben. Beim Aspekt *Segmentierung* ist erkennbar, dass sich die meisten Arbeiten auf Computer-Vision-Techniken stützten. In einem Beitrag wurde auch ein Clustering-Verfahren verwendet. Bei diesen Methoden ist anschaulich klar, wie die Hieroglyphen vom Hintergrund getrennt werden. Nur zwei der Ansätze arbeiteten mit einer Objekterkennung per R-CNN, was eher einem Blackbox-Verfahren gleicht. Die Teilaufgabe *Sequenzierung* wurde noch von keiner Arbeitsgruppe allumfassend gelöst. Entweder wurde eine konstante Leserichtung und Anordnung angenommen oder nur die automatische Erkennung der Spalten-Zeilen-Anordnung bzw. der Links-Rechts-Richtung wurde implementiert. Hier bietet sich daher ein Beitrag im Rahmen der vorliegenden Arbeit an. Bei der Teilaufgabe der *Klassifikation* ist klar zu erkennen, dass in den Anfängen der Hieroglyphenerkennung konkrete Methoden zur Merkmalsextraktion (z.B. HOG) mit sich anschließenden Matching-Algorithmen für die Messung der Ähnlichkeit der Feature-Vektoren verwendet wurden. Ab etwa dem Jahr 2018 konzentrierten sich die Forscher dann verstärkt auf die weniger nachvollziehbaren, CNN-basierten Verfahren. Der Umfang der Klassifikationsaufgabe, repräsentiert durch die Anzahl der jeweils im Modell unterschiedenen Klassen (geklammerter Wert in der Spalte „Klassifikation“) unterschied sich stark abhängig vom vorliegenden Trainingsdatensatz. Gerade bei CNN-basierten Verfahren sollte die Menge der Trainingsbeispiele möglichst groß und variantenreich sein. In dieser Arbeit wird durch Konsolidierung unterschiedlicher Datenquellen sowie umfangreiche Nutzung von Data Augmentation ein Beitrag zur Verbesserung der Qualität eines Klassifikator-Datensatzes geleistet, siehe Kapitel 4.3. Die Implementierung eines Verfahrens zur *Wortsegmentierung* wurde bisher nur von Sobhy et al. (2023) thematisiert. Diese Teilaufgabe wird in den bzgl. der *Übersetzung* fundierten Arbeiten von Wiesenbach und Riezler (2019) und De Cao et al. (2024) übersprungen. Hier wurden Gardiner-Sequenzen ohne Zwischenschritt direkt mit MTL-basierten Modellen übersetzt. Ansätze, die lediglich eine zeichenweise Übersetzung vornehmen, können aufgrund der Komplexität der Hieroglyphenschrift als nur wenig gewinnbringend eingestuft werden. Die Experimente im Kapitel 5.6 werden zeigen, dass die Teilaufgabe der Übersetzung noch bei Weitem nicht hinreichend gut gelöst wurde. Die künftige Forschung muss hier insbesondere der Problematik einer stark beschränkten Datengrundlage begegnen.

**Tabelle 3.1:** Beiträge zur Hieroglyphenerkennung und -übersetzung ausgewählter Arbeitsgruppen im Vergleich

| Gruppe<br>[Kapitel]                                                      | i) Segmentierung                                                                                                                 | ii) Sequenzierung                                            | iii) Klassifikation<br>(Klassenanzahl)                                                                     | iv) Wortsegmentierung                                                                     | v) Übersetzung                                                          |
|--------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------|------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|-------------------------------------------------------------------------|
| <b>Franken und van Gemert (2013) [3.1]</b>                               | Text-Retrieval durch Saliency Maps                                                                                               | - (konstant)                                                 | Feature-Extraktion durch Bilddeskriptoren + Patch-Matching (161)                                           | -                                                                                         | -                                                                       |
| <b>Nederhof (2016) [3.2]</b>                                             | Erkennung von Zeichen als Blobs schwarzer Pixel                                                                                  | - (konstant)                                                 | Vergleich mit Prototypen durch Image Distortion Model (490)                                                | -                                                                                         | -                                                                       |
| <b>Projekt Fabricius [3.3]</b>                                           | Clustererkennung mit DBSCAN                                                                                                      | ?                                                            | neuronales Netz aus Google Cloud AutoML Vision (ca. 1000)                                                  | -                                                                                         | Abgleiche von Hieroglyphensequenzen per Wörterbuch                      |
| <b>Hossam et al. (2018) [3.4]</b>                                        | Spaltensegmentierung mit Canny Edge Detection + Hough-Transformation, Zeichenerkennung mit Canny Edge Detection + 8-Connectivity | Annahme von Spalten, Links-Rechts-Klassifikation von Glyphen | Feature-Extraktion mit HOG + eukl. Abstand der Feature-Vektoren (197)                                      | -                                                                                         | zeichenweise „Übersetzung“                                              |
| <b>Barucci et al. (2021) [3.5]</b>                                       | auf COCO vortrainiertes Mask R-CNN mit ResNet50-Backbone                                                                         | ?                                                            | ResNet50, Inception-v3, Xception (alle vortrainiert) bzw. ResNet50 von Grund auf trainiert (Glyphnet) (40) | -                                                                                         | -                                                                       |
| <b>Sobhy et al. (2023) [3.6]</b>                                         | auf ImageNet vortrainiertes R-CNN mit ResNet-Backbone                                                                            | ? (konstant?)                                                | ResNet50, hierarchisches ResNet50, Siamese Network + LLM (161)                                             | Wörterbuchbasiert mit Max.-Forward/Reverse-Max. Matching, Subword-Tokenizer SentencePiece | Tensorflow Transformer                                                  |
| <b>Fuentes-Ferrer et al. (2025) [3.7]</b>                                | Canny Edge Detection bzw. fokussiertes, generisches SAM-typisches Segmentierungsmodell                                           | konstant rechts-links, horizontal-vertikal per Bildratio     | Cross-Validation Voting durch Klassifikator-Ensemble mit ConvNeXt-Architektur (310)                        | -                                                                                         | -                                                                       |
| <b>Moustafa et al. (2022) [3.9]</b>                                      | Canny Edge Detection, Edge-based Contour Detection und Hierarchical Segmentation                                                 | ?                                                            | MobileNet, ShuffleNet, EfficientNet (161 bzw. 87)                                                          | -                                                                                         | ? (zeichenweise?)                                                       |
| <b>Plecher et al. (2020) [3.9]</b>                                       | - (nicht explizit)                                                                                                               | - (konstant)                                                 | Single Shot Multibox Detector von TensorFlow (auf COCO vortrainierte MobileNetV2-Architektur) (35)         | (basierend auf Lücken)                                                                    | Vergleich erkannter Wörter/Sätze per Levenshtein-Distanz mit Wörterbuch |
| <b>Mohsen et al. (2023) [3.9]</b>                                        | Otsu Thresholding                                                                                                                | -                                                            | auf ImageNet vortrainiertes SqueezeNet (1072)                                                              | -                                                                                         | -                                                                       |
| <b>Wiesenbach und Riezler (2019) [3.10], De Cao et al. (2024) [3.11]</b> | -                                                                                                                                | -                                                            | -                                                                                                          | -                                                                                         | Multi-Task-Learning (bspw. mit votr. M2M-100 Multilingual Model)        |




# Kapitel 4

## Datensammlung

### 4.1 Datensatz hieroglyphischer Inschriften

Als Grundlage für alle weiteren Datensätze wurden zunächst Abbildungen hieroglyphischer Texte aus unterschiedlichen frei zugänglichen Quellen gesammelt.<sup>1</sup> Diese wurden hinsichtlich ihres Schrifttyps unterschieden nach gemeißelten Hieroglyphen ohne Details (GOD, d.h. die Zeichen sind meist einfarbig ausgefüllt ohne Feinmerkmale, 32 Bspe.), gemeißelten Hieroglyphen mit Details (GMD, 6 Bspe.), Handschriften (HS, 46 Bspe.) und computergenerierten Fonts (CG, 19 Bspe.). Abb. 4.1 zeigt für jeden der vier Typen ein Beispiel.



**Abbildung 4.1:** Beispiele für jeden der vier Schrifttypen. Ausschnitte von links nach rechts, von oben nach unten: Stele des Pay aus dem Museo Egizio (GOD), Relief des Nebhepetre Mentuhotep aus dem Metropolitan Museum (GMD), Handschrift aus Sethes *Urkunden II* (HS) und Hieroglyphen-Font aus Allen (2014a) (CG).

Als Quellen dienten die Homepages des Museo Egizio in Turin (ME)<sup>2</sup>, des Metropo-


<sup>1</sup>Datensatz\_Inschriften, ca. 200 MB

<sup>2</sup><https://www.museoegizio.it/en/>, besucht am 12.11.2024

litan Museum in New York (MET)<sup>3</sup>, des British Museum in London (BM)<sup>4</sup> sowie Abbildungen aus der Literatur (LIT), u.a die Bilder von Franken und van Gemert (2013) oder Auszüge aus den Werken von Sethe, Erman & Grapow, Brugsch, Werning und Allen.

## 4.2 Datensatz für die Segmentierung

Nach dem Vorbild von Barucci et al. (2021) wurde die Segmentierung der Inschriften mithilfe eines Objekterkennungsalgorithmus durchgeführt. Da das Material von besagten Autoren nicht mehr verfügbar war, musste zunächst ein Datensatz annotierter Bilder erstellt werden. Dafür wurde ebenfalls die Software VGG Image Annotators (VIA)<sup>5</sup> verwendet.



**Abbildung 4.2:** Links: Definition von Region Attributes in VIA mit beispielhafter Belegung. Rechts: Auszug aus dem JSON-File, dass die Annotationen speichert.

Im Unterschied zu Barucci et al. (2021) wurden die Hieroglyphen jedoch nicht mit polygonalen, sondern mit rechteckigen Bounding Boxen markiert. Die Annotationen von Bildregionen können aus VIA heraus in ein JSON-File exportiert werden und sind dort unter dem Attribut **regions** zu finden. Rechteckige Boxen werden unter dem Key **shape\_attributes.name** mit dem Wert „rect“ gespeichert. Unter **shape\_attributes** werden zudem die *x*- und *y*-Koordinaten der Ecke links oben einer Bounding Box sowie deren Breite und Höhe gespeichert, sodass alle Koordinaten der Ecken rekonstruiert werden können (Abb. 4.2 rechts, dargestellt in einem Online-Editor<sup>6</sup>). Unter **region\_attributes** werden eigens definierte Attribute einer Bounding Box gespeichert.

<sup>3</sup><https://www.metmuseum.org/de>, besucht am 12.22.2024

<sup>4</sup><https://www.britishmuseum.org/>, besucht am 12.22.2024

<sup>5</sup><https://www.robots.ox.ac.uk/~vgg/software/via/via.html>, besucht am 14.02.2025

<sup>6</sup><https://jsoneditoronline.org>, besucht am 25.02.2025






Abbildung 4.3: Vollständig annotiertes Teilbild der Stele des Qemmen aus dem Museo Egizio in Turin mit Attributen zu einer ausgewählten Box.<sup>7</sup>.




Abbildung 4.4: Rekonstruktion der Annotationen für ein Bild aus der Sammlung von Franken und van Gemert (2013).

Für die eigenen Experimente wurde jeder Hieroglyphe die Class „Hieroglyph“ sowie mit dem Attribut Gardiner der jeweilige Gardiner-Code zugeordnet (Abb. 4.2 links). Ein weiteres Attribut Number kann optional für die Markierung der Lesereihenfolge defi-

<sup>7</sup>[https://collezioni.museoegizio.it/en-GB/material/Cat\\_1513](https://collezioni.museoegizio.it/en-GB/material/Cat_1513), besucht am 25.02.2025

---

nirt werden (s. Kapitel 4.4). Zudem wurde noch ein File Attribute `Direction` definiert (s. ebenfalls Kapitel 4.4). Ein vollständig annotiertes Beispiel ist in Abb. 4.3 zu sehen.

Mit dem VIA wurden 33 Ausschnitte aus der in Kapitel 4.1 beschriebenen Sammlung annotiert. Zudem wurden die 10 bereits annotierten Bilder von den Pyramidentexten aus dem Ordner `Pictures` aus dem Datensatz von Franken und van Gemert (2013) verwendet<sup>8</sup> und mithilfe der Informationen aus dem Ordner `Locations` wurden die rechteckigen Bounding Boxen der Hieroglyphen in den Bildern rekonstruiert (s. Abb. 4.4) und in einem passenden JSON-File gespeichert. Die Annotationen von Franken und van Gemert wurden dabei teilweise bearbeitet. Zum Einen wurden einige Hieroglyphen am Rand ebenfalls annotiert, zum Anderen wurden einige der von den Autoren einzeln annotierten Zeichen zu größeren Gruppen zusammengefasst und mit dem entsprechenden Gardiner-Code versehen, damit der Objekterkennungsalgorithmus Hieroglyphen, die aus mehreren Komponenten bestehen, als solche Gruppen erkennt. Dreimal die nebeneinander geschriebene Hieroglyphe  (R8) wurde zu  (R8a), dreimal  (Z1) zu  (Z2), zweimal  (M17) zu  (M17a) und dreimal  (N35) zu  (N35a) korrigiert. Das Label „UNKNOWN“ der Autoren für fragmentarische oder nicht identifizierbare Zeichen wurde in „UD“ geändert. Zum Zweck der Data Augmentation wurden außerdem Kopien der 10 Bilder der Pyramidentexte mit jeweils 40% höheren bzw. 30% geringerem Kontrast sowie mit horizontalen Flip erstellt, sodass am Ende neben den 33 eigens annotierten Bildern noch 40 Beispiele auf Basis des Datensatzes von Franken und van Gemert gegeben waren.

Alle Bilder wurden in Greyscale transformiert. Am Ende standen 56 annotierte Bilder mit 14100 gelabelten Bounding Boxen aus 322 verschiedenen Klassen für das Training und 17 Bilder mit 5812 Annotationen für das Testing zur Verfügung.<sup>9</sup> Die Top90 Klassen sind in Anhang F.1 aufgelistet.

## 4.3 Datensatz für den Klassifikator

Um einen möglichst variantenreichen Datensatz für den Klassifikator bereitzustellen, wurden Hieroglyphenbilder aus unterschiedlichen Quellen zusammengestellt:

- Für jedes der 1072 Zeichen im Unicode-Block der Standardhieroglyphen im Bereich U+13000 bis U+1342E wurde zunächst ein Unterordner mit dem zugehörigen Gardiner-Code erzeugt. Dann wurde mit dem Aegyptus-Font<sup>10</sup> je ein 224x224-PNG-Abbild pro Hieroglyphe erzeugt und einsortiert<sup>11</sup>. Computergenerierte Hie-

---

<sup>8</sup><http://iamai.nl/downloads/GlyphDataset.zip>

<sup>9</sup>[github.com/davimon23/MAHieroglyphenOCR/data](https://github.com/davimon23/MAHieroglyphenOCR/data), Ordner `Trainingsdaten_Segmentierer` bzw. `Testdaten_Segmentierer` mit jeweiligem JSON-File, ca. 28 MB

<sup>10</sup>[localfonts.eu](http://localfonts.eu), besucht am 04.03.2025

<sup>11</sup>Die Dateinamen starten mit `XX_font_unicode_...`

---

roglyphen aus weiteren Quellen im SVG-<sup>12</sup>, TIFF-<sup>13</sup> und PNG-Format<sup>14</sup> wurden in dasselbe Format transformiert, sodass letztlich bis zu vier Beispiele pro Hieroglyphe gesammelt wurden. Alle Varianten, deren Gardiner-Code nicht Teil der Liste der Unicode-Standardhieroglyphen sind, wurden im Unterordner UD gesammelt.<sup>15</sup>

- Die ca. 9700 Patches aus dem Datensatz von Fuentes-Ferrer et al. (2025)<sup>16</sup> wurden gesichtet und mussten noch an einigen Stellen korrigiert werden, da es bspw. für die relativ häufige Hieroglyphe Aa1 keinen eigenen Ordner gab, sondern die entsprechenden Beispiele auf die Ordner anderer, ähnlicher Hieroglyphen verteilt waren.
- Die etwa 4000 manuell ausgeschnittenen, unbearbeiteten Patches von Franken und van Gemert (2013) wurden verwendet.
- Bei der eigenen Annotation von Inschriften für den Datensatz in Kapitel 4.2 fielen etwa 2700 Bounding Boxes an, die für die Klassifikation als Patches ausgeschnitten und wiederverwendet wurden.<sup>17</sup>
- Zudem wurden separat noch ca. 400 seltene Hieroglyphen aus der Handschrift von Erman und Grapow (1971) manuell ausgeschnitten.<sup>18</sup>

Als Sammlung der möglichen Klassenlabels wurde zunächst eine Liste der Gardiner-Codes der 1072 Standardhieroglyphen in Unicode erstellt.<sup>19</sup> Hier wurde R8a als relative häufige Verdreifachung des Zeichens R8 ergänzt. Außerdem wurden sehr seltene Zeichen, wie z.B. die Hieroglyphen für die ägyptischen Gaue (so wurden die Bezirke in Ägypten bezeichnet) sowie Vervielfachungen von Zählzeichen wie bspw. 𐀀, 𐀀𐀀, 𐀀𐀀𐀀, ... , 𐀀𐀀𐀀𐀀𐀀 auf wenige, häufigere Varianten reduziert. Letztlich enthielt die Klassenliste 967 verschiedene Zeichen.<sup>20</sup> Alle obigen Datensätze wurden gemäß dieser Liste gefiltert. Zudem wurden Patches mit einer maximalen Kantenlänge unter 30 Pixeln aussortiert, die Bilder wurden in Greyscale gesetzt, auf eine maximale Kantenlänge von 224 herunterskaliert und die Dateinamen wurden auf `.png` vereinheitlicht. Nach diesen Vorverarbeitungsschritten enthielt der finale Datensatz für den Klassifikator 20078 Patches aus 967 Klassen.<sup>21</sup>

---

<sup>12</sup>[github.com/googleartsculture/workbench](https://github.com/googleartsculture/workbench), besucht am 04.02.2025, Dateinamen starten mit `XX_font_glyphs_...`

<sup>13</sup>[github.com/fayrose/MiddleEgyptianDictionaryWebsite](https://github.com/fayrose/MiddleEgyptianDictionaryWebsite), besucht am 04.03.2025, Dateinamen starten mit `XX_font_Resources_...`

<sup>14</sup>[github.com/fgimbert/Hieroglyphs](https://github.com/fgimbert/Hieroglyphs), besucht am 04.03.2025, Dateinamen starten mit `XX_font_hieroglyphs_...`

<sup>15</sup>`Datensatz_Fonts`, ca. 100 MB

<sup>16</sup><https://github.com/rfuentesfe/EgyptianHieroglyphicText>, besucht am 27.03.2025

<sup>17</sup>`Annotation_ausgeschnitten`

<sup>18</sup>`Manuell_ausgeschnitten`

<sup>19</sup>`unicode_gardiner_codes.csv`

<sup>20</sup>`unicode_gardiner_codes_kurz.csv`

<sup>21</sup>`Datensatz_Final`, ca. 130 MB

---

Der Datensatz wurde durch Data Augmentation mithilfe der Bibliothek *Albumentations*<sup>22</sup> erweitert. *Albumentations*<sup>22</sup> bietet mehr als 70 verschiedene Operationen für Image Augmentation an, die einfach innerhalb eines selbst definierten Transformers kombiniert werden können. Für jede Operation gibt  $p$  die Wahrscheinlichkeit für die Ausführung der jeweiligen Transformation an. Für jeden der o.g. Teildatensätze im finalen Datensatz wurde ein etwas anders justierter Transformer verwendet, um die Eigenschaften der jeweiligen Patches zu berücksichtigen. Beispielsweise wurden je 30 Kopien jedes Font-Bilds erzeugt sowie 20 Kopien der manuellen Ausschnitte der seltenen Hieroglyphen. Die Patches aus den übrigen Datensätzen wurden gestaffelt nach ihrer absoluten Häufigkeit vervielfacht, sodass Klassen mit nur wenigen Beispielen deutlich stärker angereichert wurden im Vergleich zu den sehr häufigen Symbolen. Im Folgenden ist der Transformer für die Patches aus den selbst annotierten Bildern wiedergegeben:

```
transform = A.Compose([
    A.AdditiveNoise(noise_type='gaussian', spatial_mode = 'shared', p=0.2),
    A.Blur(blur_limit=(1, 4), p=0.4),
    A.CLAHE(clip_limit=4.0, tile_grid_size = (6, 6), p=0.4),
    A.InvertImg(p=0.3),
    A.GridDistortion(distort_limit=(-0.3,0.3), p=0.5),
    A.RandomBrightnessContrast(brightness_limit=(-0.3,0.3),
        contrast_limit=(-0.3,0.3), p=1.0),
    A.RandomCropFromBorders(crop_left=0.05, crop_right=0.05, crop_top=0.05,
        crop_bottom=0.05, p=0.7),
    A.Rotate(limit=(-10,10), border_mode=cv2.BORDER_CONSTANT, fill=255,
        crop_border=False, p=0.3)
])
```


*AdditiveNoise* fügt dem Bilder ein Gauß-Rauschen hinzu. *Blur* erzeugt Unschärfe innerhalb eines festgelegten Rahmens. *AdditiveNoise* und *Blur* wurden nur für Bilder ab einer minimalen Kantenlänge von 50 Pixeln angewendet. *CLAHE* (Contrast Limited Adaptive Histogram Equalization) ist eine erweiterte Version der klassischen Histogramm-Equalisierung, die entwickelt wurde, um die Bildkontraste zu verbessern und gleichzeitig die Überbetonung von Rauschen zu verhindern. *tile\_grid\_size* wurde bei kleinen Bildern reduziert, damit diese nicht zu grobkörnig werden. *InvertImg* invertiert das Bild. *GridDistortion* sorgt für eine Verzerrung des Bildes. *RandomBrightnessContrast* variiert Helligkeit und Kontrast. *RandomCropFromBorders* schneidet das Bild um bis zu 5% an den Rändern zu. *Rotate* dreht das Bild um bis zu 10° und schneidet es wieder rechteckig zu. Ein Beispiel für die separate Anwendung aller Transformationen ist in Abb. 4.5 zu sehen. Ein separater Transformer erzeugt dann noch horizontal gespiegelte Kopien aller Bilder.

Trotz der versuchten Balancierung hat das häufigste Zeichen N35 im angereicherten Datensatz ca. 2600 Beispiele im Vergleich zu der Standardanzahl von 120 Varianten für diejenigen Hieroglyphen, für die es keine Realbeispiele im finalen Datensatz gibt

---

<sup>22</sup><https://github.com/albumentations-team/albumentations>, besucht am 02.02.2025

(etwa unterstes Drittel des Datensatzes). Die absoluten Häufigkeiten der 200 im finalen Datensatz häufigsten Zeichen bzgl. der Quelldatensätze sowie ihrer Beispiele nach Data Augmentation sind in Anhang F.2 aufgelistet.<sup>23</sup> Nach Data Augmentation umfasste der Datensatz ca. 316.000 Beispiele mit einer Gesamtgröße von 4,4 GB, weswegen im Github-Repository nur ein Ordner mit einer Stichprobe von 2000 Patches zur Ansicht zu finden ist.<sup>24</sup> Einige Beispielpatches sind in Abb. 4.6 wiedergegeben.



**Abbildung 4.5:** Originalbild (ganz oben) und neun Varianten erzeugt durch unterschiedliche Operations aus Albumentations.

Ob nun auch 100.000 oder 200.000 Beispiele im finalen Datensatz für das Training eines guten Klassifikators ausreichen würden, müsste in Folgeexperimenten noch getestet werden, da sicherlich ein längeres Training einen spärlicheren Trainingsdatensatz in


<sup>23</sup>klassen\_anzahlen\_Klassifikator.xlsx

<sup>24</sup>Datensatz\_Augmented\_Sample, ca. 130 MB





dem Präfix LR bzw. RL versehen wurden.<sup>25</sup> Beispiele sind in der Abb. 4.7 dargestellt. Vor dem Training wurden die Bilder in Greyscale transformiert und es wurde Data Augmentation angewendet. Mit Albumentations wurden pro Bild 40 Kopien mit ähnlichen Einstellungen wie bereits beim Datensatz aus Kapitel 4.3 erzeugt. Mehrere Testläufe bei den Experimenten in Kapitel 5.2 ergaben, dass unter Verwendung von weniger Kopien keine ausreichend guten Trainingsresultate erreicht wurden. Nach Data Augmentation enthielt der finale Datensatz 4400 Bilder bei einer Gesamtgröße von 2,2 GB, sodass im in Github nur eine Stichprobe von etwa 80 Beispielen bereitgestellt wird.<sup>26</sup>



**Abbildung 4.7:** Sechs Patches aus dem Datensatz für die Links-Rechts-Leserichtung vor Data Augmentation.

Alternativ sind auch andere Datensatzstrukturen für das Training der maschinellen Erkennung der Links-Rechts-Leserichtung denkbar. Beim Datensatz aus Kapitel 4.2 wurde bereits `Direction` als `file_attribute` definiert, in dem pro annotiertem Bild festgehalten ist, ob der hieroglyphische Text horizontal oder vertikal bzw. von rechts nach links oder umgekehrt geschrieben ist. In Abb. 4.2 rechts ist z.B. „VRL“ für die Schriftrichtung „vertikal, von rechts nach links“ vermerkt. Auf diese Weise kann dieser Datensatz bei ausreichend großer Datengrundlage neben der Segmentierung auch für die Ermittlung der Leserichtung verwendet werden. Ein separater Algorithmus muss hier aber noch auf Basis der bestimmten Leserichtung die segmentierten Zeichen in die korrekte Reihenfolge bringen. Daher könnte man sogar noch einen Schritt weiter gehen und den annotierten Datensatz mit `Number` als zusätzlichem `region_attribute`, das die Zeichenreihenfolge beim korrekten Auslesen speichert, erzeugen, um damit ein

<sup>25</sup>Datensatz\_Leserichtung\_grey, 25 MB

<sup>26</sup>Datensatz\_Leserichtung\_Augmented\_Sample

---

separates Modell für die Bestimmung der Zeichensequenz zu trainieren. Diese Ansätze wurden jedoch aus Zeitgründen nicht weiter verfolgt.

## 4.5 Datensatz für den Gesamtprozess

Für den Test des Gesamtprozesses aus Segmentierung, Sequenzierung und Klassifikation wurde ein Datensatz benötigt, der sowohl Bilder von hieroglyphischen Inschriften als auch die zugehörige Gardiner-Sequenz enthält. Da es einen solchen Datensatz im Vorfeld nicht gab, wurden eine geeignete Datensammlung auf Basis der Daten aus dem TLA zusammengestellt. Im TLA selbst gibt es zwar für zahlreiche Texteinträge eine hieroglyphische Transliteration und die zugehörige Gardiner-Sequenz, jedoch gab es zum Zeitpunkt der Ausarbeitung keine API, über die die Texte einfach von der Webseite abgezogen werden konnten.



### Gardiner-Sequenz:

T22 N35 D19 N16 N23 Z1 N35 W17 N35 X1 G130 A40  
G17 O1 D21 X1 D54 O29 X1 D21 D36 X1 M17 G1 A30  
N35 O10 D2 D21 X1 D1 O34 X1 N25 Z2 W10 X1 V30 X1  
O1 Z2 D2 D21 G43 M17 N35 F39 Aa1 F20 N37 N35 D36  
V37 Z2b M17 Y5 N35 G17 F4 X1 Z1

### Transkription:

sn t̥ n ḥnt(,j)-jmn,tjw m pr,t-ḡ,t rdi,t j̥,w n ḥw,t-ḥr,w  
ḥr(,j)t-tp-z(mj),t ḥn,wt? nb,t pr.pl ḥr(,j).w jn jm̥ḥ jm,j-  
r'-šn',pl jmn-m-ḥ,t

### Übersetzung:

Die Erde küssen für Chontamenti bei der großen Prozession. Lobpreis geben für Hathor, die auf der Nekropole befindlich ist, die Herrin der oberen Häuser, durch den Versorgten, den Vorsteher des šn', Amenemhat.

**Abbildung 4.8:** Ausschnitt einer Inschrift aus der Stele des Amenemhat aus dem British Museum (BM EA 567) inklusive der Gardiner-Sequenz, der Transkription und der deutschen Übersetzung.<sup>27</sup>



---

Es gibt jedoch eine 2018 zusammengestellte ZIP-Datei **corpus.zip**, die einen von Richter et al. (2018) veröffentlichten Teilauszug des TLA enthält.<sup>28</sup> Die Inhalte wurden thematisch aggregiert in Form von JSON-Dateien bereitgestellt, die unterschiedliche inhaltliche und Meta-Daten zu den gesammelten Texten und Textausschnitten umfassen. Aus allen JSON-Dateien wurden alle Texte mit ihrem Namen, ihrer Übersetzung, Transkription und Gardiner-Sequenz extrahiert. Anschließend wurden nur solche Texte herausgefiltert, für die überhaupt eine Gardiner-Sequenz angegeben war (ca. 2900 Einträge).<sup>29</sup> Auf Basis dieser Auswahl wurden für 28 Einträge Abbildungen der zugehörigen Inschriften aus dem Web gesammelt, vornehmlich von den Webseiten des British Museum<sup>30</sup>, des Metropolitan Museum of Art<sup>31</sup>, des Louvre<sup>32</sup>, des Rijksmuseum van Oudheden<sup>33</sup> und des Museo Egizio<sup>34</sup> sowie aus Allen (2014b) und Piankoff (1968). Aus diesem Konvolut wurden anschließend 46 Textbeispiele zusammengestellt.<sup>35</sup> Die Datei **Datensatz\_Gesamtprozess.csv** tabelliert für jedes Textbeispiel einen Namen für die Inschrift, den Namen der zugehörigen JPG-Datei im Ordner **Datensatz\_Gesamtprozess**, eine Übersetzung, Transkription und eine von allen Sonderzeichen bereinigte Gardiner-Sequenz. Ein Beispiel ist in der Abb. 4.8 dargestellt. Die Hieroglyphen in den vorbereiteten Bildern können mithilfe der im nächsten Kapitel entwickelten Modelle segmentiert, sequenziert und klassifiziert und die sich daraus ergebenden Gardiner-Sequenzen mit den erwarteten Ergebnissen verglichen werden. Weiterhin kann getestet werden, wie gut der Gesamtprozess im Hinblick auf eine sich anschließende Übersetzung funktioniert. Damit kann abgeschätzt werden, wie sich Fehler bei der Segmentierung, Sequenzierung oder Klassifikation auf das Übersetzungsergebnis auswirken.

---

<sup>27</sup>[https://www.britishmuseum.org/collection/object/Y\\_EA567](https://www.britishmuseum.org/collection/object/Y_EA567), besucht am 14.03.2025

<sup>28</sup><https://edoc.bbaw.de/frontdoor/index/index/docId/2919>, besucht am 14.03.2025

<sup>29</sup>**Quellen\_GardinerCodes.xlsx**, Sheet *Quellen*

<sup>30</sup><https://www.britishmuseum.org/>, besucht am 13.03.2025

<sup>31</sup><https://www.metmuseum.org/de>, besucht am 13.03.2025

<sup>32</sup><https://collections.louvre.fr/>, besucht am 13.03.2025

<sup>33</sup><https://www.rmo.nl/>, besucht am 13.03.2025

<sup>34</sup><https://www.museoegizio.it/en/discover/collection/>, besucht am 13.03.2025

<sup>35</sup>**Datensatz\_Gesamtprozess**, ca. 40 MB




# Kapitel 5

## Experimente

Die Programmierung aller im Folgenden beschriebenen Anwendungen wurde vollständig in Form von Python Notebooks in der Umgebung von Google Colab unter Verwendung der von Google bereitgestellten CPU/GPU durchgeführt.

### 5.1 Segmentierung

Die Erkennung der Hieroglyphen in einem Bild wird im Folgenden als Segmentierung bezeichnet. Hierfür wurde analog zu Barucci et al. (2021) ein Objekterkennungsalgorithmus aus dem *Model Zoo* von Detectron2<sup>1</sup> verwendet. Genauer wurde der auf dem COCO-Datensatz vortrainierte Mask R-CNN (3x-Schedule, d.h. etwa 37 COCO-Epochen) mit ResNet50- und FPN-Backbone geladen.



**Abbildung 5.1:** Links: Anwendung des originalen Mask R-CNN auf eine Inschrift. Rechts: Beispiel für eine Vorhersage des Segmentierungsmodells mit inhärenter Klassifikation. Einige Beispiele von N35, M17 oder X1 sind bereits korrekt vorhergesagt.

<sup>1</sup><https://github.com/facebookresearch/detectron2>, besucht am 25.02.2025

In einem ersten Experiment wurde das o.g. Modell mit einem Threshold (`MODEL.ROI_HEADS.SCORE_THRESH_TEST`) von 0,2 - einem Mindest-Konfidenzwert für die vorhergesagten RoIs (Regions of Interest), der mindestens erreicht werden muss, damit eine vorhergesagte Box für die finale Ausgabe behalten wird - testweise direkt auf eine Inschrift angewendet. Das Ergebnis ist in Abb. 5.1 links gezeigt. Das Modell erkennt ohne weiteres Finetuning einige wenige Hieroglyphen und markiert ihre Konturen. Es erkennt ein paar Vögel als solche, annotiert jedoch andere Hieroglyphen oder auch Teile von ihnen mit unsinnigen Begriffen. Daher kann das Modell offensichtlich nicht direkt verwendet werden.


Als nächstes wurde das auf COCO vortrainierte Modell auf dem Trainingsdatensatz für die Segmentierung nachtrainiert. In diesem Ansatz wurden 967 Klassen unterschieden (vgl. Kapitel 4.3), d.h. der Objekterkennungsalgorithmus sollte neben der Hieroglyphenerkennung gleichzeitig eine Klassifikation vornehmen (Modell `all_in_one`). Zu der Liste wurde noch UD für im Datensatz undefinierte Zeichen hinzugefügt und alle Labels der Patches in den annotierten Bildern, die nicht in der Klassenliste vorkamen, wurden ebenfalls durch UD ersetzt. Für alle Detectron2-Modelle in dieser Arbeit wurden folgende Parameter konstant gehalten: `DATALOADER.NUM_WORKERS` = 2 (Anzahl der Data Loading Threads), `IMS_PER_BATCH` = 2 (Anzahl der Bilder pro Trainings-Batch), `ROI_HEADS.BATCH_SIZE_PER_IMAGE` = 512 (Anzahl der RoIs pro Bild für das Training des RoI-Heads). Andere Parameter wurden modellspezifisch gewählt: `ROI_HEADS.NUM_CLASSES` (Anzahl möglicher Klassen), `BASE_LR` (Lernrate), `MAX_ITER` (Anzahl der Epochen). Eine Übersicht ist in Tabelle 5.1 zusammengestellt.

| Modell                        | Klassen | Epochen | Lernrate                               | Trainingsdauer |
|-------------------------------|---------|---------|----------------------------------------|----------------|
| <code>all_in_one</code>       | 968     | 1000    | 0,00025                                | 14 min         |
| <code>segm_3000_001</code>    | 1       | 3000    | 0,001                                  | 35 min         |
| <code>segm_4000_001</code>    | 1       | 4000    | 0,001                                  | 49 min         |
| <code>segm_3000_01</code>     | 1       | 3000    | 0,01                                   | 35 min         |
| <code>segm_4000_01</code>     | 1       | 4000    | 0,01                                   | 48 min         |
| <code>segm_5000_01_001</code> | 1       | 5000    | 0,01 (ab Ep. 4000 auf 0,001 reduziert) | 60 min         |

**Tabelle 5.1:** Übersicht über die bei den verschiedenen Detectron2-Modellen variabel gewählten Parameter.

Das Training des Modells `all_in_one` dauerte ca. 14 min bei Unterstützung durch die T4-GPU von Google Colab. Ab der 200. Epoche reduzierte sich der Classification Loss sowie der Total Loss nur noch langsam. Bei der Einstellung des Prädiktors wurde ein Konfidenz-Threshold von 0,2 gewählt. Der Non-Maximum Suppression (NMS) Threshold (`ROI_HEADS.NMS_THRESH_TEST`), der angibt, ab welcher IoU (Intersection over Union) zweier Boxen die Bounding Box mit der niedrigeren Konfidenz verworfen wird, ist per default auf 0,5 gesetzt. Die maximale Anzahl an Vorhersagen pro Bild (`DETECTIONS_PER_IMAGE`) musste von 100 auf 1000 hochgesetzt werden, da viele Testbilder sehr viele Hieroglyphen enthalten, die auch alle erkannt werden sollen. Die

Parameter `RPN.PRE_NMS_TOPK_TEST` (Anzahl der Region Proposals *vor* NMS im RPN) bzw. `RPN.POST_NMS_TOPK_TEST` (Anzahl der Region Proposals *nach* NMS im RPN) wurden entsprechend auf 1500 bzw. 1000 angepasst. Gerade der erstere Parameter ist entscheidend bei der Erkennung sehr vieler Hieroglyphen, da das RPN ausreichend Region Proposals erstellen muss, damit nach vollständiger Prozessierung der Bounding Boxen auch möglichst jede Hieroglyphe im Bild gefunden wird. Dabei steigt aber gleichzeitig das Risiko von falsch-positiven Vorhersagen. Dem kann mit der Einstellung eines geeigneten Konfidenz-Thresholds begegnet werden. Je nach Anwendungsfall und erwartetem Ergebnis kann der Prädiktor also gut eingestellt werden. Ein Beispiel mit vom Modell vorhergesagten, mit Gardiner-Code gelabelten Boxen inkl. Konfidenz ist in Abb. 5.1 rechts gegeben. Die automatische Evaluation mithilfe des COCO Evaluators auf dem Testdatensatz ergab sehr niedrige Werte von wenigen Prozent für die Average Precision (AP), die die durchschnittliche Präzision über alle IoU-Schwellenwerte und alle Objektkategorien hinweg angibt. Dies lag vor allem daran, dass manche Klassen mit nur sehr wenigen Beispielen und andere gar nicht repräsentiert waren. Unter den Top10 Klassen (siehe F.1) erreichen einige Klassen wie G17 oder G43 bereits beachtlich hohe AP-Werte von 45% bzw. 50%.




**Abbildung 5.2:** Links: Mit Gardiner-Codes gelabelte Bounding Boxen. Rechts: Mit der einzigen Klasse „Hieroglyph“ gelabelte Boxen.

Insgesamt sieht dieser kombinierte Segmentierungs-Klassifizierungs-Ansatz vielversprechend aus und demonstriert nach einem nur kurzen Training auf wenigen Trainingsdaten die Mächtigkeit aktueller Objekterkennungsalgorithmen. Der Trainingsdatensatz müsste jedoch aufgrund der zahlreichen unter- und gar nicht repräsentierten Klassen erheblich erweitert werden. Die hieroglyphenweise Annotation und das Labeling der Bilder mit Gardiner-Code erfordert hierbei einen sehr großen manuellen Aufwand. Daher wur-

de im Folgenden die Segmentierung getrennt von der Klassifikation implementiert und der Gardiner-Codes der ausgeschnittenen Patches in einem Folgeprozess bestimmt.

| Modell           | AP     | AP50   | AP75   | APs    | APm    | APl    |
|------------------|--------|--------|--------|--------|--------|--------|
| segm_3000_001    | 58.199 | 89.720 | 70.001 | 45.411 | 58.866 | 69.085 |
| segm_4000_001    | 59.563 | 90.687 | 72.575 | 45.443 | 60.122 | 69.369 |
| segm_3000_01     | 62.847 | 91.810 | 77.340 | 49.071 | 63.436 | 71.428 |
| segm_4000_01     | 63.124 | 90.806 | 78.737 | 51.012 | 63.730 | 74.415 |
| segm_5000_01_001 | 63.389 | 91.734 | 76.651 | 50.478 | 63.956 | 73.072 |

**Tabelle 5.2:** Evaluation ausgewählter Detectron-Modelle.




**Abbildung 5.3:** Evaluationsmetriken für das Training mit einer Lernrate von 0,001 bei maximal 4000 Epochen.

In einem dritten Ansatz wurde der Fokus also nur noch auf die Segmentierung gelegt. Dazu wurde für jede Bounding Box nur das Attribut **Class** betrachtet, das eine Hieroglyphe als solche vom Hintergrund unterscheidet, ohne die Zeichen untereinander zu differenzieren. Der Unterschied in den Labels zwischen Ansatz 2 und 3 ist in Abb. 5.2 gezeigt. Einige initiale Tests wurden für eine grobe Eingrenzung der Parameter bzgl. Lernrate und Epochenanzahl durchgeführt. Für fünf Modelle wurden detaillierte-

re Evaluationen erstellt (s. Tabelle 5.2). Die Entwicklung der Modellgenauigkeit bzw. Loss-Werte wurden über das TensorBoard dargestellt.

Bei der Einstellung des Prädiktors wurden für die Detectron2-Modelle aus Tab. 5.2 stets dieselben Parameter verwendet: Konfidenz-Threshold von 0,5, NMS-Threshold von 0,5, maximal 1000 Vorhersagen pro Bild, 5000 Region Proposals vor NMS im RPN, 1000 Region Proposals nach NMS im RPN. Tabelle 5.2 zeigt die bei der Evaluation mit dem COCO Evaluator ermittelten AP-Werte für jedes der Modelle. AP<sub>xx</sub> ist die durchschnittliche Präzision bei einem IoU-Schwellenwert von 0.xx, die misst, wie gut das Modell Objekte mit einer mindestens xx%igen Überlappung mit den Ground-Truth-Boxen erkennt. APs (AP small) bzw. AP<sub>m</sub> (AP medium) bzw. AP<sub>l</sub> (AP large) bewertet die Erkennungsleistung für kleine (bis 32 x 32 Pixel) bzw. mittelgroße (32 x 32 Pixel bis 96 x 96 Pixel) bzw. große (über 96 x 96 Pixel) Objekte<sup>2</sup>.



**Abbildung 5.4:** Evaluationsmetriken für das Training mit einer Lernrate von 0,01 (0,001 ab Epoche 4000) bei maximal 5000 Epochen.

Bei einer Lernrate von 0,001 erkennt man bei Betrachtung der entsprechenden Diagramme in Abb. 5.3, dass die Klassifikationsgenauigkeit (**fast\_rcnn**), d.h. die Unterscheidung zwischen Hieroglyphe und Hintergrund, sowie der gewichtete Gesamtverlust (**total\_loss**) bis Epoche 2000 noch relativ stark zu- bzw. abnehmen. Danach ver-

<sup>2</sup><https://cocodataset.org/#detection-eval>, besucht am 28.02.2025



bessern sich die Werte nur noch langsam weiter. Die genaue Betrachtung des Werts `loss_box_reg`, der angibt, wie gut das Modell die Bounding Boxen positioniert und dimensioniert und des Werts `loss_cls`, dem Loss des Klassifikators, zeigt ab Epoche 3000, dass hauptsächlich die genauere Lokalisierung der Boxen zur Reduktion des Gesamtverlusts beiträgt (noch deutlicher in Abb. 5.4). Für den vorliegenden Anwendungsfall ist jedoch die Erkennung der Hieroglyphen primär von Interesse, nicht deren exakte Bounding Box. Der Vergleich der AP-Werte von `segm_3000_001` und `segm_4000_001` bestätigt den Trend, dass eine höhere Iterationszahl gewinnbringend ist, jedoch ist der Gewinn an durchschnittlicher Präzision zwischen Epoche 3000 und 4000 so gering, dass das Training nicht mehr fortgeführt wurde. Abb. 5.5 zeigt, dass das Modell `segm_4000_001` bereits eine perfekte Segmentierung eines kleinen Textbeispiels erzeugt. Bemerkenswert an diesem Beispiel ist, dass die vier grün eingerahmten Einzelstriche (etwas rechts vom Mittelpunkt der Abbildung) nicht als vier separate, sondern korrekt als eine Hieroglyphe für die Zahl 4 aufgefasst werden. Auch die Anwendung des Modells auf eine große Inschrift wie in Abb. 5.6 zeigt bis auf einige wenige fehlende Erkennungen ein hervorragendes Ergebnis. Um alle Hieroglyphen zu erfassen, müssen bei einem konkreten Beispiel ggf. die Parameter des Prädiktors anders eingestellt werden. Wird die Lernrate auf 0,01 heraufgesetzt, so ergibt sich der Trainingsverlauf in Abb. 5.4. Beim Vergleich der Kurven mit denen aus Abb. 5.3 erkennt man die Auswirkung der verzehnfachten Lernrate gut: Der Trainingsfortschritt schwankt viel stärker und etwa bei Epoche 700 ist ein relativ starker Ausbruch zu erkennen, nach dem sich das Modell aber wieder fängt. Zum Zweck eines stabileren Trainings wurde ab Epoche 4000 die Lernrate auf 0,001 reduziert und nur noch bis Epoche 5000 weitertrainiert.



Abbildung 5.5: Vorhersage auf einer kürzeren Inschrift aus Sethe (1909).







Abbildung 5.6: Vorhersage auf einer Inschrift mit sehr vielen Zeichen<sup>3</sup>.

Insgesamt werden bei einer Lernrate von 0,01 bis Epoche 4000 bessere Genauigkeiten und Loss-Werte im Vergleich zu den Modellen mit geringerer Lernrate erreicht. Tabelle 5.2 zeigt, dass die Modelle mit Lernrate 0,01 den vorherigen in den meisten AP-Kategorien überlegen sind. Aufgrund des etwas höheren AP-Werts für kleine Objekte (APs) beim Training bis Epoche 4000 wird für die folgenden Experimente das Modell `segm_4000_01.pth` (168 MB) verwendet. Detaillierte Daten zum Verlauf des Modelltrainings sind in der Datei `segm_4000_512_01_train.txt` und die Ergebnisse des COCO Evaluators in `segm_4000_512_01_test.txt` zusammengefasst.<sup>4</sup> Nichtsdestotrotz sind die AP-Werte über alle Modelle hinweg sehr solide (vgl. Tian et al. (2024)).

## 5.2 Links-Rechts-Leserichtung

Wie bereits in der Zusammenfassung von Kapitel 3 festgestellt wurde, wurde in der Literatur bisher keine allgemeingültige Lösung zur Feststellung der Links-Rechts-Leserichtung (LRL) erarbeitet. Für das menschliche Auge ist die Ermittlung der Ausrichtung der Hieroglyphen durch den Fokus auf die Blickrichtung der Menschen und Tiere darstellenden Zeichen beinahe trivial (s. Kapitel 2).



**Abbildung 5.7:** Entwicklung des gesamten Loss sowie der Top1-Genauigkeit beim Training des LRL-Klassifikators im Verlauf der 10 Epochen.

Für die maschinelle Erkennung wurde ein YOLO-Klassifikator gewählt. YOLO (You Only Look Once) ist eine CNN-basierte Architektur für die Echtzeit-Objekterkennung, die Bilder in einem einzigen Durchgang durch ein neuronales Netzwerk analysiert. Die Kernidee ist, ein Bild in eine feste Anzahl von Zellen zu unterteilen und für jede Zelle vorherzusagen, ob sich dort ein Objekt befindet und welche Position und Klasse es hat. YOLO-Architekturen zeichnen sich aus durch Schnelligkeit, zusätzliche Genauigkeit durch eine ganzheitliche Betrachtung des Bildes und eine gute Generalisierbarkeit. In Abb. E.2 ist die Architektur ebenfalls schematisch dargestellt. Für die unterschiedlichen

<sup>3</sup>KontrastA\_egyptianTexts23.jpg

<sup>4</sup>[github.com/davimon23/MAHieroglyphenOCR/tree/main/src](https://github.com/davimon23/MAHieroglyphenOCR/tree/main/src)



---

Aufgaben gibt es verschiedene Varianten in der Version 11 von YOLO, wie z.B. für die Objekterkennung, Klassifikation oder Instanz-Segmentierung. Ein YOLO-Klassifikator ist eine angepasste Version der ursprünglichen YOLO-Architektur, die nur eine Klassenwahrscheinlichkeit für das gesamte Bild ausgibt. Es gibt unterschiedlich gewichtige Varianten: *n* (nano), *s* (small), *m* (medium), *l* (large) und *x* (extra large), die wenige bis über 100 Millionen Gewichte haben und bei denen es einen unterschiedlichen Tradeoff zwischen Schnelligkeit (maximal bei *n*) und Genauigkeit (maximal bei *x*) gibt.<sup>5</sup>

Für das Training wurde der angereicherte Datensatz aus Kapitel 4.4 in die für YOLO11 notwendige Struktur überführt und im Verhältnis 80:10:10 in Trainings-, Validierungs- und Testdaten aufgeteilt. Dann wurde das auf ImageNet vortrainierte Modell `yolo11n-cls.pt` von Ultralytics geladen und die Modellparameter `model.nc = 2` und `model.names = ['LR', 'RL']` wurden entsprechend der Aufgabenstellung definiert. Für das Training wurde eine Batch Size von 32, eine initiale Lernrate von 0,01, der AdamW-Optimierer und ein `weight_decay` von 0,02 - einem Gewicht für einen L2-Regularisierungsterm für die Reduktion von Overfitting - gewählt. Das Ziel ist schließlich das Training eines gut generalisierenden Klassifikators. Außerdem wurden die Augmentation Settings `flipplr` und `flipud` explizit jeweils auf 0,0 gesetzt. Diese Hyperparameter sorgen bei der impliziten Data Augmentation während des Trainings, dass Bilder horizontal (`flipplr`) bzw. vertikal (`flipud`) geflippt werden.<sup>6</sup> Per Default gilt `flipplr = 0,5`, sodass die sorgfältig nach LRL gelabelten Bilder durch einen Flip beim Training unter dem gegenteiligen Label betrachtet würden, was es dem Modell unmöglich machen würde, ein eindeutiges Muster für die LRL in den Trainingsdaten zu erkennen. Das Modell wurde über 10 Epochen bei einer Laufzeit von 37 min auf der T4-GPU von Google Colab trainiert. Damit wurde eine zufriedenstellende Top1-Genauigkeit von 98,4% auf dem Testdatensatz erreicht, vgl. die Metriken in Abb. 5.7. Das Modell `YOLO11n_Leserichtung.pt` ist in Github zu finden und die Daten zum Verlauf des Modelltrainings und die automatisch ermittelten Evaluationsergebnisse sind in der Datei `YOLO_Leserichtung.txt` dokumentiert. Die Modellgröße von 3 MB ist im Vergleich zum Detectron2-Modell aus Abschnitt 5.1 deutlich kleiner, was die Leichtgewichtigkeit von den *state-of-the-art* YOLO-Architekturen gut veranschaulicht.

## 5.3 Sequenzierung


Nach der Bestimmung der Bounding Boxen und der Links-Rechts-Leserichtung, die nach der Anwendung des entsprechenden YOLO-Modells als LR oder RL im Flag `direction` gespeichert ist, musste für eine korrekte Sequenzierung der Hieroglyphen als nächstes die Anordnung des Texts in Zeilen bzw. Spalten bestimmt werden. Zu diesem Zweck wurden die Boxen aus der Segmentierung durch Detectron2 ausgenutzt, die sich analog zu den Hieroglyphen in Zeilen bzw. Spalten konzentrieren. Die Abb. 5.5 aus Sethe (1909), die bereits in Kapitel 5.1 per Detectron2-Modell analysiert wurde, wurde erneut mit einem Konfidenz-Threshold von 0,8 und NMS-Threshold von 0,5 ausgewertet.

---

<sup>5</sup><https://docs.ultralytics.com/de/models/yolo11/>, besucht am 04.03.2025

<sup>6</sup>[docs.ultralytics.com](https://docs.ultralytics.com), besucht am 10.03.2025

Offensichtlich ist der hieroglyphische Text zeilenweise geschrieben. Zwischen den Zeilen gibt es Bänder unterschiedlicher Dicke, die von keiner Bounding Box geschnitten werden. Die Ermittlung solcher Bänder liefert einerseits eine Entscheidung bzgl. der Ausrichtung in Zeilen/Spalten und zerlegt den Text gleichzeitig in Teillisten, die anschließend separat ausgelesen werden. Um die Bänder zwischen den Textzeilen/-spalten zuverlässig zu lokalisieren, werden reduzierte Boxen betrachtet, die durch Schrumpfen der originalen Bounding Box auf 85% in Richtung ihres Zentrums erzeugt wurden. In Abb. 5.8 sind die Zeichen bereits durch die reduzierten Boxen eingerahmt. Anschließend werden alle horizontalen bzw. vertikalen Linien mit einer Ausdehnung über die gesamte Bildbreite bzw. Bildhöhe bestimmt, die keine der reduzierten Boxen schneiden. Die verantwortliche Funktion `check_collision` verwendet hierbei den Cohen-Sutherland-Algorithmus<sup>7</sup>, mit dem ermittelt werden kann, ob die besagten Linien oberhalb, unterhalb, links oder rechts von einer Box verlaufen.



**Abbildung 5.8:** Weiterverarbeitung von Abb. 5.5 mit reduzierten Bounding Boxen und den längsten Linien im Bild (rot), die keine dieser Boxen schneiden.

Die Prozedur `find_longest_lines` bestimmt unter Verwendung von `check_collision` alle relevanten Linien und sortiert im Anschluss alle Linienbündel aus, die am Rand des Bildes liegen. Da die Boxen reduziert wurden, findet der Algorithmus stets relevante Linien am Bildrand, die jedoch als Trenner für die Zeilen/Spalten irrelevant sind und zu falschen Ergebnissen führen können. Zudem werden alle Linien entfernt, die kürzer als die doppelte Länge der längsten Box-Seite im Bild sind. Dies ist wichtig bei einzeiligen bzw. einspaltigen Texten, da deren Hieroglyphen durch viele kurze vertikale bzw. horizontale Linien getrennt werden können, die aber nichts über die eigentliche Anordnung aussagen. Schließlich wird von der Schar der gefilterten horizontalen bzw. vertikalen Linien diejenige zurückgegeben, deren Linien länger sind. Auf diese Weise wurden die längsten Linien im Bild gefunden,

<sup>7</sup>[https://de.wikipedia.org/wiki/Algorithmus\\_von\\_Cohen-Sutherland](https://de.wikipedia.org/wiki/Algorithmus_von_Cohen-Sutherland), besucht am 16.03.2025

die die Hieroglyphen trennen. Diese sind in Abb. 5.8 rot dargestellt. Die Güte des Ergebnisses hängt maßgeblich von der Ausrichtung des Bildes ab. Wurde das Bild zu schräg aufgenommen, so werden die Trennlinien ggf. nicht mehr erkannt, sodass das Bild u.U. in einer Vorprozessierung in die korrekte Ausrichtung gedreht werden muss. Die Funktion `center_lines` zentriert die roten Bänder jeweils noch auf eine einzige (blaue) Linie, um die anschließende Zerlegung in Teillisten zu vereinfachen. Aus diesem Zwischenergebnis bestimmt die Prozedur `determine_arrangement` die Anordnung in Zeilen bzw. Spalten, indem die Liste der zentrierten Linien ausgewertet wird. Ist diese leer (d.h. eine einzeilige/-spaltige Inschrift liegt vor), dann werden die maximalen und minimalen  $x$ - und  $y$ -Koordinaten aller Bounding Boxes bestimmt und aus der Differenz zwischen den extremalen  $x$ - und  $y$ -Koordinaten wird die Ausrichtung ermittelt. Wenn die Differenz in  $x$ -Richtung größer ist, ist der Text als Zeile geschrieben, sonst als Spalte. Ist die Liste der zentrierten Linien nicht leer, dann wird für die erste Linie der Liste analysiert, ob diese horizontal oder vertikal verläuft. Entsprechend wird der Flag `arrangement` auf „Zeilen“ bzw. „Spalten“ gesetzt. Zudem wird eine Liste der  $y$ - bzw.  $x$ -Koordinaten der zentrierten Linien zurückgegeben.




Abbildung 5.9: Ergebnis der Sequenzierung der separierten Teillisten aus Abb. 5.9.

Die Funktion `split_bounding_boxes` teilt, für den Fall, dass Trennlinien gefunden wurden, die Gesamtliste der Bounding Boxes im Falle von `arrangement` = „Spalten“ anhand der  $x$ -Koordinaten bzw. im Falle von `arrangement` = „Zeilen“ anhand der  $y$ -Koordinaten der Trennlinien in Teillisten auf. Der Flag für die Links-Rechts-Leserichtung `direction` bestimmt die Nummerierung der Teillisten entsprechend der Leserichtung. Die letzte Funktion `sort_bboxes_and_extract_images` sortiert nun die Boxes in den Teillisten anhand der Koordinaten ihrer Eckpunkte und schneidet die entsprechenden Patches aus dem Originalbild aus. Für die Sortierung werden die Koordinaten der Zentren der Boxes berechnet und je nach `arrangement` unterschiedlich stark gewichtet. Bei einer spaltenweisen Anordnung wird die  $y$ -Koordinate des Zentrums

doppelt und bei einer zeilenweisen Anordnung wird die  $x$ -Koordinate des Zentrums etwas mehr als doppelt gewichtet. Dann werden die Patches gemäß `direction` sortiert. Abb. 5.9 zeigt das Ergebnis der perfekten Sortierung der Teillisten, die aus dem Beispiel in Abb. 5.8 erhalten wurden.

## 5.4 Klassifikation

Der Datensatz aus Kapitel 4.3 wurde für das Training eines YOLO-Klassifikators zur Bestimmung des Gardiner-Codes einer Hieroglyphe verwendet. Zuvor wurden auf kleineren Datensätzen auch andere Architekturen wie ResNet50, EfficientNet oder ein Ansatz mit einem Siamese Network getestet, doch diese wurden verworfen aufgrund von zu langen Epochenlaufzeiten oder Beschränkungen in der Rechenkapazität.

Für die vorliegende Klassifikationsaufgabe wurden die Varianten  $n$ ,  $m$  und  $l$  des allgemeinen YOLO-Klassifikators mit den Settings in Tab. 5.3 getestet. Die jeweilige Trainingsdauer bezieht sich auf die Verwendung der L4-GPU in Google Colab.


| Modell               | Epochen | Lernrate                                                            | Trainingsdauer |
|----------------------|---------|---------------------------------------------------------------------|----------------|
| YOLO11n_15_01_0001   | 15      | 0,01 bis 0,0001 bis Epoche 10,<br>danach konstant bis Epoche 15     | 64 min         |
| YOLO11m_15_01_000001 | 15      | 0,01 bis 0,0001 bis Epoche 10,<br>danach bis 0,000001 bis Epoche 15 | 106 min        |
| YOLO11l_15_01_0001   | 15      | 0,01 bis 0,0001                                                     | 136 min        |

**Tabelle 5.3:** Übersicht über die trainierten YOLO-Modelle mit den gewählten Parametern.

Zunächst wurde der Datensatz aus Kapitel 4.3 in die für YOLO11 notwendige Struktur überführt und im Verhältnis 80:10:10 in Trainings-, Validierungs- und Testdaten aufgeteilt. Dann wurde eine entsprechende auf ImageNet vortrainierte YOLO-Modellvariante ( $n$ ,  $m$  bzw.  $l$ ) von Ultralytics geladen<sup>8</sup>. Der Modellparameter `model.nc` wurde auf 967 gesetzt und `model.names` wurde mit der Liste der zu unterscheidenden Gardiner-Codes besetzt. Für das Training wurde eine Batch Size von 128, eine initiale Lernrate von 0,01, der AdamW-Optimierer und ein `weight_decay` von 0,02 eingestellt. Die Lernrate reduziert sich beim Training per Default linear von der anfangs eingestellten Rate auf ein Hundertstel ihres Wertes bis zum Ende der letzten Epoche. Zunächst wurde ein Training mit der  $l$ -Version von YOLO über 15 Epochen durchgeführt (YOLO11l\_15\_01\_0001), wobei eine Top1- bzw. Top5-Genauigkeit von 95,1% bzw. 99,5% auf dem Test-Datensatz erreicht wurde. Bei weiteren Tests mit den schlankeren Modellen  $n$  und  $m$  hat sich herausgestellt, dass zunächst ein Training über 10 Epochen mit einer Lernrate von anfangs 0,01 bis schließlich 0,0001 die Metriken am besten optimiert. Zwischen Epoche 10 und 15 wurden dann unterschiedliche Settings für die Lernrate getestet. Abb. 5.10 zeigt die Trainingsverläufe bei einer stabilen Lernrate von 0,0001 für YOLO11n bzw. einer linear abnehmenden Lernrate von 0,0001 auf

<sup>8</sup><https://docs.ultralytics.com/models/yolo11/>, besucht am 04.03.2025

0,000001 für YOLO11m zwischen Epoche 10 und 15. YOLO11n\_15\_01\_0001 erreicht eine Top1- bzw. Top5-Genauigkeit von 96,2% bzw. 99,6%, YOLO11m\_15\_01\_000001 eine beeindruckende Top1- bzw. Top5-Genauigkeit von 97,0% bzw. 99,9%. Vermutlich würde die  $l$ - oder  $x$ -Variante von YOLO11 bei einem analogen Trainingsmodus mit dem Zwischenstopp bei Epoche 10 noch leicht verbesserte Werte für die Top1-Genauigkeit liefern, jedoch wurden hierzu aus Zeit- und Kostengründen keine weiteren Experimente durchgeführt.



**Abbildung 5.10:** Entwicklung des gesamten Loss, der Top1- und Top5-Genauigkeit im Verlauf der 15 Epochen bei Verwendung der Varianten  $n$ ,  $m$  bzw.  $l$  von YOLO11. Für die final gewählte Modellvariante YOLO11m (YOLO11m\_15\_01\_000001) sind die Genauigkeitswerte pro Epoche explizit angegeben.

Die Trainings wurden aufgrund sich kaum mehr ändernder Metriken nach der 15 Epoche nicht mehr fortgeführt. Insgesamt sind die Resultate des Modelltrainings im Hinblick auf die Problemstellung der Differenzierung zwischen etwa 1000 Klassen sehr zufriedenstellend. Das Modell YOLO11m\_15\_01\_000001 wurde aufgrund der besten Performance für alle Folgeexperimente ausgewählt. Die Modelldatei YOLO11m\_15\_01\_000001.pt ist in Github zu finden zusammen mit den Daten zum Verlauf

---

des Modelltrainings und den automatisch ermittelten Evaluationsergebnissen, die in der Datei `YOLO11m_15_01_000001.txt` dokumentiert sind. Die Modellgröße von etwa 22 MB ist im Vergleich zum YOLO11n-Modell aus Kapitel 5.2 schon deutlich schwererwichtiger.

Die Vorhersageergebnisse je Klasse wurden aus der Evaluation des Testdatensatzes als Konfusionsmatrix extrahiert.<sup>9</sup> Die tatsächlichen Klassen sind in der ersten Spalte aufgetragen und die Klassen der jeweiligen Vorhersagen entsprechen den Spaltenbezeichnungen, die zu einem bestimmten Wert in der Zeile der tatsächlichen Klasse gehören. Bspw. gab es im Testdatensatz 68 Patches zur Klasse A11, davon wurde ein Patch als A1 und 67 als A11 vorhergesagt. Da die Konfusionsmatrix etwa die Dimension 1000 x 1000 besitzt, gibt es keine übersichtliche Möglichkeit, diese abzubilden. Stattdessen wurde pro Klasse die Genauigkeit berechnet als Quotient des Diagonaleintrags (richtige Vorhersage) und der Zeilensumme in der jeweiligen Zeile. In Anhang G sind alle Codes aufgelistet, für die keine Genauigkeit von 100% erreicht wurde.<sup>10</sup> Pro Code ist die Summe an Beispielen im Trainingsdatensatz für den Klassifikator sowie der Häufigkeitsrang der Hieroglyphe im Datensatz vor der Data Augmentation angegeben. Außerdem wurde berechnet, welcher Anteil der falsch negativen Vorhersagen auf eine andere Klasse in der gleichen Gardiner-Gruppe entfiel („Gl. Gr.“) und welchen Anteil falsche Vorhersagen aus anderen Gardiner-Gruppen ausmachten („And. Gr.“). Bspw. wurde für die sehr häufige Hieroglyphe  (G17) eine Genauigkeit von 77,8% erreicht. Die übrigen Vorhersagen sind zu 100% in der Gardiner-Gruppe G gelandet. Sie wurden als  (G18) klassifiziert.  (M23), das die schlechteste Klassifikationsrate in der Tabelle aufweist, wurde ebenfalls nur mit dem Nachbar  (M22a) verwechselt. Dagegen wurde  (Z11) stets als Hieroglyphen aus anderen Gardiner-Gruppen klassifiziert: dreimal zu  (N37a) und zweimal zu  (Aa32). Insgesamt kann man feststellen, dass Fehlklassifikation in etwa gleichverteilt über alle Häufigkeitsstufen hinweg auftritt. Zudem liegen die falschen Vorhersagen annähernd zu gleichen Teilen in derselben bzw. einer anderen Gardiner-Gruppe, was bei 26 Gardiner-Gruppen bedeutet, dass die Vorhersage überproportional häufig auf ähnliche Hieroglyphen aus derselben Gruppe abzielt. Auch dies unterstreicht die Qualität des Klassifikators.

## 5.5 Gesamter Einleseprozess

Alle oben beschriebenen Teilschritte sind im Python Notebook `HieroglypheToGardiner_Git.ipynb` zusammengefasst. Bei der Ausführung dieses Notebooks werden im ersten Schritt alle benötigten Pakete installiert (v.a. Detectron2, YOLO). Die Installation von Detectron2 ist auf die Google-Colab-Umgebung ausgelegt. Falls die erste Codezeile in einer anderen Umgebung nicht ausführbar ist, so muss Detectron2 per Anleitung der Homepage installiert werden.<sup>11</sup> Danach werden die eigens trainierten Modelle importiert. Zuerst wird das Detectron2-Modell `segm_4000_512_01.pth` für die Segmentierung

---

<sup>9</sup>`confusion_matrix_YOLO11m_15_01_000001.xlsx`

<sup>10</sup>Die Ergebnisse sind auch in der Datei `Fehlklassifikationen.xlsx` zu finden.

<sup>11</sup><https://detectron2.readthedocs.io/en/latest/tutorials/install.html>, besucht am 29.03.2025



---

mit der in Kapitel 5.1 beschriebenen Konfiguration geladen. Da das Modell in Github LFS gespeichert wurde und zu groß ist, um direkt importiert zu werden, muss es zuerst lokal gespeichert werden. Dazu muss der lokale Pfad `save_path` entsprechend angepasst werden. Der Konfidenz- bzw. der NMS-Threshold ist mit 0,75 bzw. 0,3 initialisiert und kann je nach Bedarf angepasst werden. Danach werden die YOLO-Modelle `YOLO11n_Leserichtung.pt` und `YOLO11m_15_01_000001.pt` geladen. Anschließend wird ein Beispielbild aus Github importiert. Es können JPG- oder PNG-Bilder verarbeitet werden. Es folgt ein Abschnitt, in dem der gesamte Einleseprozess in Einzelschritten für ein genaueres Tracking der Zwischenergebnisse (und Fehlerquellen) ausgeführt wird.

Als Erstes ermittelt der Detectron2-Segmentierer alle Hieroglyphen im Bild. Dann wird mithilfe von `YOLO11n_Leserichtung.pt` die Links-Rechts-Leserichtung, die im Flag `direction` gespeichert wird, bestimmt. Da die Erkennung der Leserichtung entscheidend für die richtige Sequenzierung ist, wurde noch eine Validierung durch den User eingebaut. Der User bestätigt mit „Y“ die Richtung oder verneint mit „N“. Im letzteren Fall wird `direction` automatisch der gegenteilige Wert zugeordnet. Beim Test der 46 Beispiele des Datensatzes aus Kapitel 4.5 wurde die Links-Rechts-Leserichtung bei 41 Ausschnitten korrekt vorhergesagt, was einer Trefferquote von 89% entspricht. Im nächsten Schritt wird wie in Kapitel 5.3 beschrieben die Ausrichtung der Hieroglyphen bestimmt und die Bounding Boxen werden sequenziert. Falls die Erkennung der Zeilen- oder Spaltentrenner nicht wie erwartet klappt, weil z.B. Beschädigungen der Inschrift in den trennenden Bereichen fälschlicherweise als Zeichen erkannt werden, so muss das Bild im Vorfeld entsprechend manuell retuschiert werden. Zum Zweck der Klassifikation der sequenzierten Patches wird das YOLO-Modell `YOLO11m_15_01_000001.pt` der Reihe nach auf die bereits sortierte Liste der Hieroglyphen-Ausschnitte angewendet. Als Ergebnis für den maschinellen Einleseprozess des Beispiels aus Abb. 5.9 ergibt sich folgende Gardiner-Sequenz:


P5, I14 (N35), D21, M13 (Z1), G25, O48 (Aa1), Y1a, N35, E31, D35, N35, Z1 (-), U13 (U19), W24, G43, G17, G36, D21, F46a (D46), X1, A7, T28, D21, S29, M18 (M17), G43, M17, X8, M17, U36 (W14), X1, G43, I14 (N35), N35, X1, Z4, G17, S36, X1, Z1, M17, A51, S29, S29, M17, G17

Klassifikations-Korrekturen inkl. der Top5-Klassenwahrscheinlichkeiten:

- N35 (𐀎) statt I14 (𐀓): I14 0.95, N35 0.05, M33 0.00, Z9 0.00, E17 0.00
- Z1 (𐀓) statt M13 (𐀓): M13 0.55, Z1 0.27, O29a 0.03, S40 0.03, U28 0.02
- Aa1 (𐀓) statt O48 (𐀓): O48 0.99, Aa1 0.01, O50 0.00, O49 0.00, D25 0.00
- U19 (𐀓) statt U13 (𐀓): U13 0.66, F13 0.10, U21 0.05, E9a 0.03, F19 0.02
- D46 (𐀓) statt F46a (𐀓): F46a 0.50, M11 0.27, V13 0.16, F18 0.03, Y5 0.01

- M17 (𐎎) statt M18 (𐎎): M18 0.57, M17 0.38, Aa20 0.03, W25 0.01, R11 0.00
- W14 (𐎎) statt U36 (𐎎): U36 0.35, S33 0.33, A53 0.18, Aa30 0.05, V18 0.03
- N35 (𐎎) statt I14 (𐎎): I14 0.63, N35 0.37, N25 0.00, M33 0.00, Z9 0.00

Bei fünf der acht Fehlklassifikationen ist der richtige Code auf dem zweiten Platz der Top5. Bei den anderen drei Fällen kommt der richtige Code nicht unter den Top5 vor.



**Abbildung 5.11:** Fortsetzung des Beispiels aus Abb. 5.8 mit den vorhergesagten Klassenlabels der Bounding Boxes als Feedback.

Die Klassen werden als Labels in die Bounding Boxes geschrieben, damit der Nutzer die Ergebnissequenz auch direkt im Bild nachvollziehen kann, siehe Abb. 5.11. Statt der oben beschriebenen, separaten Ausführung der Einzelschritte kann im Abschnitt *Gesamtprozess in einem Schritt* des Python Notebooks das Ergebnis der maschinellen Verarbeitung auch mit nur einem Klick und einer Auswahl an relevanten Zwischenergebnissen in der Ausgabe erhalten werden.

Für alle 46 Textbeispiele des Datensatzes aus Kapitel 4.5 wurde mit dem oben beschriebenen Verfahren eine Gardinersequenz bestimmt und mit der tatsächlichen Sequenz in der Datei `Datensatz_Gesamtprozess.csv` verglichen. Als Maß für die Unterschiedlichkeit der beiden Sequenzen wurde die Distanzfunktion von Levenshtein (1965) verwendet. Die Levenshtein-Distanz gibt für zwei Zeichenketten an, wie viele Einfüge-, Löscho- und Ersetzungs-Operationen mindestens benötigt werden, um eine Zeichenkette in die zweite zu überführen. Im Falle der Gardiner-Sequenzen wurden die Gardiner-Codes als eigenständige Symbole behandelt anstatt zeichenweise verglichen zu werden. So werden in Beispiel oben M18 und M17 bzw. I14 und N35 als komplett unterschiedliche Symbole behandelt, für die jeweils eine Ersetzung veranschlagt wird, ungeachtet einer möglicherweise gleichen Gardiner-Gruppen-Zugehörigkeit, da auch benachbarte Symbole in der gleichen Gardiner-Gruppe komplett verschieden aussehen können. Für das oben im Detail analysierte Beispiel ergibt sich daher eine Levenshtein-Distanz von

---

9 bei einer tatsächlichen Sequenzlänge von 45, sodass man sagen könnte, dass nur 20% der Sequenz zu korrigieren sind.

Für eine möglichst optimale Einstellung des Detectron2-Segmentierers wurden der Konfidenz- sowie NMS-Threshold variiert und anschließend die Summe der Levenshtein-Distanzen über alle Beispiele berechnet. Die geringste Gesamtdistanz wurde bei einem Konfidenz-Threshold von 0,75 erreicht. Bei höheren Werten wurden vermehrt Hieroglyphen nicht erkannt und bei geringeren Werten wurden zu viele Objekte erkannt, die keine Hieroglyphen waren, oder einzelne Bereiche einer Hieroglyphe erhielten vermehrt eigene Bounding Boxen, was verstärkt zu Duplikaten führte. Für den NMS-Threshold wurde 0,3 als guter Kompromiss bestimmt. Bei höheren Werten wurden zunehmend mehr Boxen für die gleiche Hieroglyphe angesetzt, da eine höhere IoU erreicht werden muss, bevor Duplikate herausgefiltert werden. Mit diesen Einstellungen ergab sich über alle Textausschnitte hinweg eine Gesamtsumme vom 2108 Distanzpunkten bei einer Gesamtlänge der tatsächlichen Gardiner-Sequenzen von 4935 Codes, was einem durchschnittlichen Korrekturbedarf von etwa 40% bei einer der Testsequenzen entspricht.

In Anhang H sind 12 Texte im Detail ausgewertet: zwei handschriftliche, zwei font-generierte und acht gemeißelte Inschriften. Bei den handschriftlichen Beispielen von Sethe (1909) wird häufig  (I9) aufgrund der unpräzisen handschriftlichen Darstellung fehlklassifiziert.  (N5) wird aufgrund des fehlenden Mittelpunktes verständlicherweise als  (D12) und  (Aa1) wegen der unüblichen senkrechten Striche im Inneren als  (O48) oder  (O49) erkannt.  (N35) wird häufig für  (I14) gehalten, vermutlich wegen der eher abgerundeten Ecken in der Handschrift. Bei den Beispielen mit gedruckter Font-Schrift fällt auf, dass einige sehr häufige und einfache Hieroglyphen wie  (D36) oder  (V31) mit anderen häufigen Zeichen wie  (I9) oder  (V30) verwechselt werden. Außerdem werden bei den Font-Beispielen auffallend häufig Pluralvarianten wie  (Z2) oder  (N35a) in die Einzelteile segmentiert und letztlich als Mehrfachschreibungen der Einzelsymbole ausgegeben, was in der Gardiner-Sequenz gleich als mehrfacher Fehler gewertet wird. In Beispiel H.4 sind 6 von 42 Punkten der Levenshtein-Distanz allein auf die zweifache Fehlsegmentierung von  zurückzuführen. Bei den gemeißelten Realbeispielen hängt das Ergebnis stark von der Auflösung der Abbildung, von der Belichtung des Bildes sowie vom Zustand der Steintafel ab. Ein besseres Ergebnis wird bei Inschriften geliefert, bei denen das Bild vorverarbeitet und der Hintergrund z.B. wegreduziert wurde, wie `SteleNebipusenwosret_gezeichnet.jpg` (H.10). Auch der Detailgrad der Meißelung ist entscheidend. So wird  (N5) aufgrund des fehlenden Mittelpunktes meist als  (N33) und  (V31) als  (V30) klassifiziert. Bei der Analyse aller Beispiele zeigte sich zudem, dass für die Zählzeichen alle Varianten von  (Z1) in die Datensätze aufgenommen werden sollten, da sonst Zahlen wie „9“ in `SteleAntef_Teil1.jpg` in Einzelteilen erkannt werden, die dann relativ stark zum Gesamtfehler beitragen. Eine detaillierte Aufstellung über die Analyseergebnisse aller 46 Textausschnitte ist in der Excel-Datei `Gesamtprozess_Auswertung_075_03.xlsx` bereitgestellt. Die verarbeiteten Bilder zu diesen Inschriften sind mit gelabelten Bounding Boxen im Ordner `Eingelesene_Bilder_075_03_Labels` hinterlegt.

Insgesamt zeigt der implementierte Prozess des Einlesens hieroglyphischer Inschrif-

---

ten bei einer guten Bildqualität eine solide Gesamtleistung, was besonders am Beispiel `SteleQemnen_Ausschnitt.jpg` gut nachvollziehbar ist (H.11). In diesem Textausschnitt sind viele sehr kleine Zeichen korrekt segmentiert und klassifiziert worden. Durch die eng gedrängte Schreibung der Hieroglyphen ist die Ermittlung der korrekten Sequenz für den deterministischen Algorithmus besonders herausfordernd, sodass es gerade in diesem Testbeispiel zu mehreren Vertauschungen kommt. Zusammengenommen kann man bei der Analyse der 12 detailliert ausgewerteten Beispiele grob überschlagen, dass etwa 70% der Levenshtein-Punkte auf eine Fehlklassifikation und die übrigen 30% auf eine falsche Segmentierung und (seltener) auf eine vertauschte Code-Reihenfolgen zurückzuführen sind. Die Segmentierungsfehler hinsichtlich des „Übersehens“ von Zeichen könnte man durch eine verbesserte Bildqualität, die man z.B. durch eine entsprechende Vorprozessierung erreichen könnte, reduzieren. Bei Mehrfacherkennungen hinsichtlich Hieroglyphen, die aus mehreren Einzelteilen bestehen, muss der Segmentierer noch besser feinabgestimmt werden. Für den Klassifikator müssten die Trainingsdaten offensichtlich noch variantenreicher gestaltet werden, damit dieser die relevanten Merkmale pro Hieroglyphe besser extrahieren kann. Dennoch zeigt die Verwendung von Font-generierten Abbildungen beim Training gerade für seltene Zeichen, für die nur wenige Realbeispiele verfügbar waren, einen sehr positiven Effekt, da extrem seltene Zeichen nicht überproportional häufiger fehlerklassifiziert wurden (vgl. Auswertung in Kapitel 5.4).

## 5.6 Übersetzungsvergleiche

Mithilfe der bereits in Kapitel 3.11 vorgestellten Anwendung von De Cao et al. (2024) zur Übersetzung von Sequenzen von Transkriptionstext bzw. Gardiner-Code nach Deutsch/Englisch wurde noch getestet, wie robust die Übersetzung bei Anwendung der vorhergesagten Gardiner-Sequenz aus dem gesamten maschinellen Einleseprozess aus Kapitel 5.5 ist. In den folgenden Beispielen wird jeweils die tatsächliche Übersetzung (TÜ) eines hieroglyphischen Texts mit denjenigen verglichen, die bei Anwendung des Tools auf die tatsächliche (TG) sowie vorhergesagte Gardiner-Sequenz (VG) erhalten werden (Ergebnisse der jeweiligen Übersetzung: TGÜ bzw. VGÜ). Pro Durchlauf wurden nur Textausschnitte aus ein bis zwei Sätzen verwendet, da die Anwendung von De Cao et al. (2024) laut den Autoren nicht mehr gut auf längeren Texten arbeitet. Als Zielsprache für die Übersetzungen wurde jeweils zum Zweck einer besseren Vergleichbarkeit diejenige der tatsächlichen Übersetzung gewählt.

### 1. Beispiel:

*Quelle:* Die Geschichte des Schiffbrüchigen, vgl. Anhang H.4

*TÜ:* „Höre mir zu, Fürst!“

*TG:* F21 G17 D21 V31 N35 A1 F4 D36 A1

*TGÜ:* „Höre auf mich, Fürst!“

*VG:* F21 G17 D21 V30 N35 A1 F4 T1 A1

---

VGÜ: „Ein Gehorchender ist mein Herz.“

*Kommentar:* TÜ und TGÜ sind nahe beieinander. Der Austausch des Pronomens  $\supset$  (V31) „du“ gegen das Substantiv  $\supset$  (V30) „Herr“ ändert das Subjekt des Satzes und der Tausch von  $\supset$  (D36) gegen  $\supset$  (T1) leitet die Übersetzung komplett fehl.

2. Beispiel:

*Quelle:* Die Geschichte des Schiffbrüchigen, vgl. Anhang H.4

TÜ: „Ich bin einer, der nicht übertreibt (lit. der frei ist von Übertreibung).“

TG: W24 V31 A1 H6 Z7 G37 M16 G1 G43 Y2 Z2

TGÜ: „Ich bin einer, der ohne Zorn ist.“

VG: W24 V30 A1 M17 Z7 G37 M16 G1 G43 D46 S28

VGÜ: „Meine Herren waren schwach.“

*Kommentar:* TÜ und TGÜ zeigen bereits Unterschiede in den Relativsätzen. Der Austausch von V31 gegen V30 ändert analog zu Beispiel 1 das Subjekt des Satzes und drei fehlerhafte Codes verändern das Prädikat des Satzes, sodass TÜ und TGÜ nicht mehr vergleichbar sind.

3. Beispiel:

*Quelle:* Stele des Nebipusenwosret, vgl. Anhang H.10

TÜ: „he may see the beauty of Wepwawet in his beautiful procession“

TG: U1 D4 I9 F35 F35 F35 F13 N31 X1 Z2 E18 G17 01 D21 X1 D54 I9 F35 D21 X1

TGÜ: „May he see the beauty of Wepwawet at his beautiful procession.“

VG: U2 D4 I9 F35 F35 F35 F13 N31 I9 Z2 E19 G17 01 D21 X1 D54 <> I9 D21 F35 I9

VGÜ: „May he see the beauty of his upuaut in his procession.“

*Kommentar:* TÜ und TGÜ sind äquivalent. Der Austausch der Wortendung  $\supset$  (X1) gegen das Possessivpronomen  $\supset$  (I9) ändert leicht den Sinn des Satzes bzgl. des Gottes Wepwawet (= Upuaut). Die Vertauschung von F35 und D21 beeinflusst die Übersetzung nicht.

4. Beispiel:

*Quelle:* Stele des Qemnen, vgl. Anhang H.11

TÜ: „Möge er das Firmament durchqueren. Möge er den Himmel durchfahren.“

TG: U28 G1 P1 I9 D58 N42 N21 N35 T34 G17 D54 I9 Q3 X1 N1

TGÜ: „Möge er die Balsamierungsstätte überqueren, wenn er den Himmel durchzieht.“

---

VG: U29 G1 P1 I9 D58 N42 N35 Aa14 R8 G17 D54 I9 Q3 N1 X1

VGÜ: „Möge er aufsteigen, möge der Gott seinen Himmel durchziehen.“

*Kommentar:* TÜ und TGÜ unterscheiden sich im Objekt ihres ersten Satzes. Der zweite Satz ist bei TÜ eigenständig und bei TGÜ ein Adverbialsatz, was als äquivalent gesehen werden kann. Der Austausch dreier Codes in der Mitte der Sequenz (insbesondere die Einführung des Substantivs ¶ (R8) „Gott“) verändert den Sinn der Übersetzung bereits stark.

#### 5. Beispiel:

*Quelle:* Stele des Maati, vgl. Anhang H.5

TÜ: „an invocation offering (of) a thousand of bread and beer, a thousand of bulls and birds, a thousand of alabaster and linen, a thousand of all good and pure things, pure bread from the estate “

TG: 03 M12 X2 W22 M12 F1a H1 M12 V33 S115 M12 Aa1 X1 V30 F35 D60 X1 X2 D60 N35 01 Z1

TGÜ: „A mortal sacrifice a thousand of bread, beer, pockets, birds, gins, alabaster, linen, each good and pure thing, pure bread of the house.“

VG: 03 M17 S29 F35 M12 X2 W22 M12 F1 H1 M12 F34 S27 M12 N33 X1 V30 F35 D60 X1 A40 D60 S29 N35 01 Z1

VGÜ: „A mortal sacrifice a good thing, a thousand of bread and beer, a hundred of birds and birds, a Hundred of jb-heart and a Thousand of Clothes, a every good and pure thing from which a house is cleaned.“

*Kommentar:* TÜ und TGÜ unterscheiden sich lediglich etwas in der Aufzählung der Dinge sowie einzelnen Begriffen. Trotz der zahlreichen Abweichungen zwischen TG und VG bleibt VGÜ überraschend stabil bzgl. des Inhalts.

Weitere Übersetzungsvergleiche sind in der Excel-Datei **Übersetzungen.xlsx** zu finden. Bei der Betrachtung von Beispiel 1 und 2 sieht man bereits gut, dass das Übersetzungstool sogar auf korrekten Gardiner-Sequenzen keine akkuraten Ergebnisse liefert. Wenn dann noch einzelne Gardiner-Codes in der vorhergesagten Sequenz nicht richtig ermittelt und stattdessen durch sinnverändernde Codes ersetzt wurden, dann ist verständlich, dass die Verkettung von fehlerbehafteten Prozessen zu stark deformierten Übersetzungsergebnissen führt. Bei der Analyse anderer Textausschnitte wie Beispiel 3 oder (weitestgehend) Beispiel 5 bleibt der Sinn der Übersetzung relativ gut erhalten, trotz zahlreicher Code-Unterschiede. Für eine verlässliche und akzeptable Übersetzung muss daher jeder der Prozessschritte - einschließlich des Übersetzers - noch weiter optimiert werden, um eine Fehlerfortpflanzung möglichst zu begrenzen. Im Notebook **HieroglypheToGardiner\_Git.ipynb** kann nach dem Einlesen der Gardiner-Sequenz einer hieroglyphischen Inschrift noch im Anschluß optional eine Übersetzung wie oben generiert werden. Diese sollte vom Laien aber nur mit äußerster Skepsis betrachtet werden, da die Übersetzungsvergleiche zeigen, dass die Ergebnisse meist nur grob den eigentlichen Inhalt oder Kontext wiedergeben.

# Kapitel 6

## Zusammenfassung und Ausblick

### 6.1 Zusammenfassung

Im Rahmen der vorliegenden Arbeit wurden die Anforderungen des maschinellen Einlesens hieroglyphischer Inschriften im Detail analysiert. Zunächst wurde für den Laien auf dem Gebiet der Ägyptologie und insbesondere der ägyptischen Hieroglyphenschrift ein Überblick über die grundlegenden Eigenschaften der hieroglyphischen Schriftsprache zusammengestellt, damit die technischen Entscheidungen bzgl. der Datensammlung und der Implementierung nachvollziehbar sind. Anschließend wurde eine ausführliche Analyse hinsichtlich des Stands der Forschung zum Thema der maschinellen Erkennung von Hieroglyphen sowie deren maschineller Übersetzung durchgeführt. Der tabellarische Vergleich der wenigen bisher veröffentlichten Arbeiten in Kapitel 3.12 zeigt unterschiedliche Herangehensweisen bei der maschinellen Verarbeitung von Inschriften, die sich meist nur auf Teilaspekte des Problems fokussieren. Es fehlte bisher ein allgemein anwendbarer Ansatz, der beliebige Abbildungen von Hieroglyphentext in maschinenlesbare Repräsentationen transformiert. Besonders der Aspekt der Sequenzierung der Zeichen wurde in den existierenden Publikationen nicht umfassend bearbeitet. Außerdem war zu den Publikationen in den seltensten Fällen überhaupt (lauffähiger) Programmiercode veröffentlicht. Auf Basis der Literaturrecherche wurde daher ein Verfahren implementiert, mit dessen Hilfe beliebige Abbildungen hieroglyphischer Inschriften in eine maschinenlesbare Sequenz des Gardiner-Codes umgewandelt werden können. Dabei werden die Hieroglyphen zuerst vom Hintergrund segmentiert, dann nach Klassifikation der Links-Rechts-Leserichtung und Ermittlung der Zeilen-Spalten-Anordnung in die korrekte Reihenfolge sortiert und schließlich nach Gardiner-Code klassifiziert. Obwohl jeder der Teilschritte für sich zufriedenstellende Ergebnisse lieferte, zeigten Vergleiche von vom Programm ausgegebenen Gardiner-Sequenzen mit den tatsächlichen Sequenzen, dass künftig jeder Teilprozess weiter verfeinert werden muss, da die Verkettung der Einzelmethode noch immer zu einer zu großen Gesamtfehlerrate führt. Trotz der verbesserungsfähigen Implementierung des Einleseprozesses war die Verwendung der entwickelten Anwendung im Zuge der Datensammlung bereits eine erhebliche Arbeitserleichterung bei der Bestimmung der Gardiner-Sequenzen für längere Hieroglyphentexte, die noch nicht „digitalisiert“ vorlagen. So dauerte es nur etwa fünf Minuten, die maschinelle Ausgabe für das Bild `SetheIII_S887mitte.jpg`, für das keine Gardiner-Sequenz in der Literatur auffindbar war, zu überprüfen und an einigen Stellen zu korrigieren. Gerade seltenere Zeichen,



---

für die man den Gardiner-Code mühselig nachschlagen müsste, werden erfreulicherweise relativ gut erkannt oder es wird bereits die richtige Gardiner-Gruppe vorhergesagt, aus der dann nur noch der korrekte Code ausgewählt werden muss. Schließlich wurde das eigens zusammengestellte Programm noch um das bisher am besten funktionierende Übersetzer-Tool aus der Literatur ergänzt, sodass insgesamt sogar nicht nur die Aufgabe „Vom Bild zu maschinenlesbarem Text“ zufriedenstellend gelöst, sondern auch das Problem „Vom Bild zur Übersetzung“ angerissen wurde. Experimente zum letzteren Gesamtansatz zeigten, dass der Teilschritt der Übersetzung jedoch für eine praktische Relevanz noch erheblich optimiert werden muss.


## 6.2 Ausblick

Das in der vorliegenden Arbeit entwickelte Verfahren setzt noch eine gewisse Beschaffenheit des Input-Bildes voraus. So können verdrehte Aufnahmen noch nicht korrekt verarbeitet werden und die Anwendung ist vor allem darauf angewiesen, dass auf der Abbildung möglichst nur Hieroglyphentext vorkommt und eine einheitliche Leserichtung gegeben ist. Zahlreiche Schriftzeugnisse zeigen jedoch neben Textpassagen auch Bildbereiche ohne Textmaterial oder - je nach Komposition des Texts - gemischte Leserichtungen. Für solche komplexeren Inputs müssen ebenfalls fachlich korrekte und benutzerfreundliche Lösungen gefunden werden.

Neben einer weiteren Verfeinerung der einzelnen Teilschritte des maschinellen Einlesens hieroglyphischer Texte könnte in künftigen Arbeiten auch ein Fokus auf leichtgewichtiger Modelle gelegt werden, um die Anwendung für mobile Endgeräte zu optimieren. YOLO11n-Klassifikatoren sind mit einer Größe von ca. 3 MB bereits sehr gut dafür geeignet. Der YOLO11m-Klassifikator, der für die Bestimmung der Gardiner-Codes genutzt wurde und etwa 22 MB Speicher benötigt, kann durch ein optimiertes Training sicherlich auf die *s*- oder sogar *n*-Variante reduziert werden. Dagegen wäre der Detectron2-Objekterkennungsalgorithmus für die Segmentierung mit 168 MB noch nicht für mobile (Online-)Anwendungen geeignet. Alternativ könnten auch für diesen Teilprozess YOLO-Modellvarianten getestet werden, was aus Zeitgründen im Rahmen dieser Arbeit nicht mehr möglich war. Letztlich sind zahlreiche praktische Anwendungen für das zusammengestellte Verfahren denkbar, wie beispielsweise eine Hieroglyphenerkennung per Smartphone-App sowohl für den Experten als auch für den Laien. Die visuelle Darstellung kann - sobald die Algorithmen auf Echtzeitverarbeitung hin optimiert wurden - sogar in Form von Augmented Reality erfolgen. Beim Führen der Smartphone-Kamera über die Inschrift oder bei der Verwendung einer AR-Brille könnten die Hieroglyphen in Echtzeit gelabelt werden. Wird zudem noch ein verbesserter Übersetzer an den bestehenden Einleseprozess angefügt, so wäre sogar eine maschinelle Echtzeitübersetzung analog zur App *Google Übersetzer* denkbar.

Aus dem Blickwinkel der Ägyptologie sind weitere Features wünschenswert, um Hieroglyphentexte noch akkurater digital zu dokumentieren. So ist aus fachlicher Sicht nicht nur interessant, die erkannten Hieroglyphen als korrekte Sequenz bzgl. der Leserichtung, sondern auch deren exakte Anordnung zueinander zu speichern. Damit der digitalisierte

Hieroglyphentext mit einem entsprechenden Font in seiner originalen, ästhetisch ansprechenden Anordnung wiedergegeben werden kann, muss eine Anwendung zusätzlich in der Gardiner-Sequenz vermerken, welche Symbole über- oder nebeneinander gesetzt waren. Dies garantiert dann eine originalgetreue Dokumentation einer Inschrift in digitaler Form.



**Abbildung 6.1:** Anwendung der entwickelten Verfahren auf einen kursivhieroglyphischen Text (links) und ein hieratisches Beispiel (rechts).

Das entwickelte Verfahren arbeitet bereits gut auf Kursivhieroglyphen wie in Abb. 6.1 links. Die meisten Hieroglyphen werden zuverlässig erkannt, die Segmentierung zeigt lediglich die Schwächen analog zu den bereits bei den normalen Hieroglyphen auftretenden Problemen. Viele kursiv geschriebene Hieroglyphen werden sogar richtig klassifiziert. Eine Übertragung der Methodik auf andere Schriftsysteme im Alten Ägypten, vor allem das schwerer für den Menschen zu lesende Hieratisch und das noch erheblich schwerer lesbare Demotisch wäre eine große Herausforderung, aber auch ein echter Gewinn für die Fachwelt sowie den interessierten Nutzer, der mit einer derartig weiterentwickelten Methodik auch Texte wie das üblicherweise in Hieratisch geschriebene „Buch der Toten“ studieren könnte. Abb. 6.1 rechts zeigt die Auswertung eines hieratischen Ausschnitts ohne Boxlabeling. Die Objekterkennung gestaltet sich in diesem Beispiel durch langgezogene Ausläufer der Zeichen oder Ligaturen analog einer Schreibschrift bereits deutlich komplexer. Sich daraus ergebende Abweichungen von der klar abgegrenzten Zeilen- bzw. Spaltenanordnung lassen die Trennung in Teillisten versagen. Auch die Klassifikation dürfte sich aufgrund der weniger markanten Zeichenformen deutlich schwerer gestalten.

Die maschinelle Verarbeitung antiker ägyptischer Texte befindet sich insgesamt ge-





---








sehen also noch in der Anfangsphase ihrer Entwicklung und es bleibt abzuwarten, ob und wann KI-Technologien den menschlichen Experten bei der Fähigkeit des Lesens und Übersetzens ägyptischer Texte überholen werden.

# **Appendix**





# A Kurzfassung der Gardinerliste, Original aus Gardiner (1957)











**Sect. P. SHIPS AND PARTS OF SHIPS**  1 (1) 2 3 4 5 6 7 8 9 10 11


**Sect. Q. DOMESTIC AND FUNERARY FURNITURE**  1 2 3 4 5 6 7

**Sect. R. TEMPLE FURNITURE AND SACRED EMBLEMS**  1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25

**Sect. S. CROWNS, DRESS, STAVES, ETC.**  1 2 3 4 5 6 7 8 9 10 11 12 13 14 14\* 15 16 17 18 19 20 21 22 17\* 23 24 25 26 (N 18) 27 28 29 30 31 32 33 34 (V 39) 35 36 37 38 39 40 41 42 43 44 45

**Sect. T. WARFARE, HUNTING, BUTCHERY**  1 2 3 4 5 6 7 7\* 8 8\* 9 9\* 10 (Aa 32) 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35


**Sect. U. AGRICULTURE, CRAFTS, AND PROFESSIONS**  1 2 3 4 5 6 7 8 9 10 11 12 (O 30) 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 (Aa 23) (Aa 24) 36 37 38 39 40 41

**Sect. V. ROPE, FIBRE, BASKETS, BAGS, ETC.**  1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 31\* 32 33 34 35 36 37 38

**Sect. W. VESSELS OF STONE AND EARTHENWARE**




**Sect. X. LOAVES AND CAKES**




**Sect. Y. WRITINGS, GAMES, MUSIC**



**Sect. Z. STROKES, SIGNS DERIVED FROM HIERATIC, GEOMETRICAL FIGURES**



**Sect. Aa. UNCLASSIFIED**



## **B Häufigkeitsverteilung der 300 häufigsten Hieroglyphen**

Die beiden folgenden Tabellen zeigen die 300 häufigsten Hieroglyphen aus Wernings Zählung von insgesamt 1.734.445 Zeichen (Werning (2021)). Die Schriftzeichen sind absteigend nach ihrer Anzahl sortiert. Neben ihrer relativen Häufigkeit ist auch die erwartete Häufigkeit nach dem Zipfschen Gesetz angegeben.

| Rang | Gardiner-<br>code | Anzahl | Relative<br>Häufigkeit | Erw. Zipf-<br>Häufigkeit |
|------|-------------------|--------|------------------------|--------------------------|
| 1    | X001              | 136265 | 7,856%                 | 21,748%                  |
| 2    | N035              | 119349 | 6,881%                 | 9,466%                   |
| 3    | M017              | 87381  | 5,038%                 | 5,819%                   |
| 4    | D021              | 75849  | 4,373%                 | 4,121%                   |
| 5    | Z001              | 61714  | 3,558%                 | 3,153%                   |
| 6    | G017              | 52113  | 3,005%                 | 2,533%                   |
| 7    | I009              | 46123  | 2,659%                 | 2,105%                   |
| 8    | S029              | 39821  | 2,296%                 | 1,794%                   |
| 9    | Z007              | 39085  | 2,253%                 | 1,557%                   |
| 10   | Z002              | 36661  | 2,114%                 | 1,372%                   |
| 11   | Q003              | 34256  | 1,975%                 | 1,224%                   |
| 12   | G043              | 31609  | 1,822%                 | 1,103%                   |
| 13   | D036              | 30936  | 1,784%                 | 1,002%                   |
| 14   | G001              | 28405  | 1,638%                 | 0,916%                   |
| 15   | V031              | 26622  | 1,535%                 | 0,844%                   |
| 16   | AA001             | 25398  | 1,464%                 | 0,781%                   |
| 17   | Y001              | 21423  | 1,235%                 | 0,726%                   |
| 18   | V028              | 18625  | 1,074%                 | 0,678%                   |
| 19   | D046              | 18030  | 1,040%                 | 0,635%                   |
| 20   | A001              | 17800  | 1,026%                 | 0,597%                   |
| 21   | N005              | 17796  | 1,026%                 | 0,563%                   |
| 22   | O034              | 16838  | 0,971%                 | 0,533%                   |
| 23   | W024              | 16782  | 0,968%                 | 0,505%                   |
| 24   | D058              | 15489  | 0,893%                 | 0,480%                   |
| 25   | D004              | 15224  | 0,878%                 | 0,457%                   |
| 26   | G007              | 15091  | 0,870%                 | 0,436%                   |
| 27   | D002              | 14893  | 0,859%                 | 0,417%                   |
| 28   | V011A             | 13940  | 0,804%                 | 0,399%                   |
| 29   | Z004              | 13775  | 0,794%                 | 0,382%                   |
| 30   | V030              | 13500  | 0,778%                 | 0,367%                   |
| 31   | I010              | 13174  | 0,760%                 | 0,353%                   |
| 32   | O001              | 13103  | 0,755%                 | 0,340%                   |
| 33   | V011B             | 12897  | 0,744%                 | 0,327%                   |
| 34   | R008              | 12876  | 0,742%                 | 0,316%                   |
| 35   | D054              | 12588  | 0,726%                 | 0,305%                   |
| 36   | V031A             | 9637   | 0,556%                 | 0,295%                   |
| 37   | A002              | 9550   | 0,551%                 | 0,285%                   |
| 38   | M023              | 8774   | 0,506%                 | 0,276%                   |
| 39   | AA015             | 8394   | 0,484%                 | 0,268%                   |
| 40   | N037              | 8324   | 0,480%                 | 0,260%                   |
| 41   | Q001              | 7898   | 0,455%                 | 0,252%                   |
| 42   | O049              | 7843   | 0,452%                 | 0,245%                   |
| 43   | Z003A             | 7475   | 0,431%                 | 0,238%                   |
| 44   | F035              | 7220   | 0,416%                 | 0,232%                   |
| 45   | N029              | 7134   | 0,411%                 | 0,226%                   |
| 46   | V013              | 7070   | 0,408%                 | 0,220%                   |
| 47   | D035              | 6595   | 0,380%                 | 0,214%                   |
| 48   | S034              | 6297   | 0,363%                 | 0,209%                   |
| 49   | A024              | 6068   | 0,350%                 | 0,204%                   |
| 50   | O004              | 5961   | 0,344%                 | 0,199%                   |

| Rang | Gardiner-<br>code | Anzahl | Relative<br>Häufigkeit | Erw. Zipf-<br>Häufigkeit |
|------|-------------------|--------|------------------------|--------------------------|
| 51   | D028              | 5960   | 0,344%                 | 0,194%                   |
| 52   | G005              | 5649   | 0,326%                 | 0,190%                   |
| 53   | N033              | 5391   | 0,311%                 | 0,185%                   |
| 54   | G036              | 5317   | 0,307%                 | 0,181%                   |
| 55   | Y005              | 5315   | 0,306%                 | 0,177%                   |
| 56   | A040              | 5232   | 0,302%                 | 0,174%                   |
| 57   | D040              | 5189   | 0,299%                 | 0,170%                   |
| 58   | N001              | 4679   | 0,270%                 | 0,166%                   |
| 59   | E034              | 4657   | 0,269%                 | 0,163%                   |
| 60   | N017              | 4415   | 0,255%                 | 0,160%                   |
| 61   | F051              | 4319   | 0,249%                 | 0,157%                   |
| 62   | G037              | 4247   | 0,245%                 | 0,154%                   |
| 63   | F034              | 4130   | 0,238%                 | 0,151%                   |
| 64   | Z003              | 4120   | 0,238%                 | 0,148%                   |
| 65   | D037              | 4115   | 0,237%                 | 0,145%                   |
| 66   | H008              | 4068   | 0,235%                 | 0,143%                   |
| 67   | G041              | 4031   | 0,232%                 | 0,140%                   |
| 68   | N035A             | 3966   | 0,229%                 | 0,138%                   |
| 69   | N023              | 3933   | 0,227%                 | 0,135%                   |
| 70   | S043              | 3874   | 0,223%                 | 0,133%                   |
| 71   | B001              | 3855   | 0,222%                 | 0,131%                   |
| 72   | G039              | 3823   | 0,220%                 | 0,128%                   |
| 73   | R004              | 3751   | 0,216%                 | 0,126%                   |
| 74   | O029              | 3657   | 0,211%                 | 0,124%                   |
| 75   | Z009              | 3605   | 0,208%                 | 0,122%                   |
| 76   | N014              | 3588   | 0,207%                 | 0,120%                   |
| 77   | N016              | 3505   | 0,202%                 | 0,118%                   |
| 78   | D001              | 3454   | 0,199%                 | 0,117%                   |
| 79   | U033              | 3446   | 0,199%                 | 0,115%                   |
| 80   | W011              | 3400   | 0,196%                 | 0,113%                   |
| 81   | R008A             | 3363   | 0,194%                 | 0,111%                   |
| 82   | W019              | 3359   | 0,194%                 | 0,110%                   |
| 83   | U001              | 3139   | 0,181%                 | 0,108%                   |
| 84   | N025              | 3099   | 0,179%                 | 0,107%                   |
| 85   | AA011             | 2954   | 0,170%                 | 0,105%                   |
| 86   | Z005              | 2906   | 0,168%                 | 0,104%                   |
| 87   | U006              | 2879   | 0,166%                 | 0,102%                   |
| 88   | U028              | 2861   | 0,165%                 | 0,101%                   |
| 89   | Z011              | 2860   | 0,165%                 | 0,100%                   |
| 90   | X008              | 2834   | 0,163%                 | 0,098%                   |
| 91   | M012              | 2716   | 0,157%                 | 0,097%                   |
| 92   | U036              | 2615   | 0,151%                 | 0,096%                   |
| 93   | G025              | 2611   | 0,151%                 | 0,094%                   |
| 94   | L001              | 2546   | 0,147%                 | 0,093%                   |
| 95   | F031              | 2510   | 0,145%                 | 0,092%                   |
| 96   | M002              | 2493   | 0,144%                 | 0,091%                   |
| 97   | Z006              | 2445   | 0,141%                 | 0,090%                   |
| 98   | M003              | 2441   | 0,141%                 | 0,089%                   |
| 99   | AA002             | 2424   | 0,140%                 | 0,088%                   |
| 100  | H006              | 2355   | 0,136%                 | 0,087%                   |

| Rang | Gardiner-<br>code | Anzahl | Relative<br>Häufigkeit | Erw. Zipf-<br>Häufigkeit |
|------|-------------------|--------|------------------------|--------------------------|
| 101  | V004              | 2341   | 0,135%                 | 0,086%                   |
| 102  | N031              | 2327   | 0,134%                 | 0,085%                   |
| 103  | T028              | 2311   | 0,133%                 | 0,084%                   |
| 104  | G029              | 2226   | 0,128%                 | 0,083%                   |
| 105  | V020              | 2191   | 0,126%                 | 0,082%                   |
| 106  | N036              | 2183   | 0,126%                 | 0,081%                   |
| 107  | F018              | 2131   | 0,123%                 | 0,080%                   |
| 108  | F004              | 2119   | 0,122%                 | 0,079%                   |
| 109  | P006              | 2035   | 0,117%                 | 0,078%                   |
| 110  | W010              | 2026   | 0,117%                 | 0,077%                   |
| 111  | N021              | 2023   | 0,117%                 | 0,076%                   |
| 112  | P008              | 2015   | 0,116%                 | 0,076%                   |
| 113  | W022              | 1978   | 0,114%                 | 0,075%                   |
| 114  | T014              | 1971   | 0,114%                 | 0,074%                   |
| 115  | N033A             | 1939   | 0,112%                 | 0,073%                   |
| 116  | M018              | 1930   | 0,111%                 | 0,072%                   |
| 117  | F020              | 1929   | 0,111%                 | 0,072%                   |
| 118  | Q007              | 1920   | 0,111%                 | 0,071%                   |
| 119  | Z004A             | 1873   | 0,108%                 | 0,070%                   |
| 120  | D056              | 1854   | 0,107%                 | 0,070%                   |
| 121  | F032              | 1785   | 0,103%                 | 0,069%                   |
| 122  | M022              | 1735   | 0,100%                 | 0,068%                   |
| 123  | Z015C             | 1724   | 0,099%                 | 0,068%                   |
| 124  | U007              | 1718   | 0,099%                 | 0,067%                   |
| 125  | S042              | 1692   | 0,098%                 | 0,066%                   |
| 126  | O050              | 1667   | 0,096%                 | 0,066%                   |
| 127  | N026              | 1636   | 0,094%                 | 0,065%                   |
| 128  | W025              | 1617   | 0,093%                 | 0,064%                   |
| 129  | G040              | 1598   | 0,092%                 | 0,064%                   |
| 130  | T021              | 1571   | 0,091%                 | 0,063%                   |
| 131  | Z005A             | 1509   | 0,087%                 | 0,063%                   |
| 132  | G014              | 1478   | 0,085%                 | 0,062%                   |
| 133  | T022              | 1478   | 0,085%                 | 0,061%                   |
| 134  | U015              | 1460   | 0,084%                 | 0,061%                   |
| 135  | D052              | 1457   | 0,084%                 | 0,060%                   |
| 136  | N027              | 1436   | 0,083%                 | 0,060%                   |
| 137  | O031              | 1415   | 0,082%                 | 0,059%                   |
| 138  | M016              | 1388   | 0,080%                 | 0,059%                   |
| 139  | L002              | 1384   | 0,080%                 | 0,058%                   |
| 140  | V006              | 1368   | 0,079%                 | 0,058%                   |
| 141  | FF100             | 1357   | 0,078%                 | 0,057%                   |
| 142  | M036              | 1351   | 0,078%                 | 0,057%                   |
| 143  | T003              | 1331   | 0,077%                 | 0,056%                   |
| 144  | N042              | 1301   | 0,075%                 | 0,056%                   |
| 145  | AA027             | 1295   | 0,075%                 | 0,055%                   |
| 146  | Z015B             | 1294   | 0,075%                 | 0,055%                   |
| 147  | F013              | 1282   | 0,074%                 | 0,055%                   |
| 148  | Z015A             | 1278   | 0,074%                 | 0,054%                   |
| 149  | F051B             | 1274   | 0,073%                 | 0,054%                   |
| 150  | N041              | 1270   | 0,073%                 | 0,053%                   |



| Rang | Gardiner-<br>code | Anzahl | Relative<br>Häufigkeit | Erw. Zipf-<br>Häufigkeit |
|------|-------------------|--------|------------------------|--------------------------|
| 151  | F021              | 1251   | 0,072%                 | 0,053%                   |
| 152  | P001              | 1228   | 0,071%                 | 0,052%                   |
| 153  | G038              | 1217   | 0,070%                 | 0,052%                   |
| 154  | V022              | 1204   | 0,069%                 | 0,052%                   |
| 155  | N028              | 1199   | 0,069%                 | 0,051%                   |
| 156  | D012              | 1194   | 0,069%                 | 0,051%                   |
| 157  | R014              | 1171   | 0,068%                 | 0,050%                   |
| 158  | M004              | 1169   | 0,067%                 | 0,050%                   |
| 159  | Y002              | 1167   | 0,067%                 | 0,050%                   |
| 160  | Y003              | 1163   | 0,067%                 | 0,049%                   |
| 161  | V017              | 1163   | 0,067%                 | 0,049%                   |
| 162  | N018              | 1156   | 0,067%                 | 0,049%                   |
| 163  | U023              | 1155   | 0,067%                 | 0,048%                   |
| 164  | S003              | 1125   | 0,065%                 | 0,048%                   |
| 165  | W018              | 1109   | 0,064%                 | 0,047%                   |
| 166  | E001              | 1108   | 0,064%                 | 0,047%                   |
| 167  | A017              | 1108   | 0,064%                 | 0,047%                   |
| 168  | E023              | 1101   | 0,063%                 | 0,046%                   |
| 169  | D019              | 1088   | 0,063%                 | 0,046%                   |
| 170  | D050              | 1084   | 0,062%                 | 0,046%                   |
| 171  | D053              | 1053   | 0,061%                 | 0,045%                   |
| 172  | P008H             | 1051   | 0,061%                 | 0,045%                   |
| 173  | R011              | 1046   | 0,060%                 | 0,045%                   |
| 174  | O039              | 1040   | 0,060%                 | 0,045%                   |
| 175  | F039              | 1034   | 0,060%                 | 0,044%                   |
| 176  | X002              | 1018   | 0,059%                 | 0,044%                   |
| 177  | O006              | 1018   | 0,059%                 | 0,044%                   |
| 178  | G047              | 985    | 0,057%                 | 0,043%                   |
| 179  | Z014              | 978    | 0,056%                 | 0,043%                   |
| 180  | R015              | 977    | 0,056%                 | 0,043%                   |
| 181  | D041              | 972    | 0,056%                 | 0,042%                   |
| 182  | V012              | 947    | 0,055%                 | 0,042%                   |
| 183  | M008              | 946    | 0,055%                 | 0,042%                   |
| 184  | O029A             | 938    | 0,054%                 | 0,042%                   |
| 185  | X004              | 930    | 0,054%                 | 0,041%                   |
| 186  | U002              | 920    | 0,053%                 | 0,041%                   |
| 187  | U030              | 912    | 0,053%                 | 0,041%                   |
| 188  | G004              | 904    | 0,052%                 | 0,041%                   |
| 189  | A053              | 902    | 0,052%                 | 0,040%                   |
| 190  | T030              | 877    | 0,051%                 | 0,040%                   |
| 191  | F001A             | 868    | 0,050%                 | 0,040%                   |
| 192  | N040              | 863    | 0,050%                 | 0,040%                   |
| 193  | V001              | 854    | 0,049%                 | 0,039%                   |
| 194  | M029              | 850    | 0,049%                 | 0,039%                   |
| 195  | W014              | 841    | 0,048%                 | 0,039%                   |
| 196  | M042              | 839    | 0,048%                 | 0,039%                   |
| 197  | S038              | 824    | 0,048%                 | 0,038%                   |
| 198  | N006              | 818    | 0,047%                 | 0,038%                   |
| 199  | D006              | 810    | 0,047%                 | 0,038%                   |
| 200  | W003              | 809    | 0,047%                 | 0,038%                   |

| Rang | Gardiner-<br>code | Anzahl | Relative<br>Häufigkeit | Erw. Zipf-<br>Häufigkeit |
|------|-------------------|--------|------------------------|--------------------------|
| 201  | F022              | 806    | 0,046%                 | 0,037%                   |
| 202  | I012              | 797    | 0,046%                 | 0,037%                   |
| 203  | M020              | 791    | 0,046%                 | 0,037%                   |
| 204  | G028              | 788    | 0,045%                 | 0,037%                   |
| 205  | N008              | 780    | 0,045%                 | 0,037%                   |
| 206  | D060              | 777    | 0,045%                 | 0,036%                   |
| 207  | F045A             | 760    | 0,044%                 | 0,036%                   |
| 208  | O028              | 748    | 0,043%                 | 0,036%                   |
| 209  | F044              | 740    | 0,043%                 | 0,036%                   |
| 210  | F027              | 738    | 0,043%                 | 0,036%                   |
| 211  | G007A             | 725    | 0,042%                 | 0,035%                   |
| 212  | R025              | 723    | 0,042%                 | 0,035%                   |
| 213  | A019              | 708    | 0,041%                 | 0,035%                   |
| 214  | M013              | 703    | 0,041%                 | 0,035%                   |
| 215  | V024              | 698    | 0,040%                 | 0,035%                   |
| 216  | E009              | 695    | 0,040%                 | 0,034%                   |
| 217  | W017              | 693    | 0,040%                 | 0,034%                   |
| 218  | V007              | 690    | 0,040%                 | 0,034%                   |
| 219  | Z002C             | 681    | 0,039%                 | 0,034%                   |
| 220  | A030              | 675    | 0,039%                 | 0,034%                   |
| 221  | F040              | 661    | 0,038%                 | 0,033%                   |
| 222  | AA013             | 659    | 0,038%                 | 0,033%                   |
| 223  | U032              | 656    | 0,038%                 | 0,033%                   |
| 224  | F030              | 649    | 0,037%                 | 0,033%                   |
| 225  | AA018             | 649    | 0,037%                 | 0,033%                   |
| 226  | S024              | 645    | 0,037%                 | 0,033%                   |
| 227  | S012              | 641    | 0,037%                 | 0,032%                   |
| 228  | T012              | 641    | 0,037%                 | 0,032%                   |
| 229  | A051              | 638    | 0,037%                 | 0,032%                   |
| 230  | O035              | 636    | 0,037%                 | 0,032%                   |
| 231  | G020              | 634    | 0,037%                 | 0,032%                   |
| 232  | AA017             | 629    | 0,036%                 | 0,032%                   |
| 233  | V015              | 628    | 0,036%                 | 0,031%                   |
| 234  | P005              | 625    | 0,036%                 | 0,031%                   |
| 235  | M001              | 618    | 0,036%                 | 0,031%                   |
| 236  | V029              | 616    | 0,036%                 | 0,031%                   |
| 237  | D026              | 616    | 0,036%                 | 0,031%                   |
| 238  | D003              | 608    | 0,035%                 | 0,031%                   |
| 239  | U029              | 607    | 0,035%                 | 0,030%                   |
| 240  | F026              | 600    | 0,035%                 | 0,030%                   |
| 241  | A028              | 599    | 0,035%                 | 0,030%                   |
| 242  | A015              | 591    | 0,034%                 | 0,030%                   |
| 243  | I064              | 591    | 0,034%                 | 0,030%                   |
| 244  | D051              | 589    | 0,034%                 | 0,030%                   |
| 245  | V014              | 587    | 0,034%                 | 0,030%                   |
| 246  | K001              | 582    | 0,034%                 | 0,029%                   |
| 247  | D039              | 581    | 0,033%                 | 0,029%                   |
| 248  | S040              | 575    | 0,033%                 | 0,029%                   |
| 249  | T019              | 569    | 0,033%                 | 0,029%                   |
| 250  | FF101             | 568    | 0,033%                 | 0,029%                   |



| Rang | Gardiner-<br>code | Anzahl | Relative<br>Häufigkeit | Erw. Zipf-<br>Häufigkeit |
|------|-------------------|--------|------------------------|--------------------------|
| 251  | AA028             | 553    | 0,032%                 | 0,029%                   |
| 252  | N037A             | 551    | 0,032%                 | 0,029%                   |
| 253  | A047              | 551    | 0,032%                 | 0,028%                   |
| 254  | A026              | 547    | 0,032%                 | 0,028%                   |
| 255  | F012              | 546    | 0,031%                 | 0,028%                   |
| 256  | W009              | 545    | 0,031%                 | 0,028%                   |
| 257  | F046              | 530    | 0,031%                 | 0,028%                   |
| 258  | X006              | 523    | 0,030%                 | 0,028%                   |
| 259  | S046              | 509    | 0,029%                 | 0,028%                   |
| 260  | V025              | 506    | 0,029%                 | 0,028%                   |
| 261  | U021              | 504    | 0,029%                 | 0,027%                   |
| 262  | O042              | 504    | 0,029%                 | 0,027%                   |
| 263  | A007              | 501    | 0,029%                 | 0,027%                   |
| 264  | G021              | 499    | 0,029%                 | 0,027%                   |
| 265  | W054              | 498    | 0,029%                 | 0,027%                   |
| 266  | U019              | 487    | 0,028%                 | 0,027%                   |
| 267  | R007              | 486    | 0,028%                 | 0,027%                   |
| 268  | M001A             | 485    | 0,028%                 | 0,027%                   |
| 269  | S028              | 482    | 0,028%                 | 0,026%                   |
| 270  | I001              | 482    | 0,028%                 | 0,026%                   |
| 271  | G035              | 480    | 0,028%                 | 0,026%                   |
| 272  | N011              | 479    | 0,028%                 | 0,026%                   |
| 273  | A009              | 478    | 0,028%                 | 0,026%                   |
| 274  | T018              | 476    | 0,027%                 | 0,026%                   |
| 275  | Y024              | 473    | 0,027%                 | 0,026%                   |
| 276  | M006              | 463    | 0,027%                 | 0,026%                   |
| 277  | U013              | 461    | 0,027%                 | 0,025%                   |
| 278  | D045              | 459    | 0,026%                 | 0,025%                   |
| 279  | V020J             | 458    | 0,026%                 | 0,025%                   |
| 280  | A021              | 452    | 0,026%                 | 0,025%                   |
| 281  | D035A             | 438    | 0,025%                 | 0,025%                   |
| 282  | T001              | 437    | 0,025%                 | 0,025%                   |
| 283  | F028              | 421    | 0,024%                 | 0,025%                   |
| 284  | D016              | 421    | 0,024%                 | 0,025%                   |
| 285  | D055              | 417    | 0,024%                 | 0,025%                   |
| 286  | G054              | 416    | 0,024%                 | 0,025%                   |
| 287  | K004              | 413    | 0,024%                 | 0,024%                   |
| 288  | T034              | 411    | 0,024%                 | 0,024%                   |
| 289  | N030              | 409    | 0,024%                 | 0,024%                   |
| 290  | E015              | 407    | 0,023%                 | 0,024%                   |
| 291  | U005              | 405    | 0,023%                 | 0,024%                   |
| 292  | I014              | 388    | 0,022%                 | 0,024%                   |
| 293  | F042              | 387    | 0,022%                 | 0,024%                   |
| 294  | T020              | 385    | 0,022%                 | 0,024%                   |
| 295  | E017              | 384    | 0,022%                 | 0,024%                   |
| 296  | Y001A             | 377    | 0,022%                 | 0,024%                   |
| 297  | U035              | 376    | 0,022%                 | 0,023%                   |
| 298  | F016              | 376    | 0,022%                 | 0,023%                   |
| 299  | O022              | 375    | 0,022%                 | 0,023%                   |
| 300  | T030A             | 374    | 0,022%                 | 0,023%                   |



## C Beispielhafte Anwendung von Fabricius

Die folgenden Screenshots zeigen zuerst die Anwendung des Tools Fabricius auf Hieroglyphen, die mithilfe eines Fonts abgedruckt wurden. In der letzten Abbildung wird das Tool auf einen handschriftlichen Text angewendet.

Einlesen eines Bildes und Vorprozessierung eines Font-Beispiels:





## Segmentierung, Sequenzierung und Klassifikation, Übersetzungsvorschläge:

**FABRICIUS** by Google Arts & Culture | TEST

1 PROCESS 2 GENERATE 3 **ANALYSE** 4 ANNOTATE PROPERTIES

**SEQUENCE**

**SENTENCE**

**WORD**

F31 N21 A17 N35A X1 Z16 Z16 G43 C19 G17 T22 N35A C19 N35A G14 X1 B1 I1

Add translation...

Add transliteration...

Transliterations...

Add interpretation...

> Translations

**TRANSLATION**

F31 S29 A17 N35 X1 Z4 G43 A1 G17 T22 N35 A1 N35 G14 X1 B1 I9

Add translation...

Add transliteration...

Transliterations...

Add interpretation...

Auto translate AT

she; her; hers (suffix pron. 3rd per. fem. sing.) | =s

she; her; hers (suffix pron. 3rd per. fem. sing.) | =s


she; her; hers (suffix pron. 3rd per. fem. sing.) | =s

she; her; hers (suffix pron. 3rd per. fem. sing.) | =s

she; her; hers (suffix pron. 3rd per. fem. sing.) | =s

---

Beispielhafte Anwendung auf eine Handschrift:





## D Klassifikator Glyphnet von Barucci et al. (2021) mit Kurztest

```
•[8]: dataset = r"C:\Users\David\Desktop\Google Drive\Studium\Data Science MSc\Masterarbeit\Tools\Glyphnet\Beispiele"

X_test, y_test = load_dataset(dataset, 'jpg')    # Loads your dataset and extracts the Label for each image

y_test = label_enc.transform(y_test)
# encodes the labels using our set of data (Label_enc is instantiated in the useful_functions notebook)
n_classes = len(list(label_enc.classes_))

# changes dimensions to the data to accomplish the requirements of the model
X_test = np.asarray(X_test)
X_test, y_test = add_extra_dim(X_test, y_test, n_classes)

print('Test images dimensions:', np.shape(X_test))
print('Test labels dimension:', np.shape(y_test))
print('\nNumber of labels:', n_classes)
```

```
Test images dimensions: (10, 100, 100, 1)
Test labels dimension: (10, 40)
```

```
Number of labels: 40
```

```
[9]: model = build_model()
model.load_weights('weights.hdf5')

y_pred = model.predict(X_test)
y_test_decoded = np.argmax(y_test, axis=1)
y_pred_decoded = np.argmax(y_pred, axis=1)
#print(y_test_decoded)
#print(y_pred_decoded)

# Print f1, precision, and recall scores
print("accuracy = ", accuracy_score(y_test_decoded, y_pred_decoded))
print("precision = ", precision_score(y_test_decoded, y_pred_decoded , average="macro"))
print("recall = ", recall_score(y_test_decoded, y_pred_decoded , average="macro"))
print("f1_score = ", f1_score(y_test_decoded, y_pred_decoded , average="macro"))
print('-----')

X_test_reshape = X_test.reshape(X_test.shape[0], X_test.shape[1], X_test.shape[2])
get_prediction_data(y_pred, X_test_reshape, y_test, label_enc,
                    summary=False, details=True, plot=(None,0,None))
```

```
accuracy = 0.9
precision = 0.8125
recall = 0.875
f1_score = 0.8333333333333333
```

```
-----
Test dataset dimensions: (10, 100, 100)
```


```
100% 2/2 G43
100% 1/1 X1
100% 1/1 D21
100% 1/1 Q3
100% 1/1 I9
100% 2/2 G17
100% 1/1 N35
0% 0/1 S29
-----
```

```
Correct prediction: 9/10
```




## E Grundlagen zu CNNs und darauf aufbauenden Architekturen

Ein Convolutional Neural Network (CNN) ist eine spezielle Art von künstlichem neuronalen Netzwerk, das insbesondere für die Verarbeitung von Bilddaten entwickelt wurde. Ein Bild wird dabei mithilfe mehrerer Schichten (Layer) in Feature Maps transformiert. Faltungsschichten (Convolutional Layers) erkennen lokale Muster in Bildern, wie Kanten, Texturen oder Formen und produzieren Feature Maps, die jeweils ein bestimmtes Merkmal hervorheben. Das Ergebnis jeder Filterung wird noch durch eine Aktivierungsfunktion geschickt (z.B. ReLU), um Nicht-Linearität in das Modell einzuführen und so das Lernen komplexer Eigenschaften zu ermöglichen. Pooling-Schichten reduzieren die Datenmenge durch Abbildung benachbarter Pixel auf einen neuen Wert (z.B. über Durchschnitts- oder Maximumberechnung). Die extrahierten Features werden schließlich durch ein voll-vernetztes neuronales Netz (Fully Connected (FC) Layer) prozessiert, dass die eigentliche Aufgabe löst und in der Ausgangsschicht das Ergebnis mit einer Wahrscheinlichkeitsverteilung ausgibt. CNNs werden häufig in der Bildklassifikation, Objekterkennung und Gesichtserkennung eingesetzt. Die Architektur ist schematisch in E.1 dargestellt.



**Abbildung E.1:** Grundlegende Architektur eines CNN, aus AnalytixLabs (2024).

In dem Überblick von Zaidi et al. (2021) sind zahlreiche CNN-basierte Algorithmentypen für die Objekterkennung beschrieben. In Abb. E.2 sind einige Architekturen schematisch abgebildet. Beim R-CNN (Region-based Convolutional Neural Network) ist dem CNN ein zusätzliches Modul vorgelagert, das im Bild zuerst verschiedene Regionen (Regionen von Interesse, RoI) identifiziert und extrahiert. Die Einzelbilder werden dann auf das Eingabeformat für das CNN gebracht (Warping). Das CNN extrahiert die Features jeder RoI und eine Support Vector Machine klassifiziert das Objekt. Anschließend wird die Bounding Box (BB) des Objekts verfeinert (durch den BB-Regressor).



**Abbildung E.2:** Architekturen von R-CNN, SPP-Net, Fast R-CNN, Faster R-CNN, FPN, R-FCN, Mask R-CNN und YOLO, aus Zaidi et al. (2021).

Beim Fast R-CNN wird das Inputbild ohne Vorprozessierung direkt durch die Convolutional-/Pooling-Layer, die keine definierte Eingabegröße benötigen, zu Feature Maps transformiert und parallel werden die RoIs extrahiert. Diese werden dann auf die Feature Maps gemappt. Jede Region wird durch einen Spatial Pyramid Pooling (SPP) Layer nun auf das benötigte Eingabeformat für den darauf folgenden FC Layer transformiert. Dieser ist mit weiteren FC Layern verbunden, die zum Klassifikator sowie zum



---

BB-Regressor verzweigen. Im Vergleich zum R-CNN arbeitet der Fast R-CNN 146 mal schneller. Eine Variante ohne verzweigende FC Layer ist SPP-Net. Faster R-CNN ist ein Fast R-CNN mit integriertem Region Proposal Network (RPN). Im Gegensatz zum Fast R-CNN werden die RoIs nicht bei der Analyse des Originalbilds, sondern der Feature Maps ermittelt. Die vom RPN parallel bestimmten RoIs werden dann wieder mit den Feature Maps gemappt und nach Ersetzen des SPP Layers durch einen RoI Pooling Layer wird die restliche Pipeline des Fast R-CNNs verfolgt. Die Geschwindigkeit ist um etwa eine Größenordnung größer im Vergleich zum Fast R-CNN, da die Extraktion der RoIs auf den weniger komplexen Feature Maps deutlich schneller verläuft. FPN (Feature Pyramid Network) wurde für die Multiskalen-Erkennung entwickelt. Das Netzwerk nutzt das Prinzip von Feature-Pyramiden, um Objekte in Bildern effizient auf verschiedenen Skalen oder in unterschiedlichen Größen zu erkennen und damit insbesondere kleine Objekte besser zu identifizieren. Dieses Ziel wird erreicht durch die Kombination eines Bottom-Up-Ansatz, der durch die Convolutional Layer erzeugten Feature-Map-Hierarchie entspricht, mit einem Top-Down-Ansatz, bei dem das FPN eine Pyramide von Merkmalen aufbaut, indem es Merkmale aus den höheren, abstrakteren Schichten (mit kleinerer Auflösung) in die niedrigeren Schichten (mit höherer Auflösung) hochskaliert. Dabei werden feinere Details aus den höheren Schichten auf die größeren Informationen der tieferen Schichten übertragen. Beide Ansätze werden dann übereinander gelegt. Das Region-based Fully Convolutional Network (R-FCN) nutzt im Gegensatz zum klassischen R-CNN, das auf regionenspezifischen CNNs basiert, keine FC Layer. Statt jeder Region einen separaten CNN-Block zuzuweisen, verwendet R-FCN Position-Sensitive Score Maps, die für jede Position im Bild eine Wahrscheinlichkeitsbewertung für jede Objektklasse liefern und es dem Netzwerk somit ermöglichen, auf jeder Position im Bild simultan eine Objektklassifikation und Bounding-Box-Verfeinerung durchzuführen (beim sog. Voting). Diese Methode reduziert die Berechnungszeit im Vergleich zum Faster R-CNN nochmal um bis zu einen Faktor 20. Der Mask R-CNN erweitert den Faster R-CNN um einem zum FC Layer parallelen Zweig mit einem Fully Connected Network (FCN). Der FCN klassifiziert jede RoI auf Pixelebene und erzeugt parallel zum Klassifizierer und BB-Regressor eine Maske, die bei einer detaillierteren Segmentierung eines Bildes unterstützt. Zudem wird der RoI Pooling Layer durch einen RoI Align Layer ersetzt. Mask R-CNN performt besser im Vergleich zu den zuvor beschriebenen Architekturen, ist einfach zu trainieren und zeigt gute Generalisierungseigenschaften. Mit dem Mask R-CNN ist aber noch immer keine Echtzeit-Objekterkennung möglich. Mithilfe der YOLO-Architektur (You Only Look Once) kann diese schließlich erreicht werden, siehe Kapitel 5.4.



## F Klassenverteilungen der Datensätze

### F.1 Verteilung im Trainingsdatensatz für die Segmentierung (Top90 Klassen)

| Rang | Gardiner Code | Anzahl |
|------|---------------|--------|
| 1    | N35           | 1433   |
| 2    | M17           | 1049   |
| 3    | X1            | 858    |
| 4    | S29           | 811    |
| 5    | UD            | 675    |
| 6    | G17           | 632    |
| 7    | D21           | 612    |
| 8    | G43           | 598    |
| 9    | I9            | 504    |
| 10   | V31           | 446    |
| 11   | E34           | 353    |
| 12   | O50           | 288    |
| 13   | Q3            | 240    |
| 14   | V13           | 216    |
| 15   | D36           | 210    |
| 16   | D35           | 184    |
| 17   | Z1            | 160    |
| 18   | D46           | 148    |
| 19   | G1            | 143    |
| 20   | D58           | 130    |
| 21   | W24           | 130    |
| 22   | I10           | 129    |
| 23   | D4            | 124    |
| 24   | V28           | 118    |
| 25   | M23           | 116    |
| 26   | G35           | 99     |
| 27   | N37           | 95     |
| 28   | D2            | 89     |
| 29   | G5            | 86     |
| 30   | R8            | 85     |

| Rang | Gardiner Code | Anzahl |
|------|---------------|--------|
| 31   | U1            | 75     |
| 32   | O1            | 74     |
| 33   | O34           | 72     |
| 34   | N5            | 71     |
| 35   | G25           | 67     |
| 36   | G39           | 66     |
| 37   | Q1            | 65     |
| 38   | Aa1           | 60     |
| 39   | N1            | 56     |
| 40   | N29           | 56     |
| 41   | D54           | 55     |
| 42   | Z2            | 54     |
| 43   | D28           | 54     |
| 44   | U33           | 52     |
| 45   | O4            | 50     |
| 46   | V30           | 50     |
| 47   | P8            | 50     |
| 48   | U15           | 46     |
| 49   | R8a           | 46     |
| 50   | O49           | 44     |
| 51   | N18           | 43     |
| 52   | N31           | 43     |
| 53   | N14           | 43     |
| 54   | N30           | 43     |
| 55   | M18           | 42     |
| 56   | Z7            | 39     |
| 57   | W25           | 38     |
| 58   | G36           | 38     |
| 59   | F34           | 38     |
| 60   | M17a          | 37     |

| Rang | Gardiner Code | Anzahl |
|------|---------------|--------|
| 61   | V4            | 36     |
| 62   | Z11           | 35     |
| 63   | S34           | 35     |
| 64   | Y5            | 32     |
| 65   | E9            | 32     |
| 66   | O28           | 31     |
| 67   | A1            | 29     |
| 68   | G7            | 29     |
| 69   | E23           | 29     |
| 70   | R4            | 28     |
| 71   | T22           | 28     |
| 72   | F31           | 26     |
| 73   | N17           | 26     |
| 74   | X8            | 24     |
| 75   | F13           | 23     |
| 76   | P1            | 21     |
| 77   | E1            | 21     |
| 78   | Y1            | 21     |
| 79   | D1            | 21     |
| 80   | W18           | 21     |
| 81   | O31           | 21     |
| 82   | M3            | 20     |
| 83   | Y2            | 20     |
| 84   | H6            | 20     |
| 85   | Aa15          | 20     |
| 86   | F18           | 20     |
| 87   | G4            | 20     |
| 88   | F35           | 19     |
| 89   | V24           | 19     |
| 90   | G40           | 19     |

---

## F.2 Verteilung im Trainingsdatensatz für die Klassifizierung

Abkürzungen der Spaltennamen:

- FG: Patches von Franken und van Gemert (2013)
- FON: Computergenerierte Patches (Fonts)
- MAN: Manuelle Ausschnitte aus Erman und Grapow (1971)
- SEG: Aus den eigenen annotierten Bildern gewonnene Patches
- FF: Patches von Fuentes-Ferrer et al. (2025)

Die Varianten mit dem Suffix „a“ sind die absoluten Häufigkeiten im angereicherten Datensatz bzgl. der Teildatensätze. **Final** gibt die Gesamthäufigkeit im Datensatz mit Data Augmentation an. Auf den folgenden Seiten sind die im finalen Datensatz 200 häufigsten Klassen (bzgl. **SUM**) aufgelistet.

|    | Code | FG  | FON | MAN | SEG | FF  | SUM  | FGa | FONa | MANa | SEGa | FFa | SUM2 | Final |
|----|------|-----|-----|-----|-----|-----|------|-----|------|------|------|-----|------|-------|
| 1  | N35  | 448 | 4   | 0   | 197 | 534 | 1183 | 448 | 120  | 0    | 197  | 534 | 1299 | 2598  |
| 2  | M17  | 364 | 4   | 0   | 107 | 481 | 956  | 364 | 120  | 0    | 107  | 481 | 1072 | 2144  |
| 3  | X1   | 232 | 4   | 0   | 196 | 439 | 871  | 232 | 120  | 0    | 196  | 439 | 987  | 1974  |
| 4  | D21  | 183 | 4   | 0   | 125 | 357 | 669  | 183 | 120  | 0    | 125  | 357 | 785  | 1570  |
| 5  | I9   | 146 | 4   | 0   | 93  | 327 | 570  | 146 | 120  | 0    | 372  | 327 | 965  | 1930  |
| 6  | S29  | 265 | 4   | 0   | 73  | 207 | 549  | 265 | 120  | 0    | 292  | 207 | 884  | 1768  |
| 7  | G43  | 197 | 4   | 0   | 71  | 176 | 448  | 197 | 120  | 0    | 284  | 176 | 777  | 1554  |
| 8  | G17  | 195 | 4   | 0   | 56  | 139 | 394  | 195 | 120  | 0    | 224  | 139 | 678  | 1356  |
| 9  | V30  | 8   | 4   | 0   | 29  | 276 | 317  | 48  | 120  | 0    | 174  | 276 | 618  | 1236  |
| 10 | D4   | 37  | 4   | 0   | 27  | 238 | 306  | 148 | 120  | 0    | 162  | 238 | 668  | 1336  |
| 11 | V31  | 133 | 4   | 0   | 29  | 133 | 299  | 133 | 120  | 0    | 174  | 133 | 560  | 1120  |
| 12 | D36  | 59  | 4   | 0   | 41  | 163 | 267  | 236 | 120  | 0    | 164  | 163 | 683  | 1366  |
| 13 | R8   | 67  | 4   | 0   | 25  | 170 | 266  | 268 | 120  | 0    | 150  | 170 | 708  | 1416  |
| 14 | Q3   | 77  | 4   | 0   | 43  | 140 | 264  | 308 | 120  | 0    | 172  | 140 | 740  | 1480  |
| 15 | V28  | 36  | 4   | 0   | 23  | 171 | 234  | 144 | 120  | 0    | 138  | 171 | 573  | 1146  |
| 16 | M23  | 38  | 4   | 0   | 19  | 171 | 232  | 152 | 120  | 0    | 114  | 171 | 557  | 1114  |
| 17 | Q1   | 17  | 4   | 0   | 22  | 157 | 200  | 102 | 120  | 0    | 132  | 157 | 511  | 1022  |
| 18 | A1   | 0   | 4   | 0   | 30  | 166 | 200  | 0   | 120  | 0    | 120  | 166 | 406  | 812   |
| 19 | D58  | 36  | 4   | 0   | 23  | 127 | 190  | 144 | 120  | 0    | 138  | 127 | 529  | 1058  |
| 20 | O1   | 20  | 4   | 0   | 23  | 142 | 189  | 120 | 120  | 0    | 138  | 142 | 520  | 1040  |
| 21 | F35  | 3   | 4   | 0   | 14  | 168 | 189  | 18  | 120  | 0    | 84   | 168 | 390  | 780   |
| 22 | V13  | 79  | 4   | 1   | 17  | 83  | 184  | 316 | 120  | 20   | 102  | 332 | 890  | 1780  |
| 23 | E34  | 122 | 4   | 0   | 19  | 35  | 180  | 122 | 120  | 0    | 114  | 140 | 496  | 992   |
| 24 | N33  | 0   | 3   | 1   | 4   | 164 | 172  | 0   | 90   | 20   | 24   | 164 | 298  | 596   |
| 25 | X8   | 6   | 5   | 1   | 9   | 148 | 169  | 36  | 150  | 20   | 54   | 148 | 408  | 816   |
| 26 | R4   | 3   | 4   | 0   | 20  | 141 | 168  | 18  | 120  | 0    | 120  | 141 | 399  | 798   |
| 27 | D46  | 50  | 4   | 0   | 21  | 92  | 167  | 200 | 120  | 0    | 126  | 368 | 814  | 1628  |
| 28 | D37  | 0   | 4   | 1   | 9   | 147 | 161  | 0   | 120  | 20   | 54   | 147 | 341  | 682   |
| 29 | Z1   | 43  | 4   | 0   | 58  | 54  | 159  | 172 | 120  | 0    | 232  | 216 | 740  | 1480  |
| 30 | Y1   | 1   | 5   | 0   | 19  | 133 | 158  | 6   | 150  | 0    | 114  | 133 | 403  | 806   |
| 31 | S34  | 10  | 4   | 0   | 10  | 131 | 155  | 60  | 120  | 0    | 60   | 131 | 371  | 742   |
| 32 | D2   | 24  | 4   | 0   | 17  | 93  | 138  | 144 | 120  | 0    | 102  | 372 | 738  | 1476  |
| 33 | O49  | 13  | 4   | 0   | 12  | 103 | 132  | 78  | 120  | 0    | 72   | 103 | 373  | 746   |
| 34 | D28  | 17  | 4   | 0   | 11  | 95  | 127  | 102 | 120  | 0    | 66   | 380 | 668  | 1336  |
| 35 | O34  | 19  | 4   | 0   | 30  | 74  | 127  | 114 | 120  | 0    | 120  | 296 | 650  | 1300  |
| 36 | Y5   | 8   | 4   | 0   | 6   | 104 | 122  | 48  | 120  | 0    | 36   | 104 | 308  | 616   |
| 37 | D35  | 57  | 4   | 0   | 20  | 40  | 121  | 228 | 120  | 0    | 120  | 160 | 628  | 1256  |
| 38 | N1   | 18  | 4   | 0   | 12  | 85  | 119  | 108 | 120  | 0    | 72   | 340 | 640  | 1280  |
| 39 | I10  | 41  | 4   | 0   | 19  | 51  | 115  | 164 | 120  | 0    | 114  | 204 | 602  | 1204  |
| 40 | Aa15 | 3   | 3   | 0   | 16  | 93  | 115  | 18  | 90   | 0    | 96   | 372 | 576  | 1152  |
| 41 | O50  | 106 | 4   | 0   | 2   | 1   | 113  | 106 | 120  | 0    | 12   | 6   | 244  | 488   |
| 42 | W24  | 39  | 4   | 0   | 16  | 35  | 94   | 156 | 120  | 0    | 96   | 140 | 512  | 1024  |
| 43 | M12  | 3   | 4   | 0   | 5   | 79  | 91   | 18  | 120  | 0    | 30   | 316 | 484  | 968   |
| 44 | G1   | 35  | 4   | 0   | 42  | 6   | 87   | 140 | 120  | 0    | 168  | 36  | 464  | 928   |
| 45 | F31  | 8   | 4   | 1   | 1   | 71  | 85   | 48  | 120  | 20   | 6    | 284 | 478  | 956   |
| 46 | U7   | 4   | 4   | 0   | 3   | 72  | 83   | 24  | 120  | 0    | 18   | 288 | 450  | 900   |
| 47 | F1   | 0   | 5   | 0   | 2   | 70  | 77   | 0   | 150  | 0    | 12   | 280 | 442  | 884   |
| 48 | U1   | 25  | 4   | 0   | 6   | 36  | 71   | 150 | 120  | 0    | 36   | 144 | 450  | 900   |
| 49 | O4   | 14  | 4   | 0   | 7   | 45  | 70   | 84  | 120  | 0    | 42   | 180 | 426  | 852   |
| 50 | A40  | 0   | 4   | 0   | 10  | 54  | 68   | 0   | 120  | 0    | 60   | 216 | 396  | 792   |

|     | Code | FG | FON | MAN | SEG | FF | SUM | FGa | FONa | MANa | SEGa | FFa | SUM2 | Final |
|-----|------|----|-----|-----|-----|----|-----|-----|------|------|------|-----|------|-------|
| 51  | Aa1  | 0  | 3   | 0   | 49  | 15 | 67  | 0   | 90   | 0    | 196  | 90  | 376  | 752   |
| 52  | G36  | 9  | 4   | 0   | 10  | 43 | 66  | 54  | 120  | 0    | 60   | 172 | 406  | 812   |
| 53  | Z2   | 0  | 5   | 0   | 42  | 18 | 65  | 0   | 150  | 0    | 168  | 108 | 426  | 852   |
| 54  | N37  | 30 | 4   | 0   | 18  | 13 | 65  | 120 | 120  | 0    | 108  | 78  | 426  | 852   |
| 55  | D55  | 0  | 4   | 0   | 0   | 61 | 65  | 0   | 120  | 0    | 0    | 244 | 364  | 728   |
| 56  | W19  | 4  | 4   | 0   | 9   | 41 | 58  | 24  | 120  | 0    | 54   | 164 | 362  | 724   |
| 57  | H1   | 0  | 4   | 0   | 3   | 50 | 57  | 0   | 120  | 0    | 18   | 200 | 338  | 676   |
| 58  | D54  | 12 | 4   | 0   | 16  | 23 | 55  | 72  | 120  | 0    | 96   | 138 | 426  | 852   |
| 59  | H6   | 7  | 4   | 0   | 5   | 39 | 55  | 42  | 120  | 0    | 30   | 156 | 348  | 696   |
| 60  | N14  | 14 | 4   | 1   | 3   | 31 | 53  | 84  | 120  | 20   | 18   | 124 | 366  | 732   |
| 61  | B1   | 0  | 4   | 1   | 3   | 45 | 53  | 0   | 120  | 20   | 18   | 180 | 338  | 676   |
| 62  | Z11  | 11 | 4   | 2   | 6   | 29 | 52  | 66  | 120  | 40   | 36   | 174 | 436  | 872   |
| 63  | D40  | 0  | 4   | 1   | 10  | 37 | 52  | 0   | 120  | 20   | 60   | 148 | 348  | 696   |
| 64  | A2   | 0  | 4   | 0   | 13  | 34 | 51  | 0   | 120  | 0    | 78   | 136 | 334  | 668   |
| 65  | N25  | 2  | 4   | 0   | 10  | 33 | 49  | 12  | 120  | 0    | 60   | 132 | 324  | 648   |
| 66  | G5   | 31 | 4   | 0   | 4   | 9  | 48  | 124 | 120  | 0    | 24   | 54  | 322  | 644   |
| 67  | U6   | 0  | 4   | 0   | 2   | 42 | 48  | 0   | 120  | 0    | 12   | 168 | 300  | 600   |
| 68  | V1   | 0  | 5   | 2   | 1   | 39 | 47  | 0   | 150  | 40   | 6    | 156 | 352  | 704   |
| 69  | F39  | 0  | 3   | 1   | 6   | 37 | 47  | 0   | 90   | 20   | 36   | 148 | 294  | 588   |
| 70  | W25  | 12 | 4   | 2   | 2   | 24 | 44  | 72  | 120  | 40   | 12   | 144 | 388  | 776   |
| 71  | S3   | 0  | 4   | 0   | 13  | 27 | 44  | 0   | 120  | 0    | 78   | 162 | 360  | 720   |
| 72  | G35  | 38 | 4   | 2   | 0   | 0  | 44  | 152 | 120  | 40   | 0    | 0   | 312  | 624   |
| 73  | N26  | 1  | 4   | 0   | 6   | 33 | 44  | 6   | 120  | 0    | 36   | 132 | 294  | 588   |
| 74  | S21  | 0  | 3   | 0   | 0   | 41 | 44  | 0   | 90   | 0    | 0    | 164 | 254  | 508   |
| 75  | R11  | 0  | 4   | 2   | 1   | 36 | 43  | 0   | 120  | 40   | 6    | 144 | 310  | 620   |
| 76  | D1   | 5  | 4   | 0   | 9   | 24 | 42  | 30  | 120  | 0    | 54   | 144 | 348  | 696   |
| 77  | W17  | 0  | 4   | 1   | 2   | 35 | 42  | 0   | 120  | 20   | 12   | 140 | 292  | 584   |
| 78  | U33  | 17 | 4   | 1   | 4   | 15 | 41  | 102 | 120  | 20   | 24   | 90  | 356  | 712   |
| 79  | G25  | 27 | 4   | 2   | 2   | 5  | 40  | 162 | 120  | 40   | 12   | 30  | 364  | 728   |
| 80  | U23  | 0  | 4   | 1   | 5   | 29 | 39  | 0   | 120  | 20   | 30   | 174 | 344  | 688   |
| 81  | M18  | 13 | 4   | 1   | 6   | 15 | 39  | 78  | 120  | 20   | 36   | 90  | 344  | 688   |
| 82  | D60  | 6  | 4   | 0   | 4   | 24 | 38  | 36  | 120  | 0    | 24   | 144 | 324  | 648   |
| 83  | R14  | 0  | 4   | 1   | 3   | 30 | 38  | 0   | 120  | 20   | 18   | 120 | 278  | 556   |
| 84  | M16  | 2  | 4   | 1   | 0   | 31 | 38  | 12  | 120  | 20   | 0    | 124 | 276  | 552   |
| 85  | U15  | 13 | 4   | 2   | 4   | 14 | 37  | 78  | 120  | 40   | 24   | 84  | 346  | 692   |
| 86  | N5   | 21 | 4   | 0   | 10  | 2  | 37  | 126 | 120  | 0    | 60   | 12  | 318  | 636   |
| 87  | L1   | 3  | 4   | 1   | 0   | 28 | 36  | 18  | 120  | 20   | 0    | 168 | 326  | 652   |
| 88  | D45  | 0  | 4   | 0   | 3   | 29 | 36  | 0   | 120  | 0    | 18   | 174 | 312  | 624   |
| 89  | M3   | 4  | 4   | 1   | 8   | 18 | 35  | 24  | 120  | 20   | 48   | 108 | 320  | 640   |
| 90  | N29  | 18 | 4   | 0   | 7   | 6  | 35  | 108 | 120  | 0    | 42   | 36  | 306  | 612   |
| 91  | Y4   | 0  | 4   | 0   | 1   | 29 | 34  | 0   | 120  | 0    | 6    | 174 | 300  | 600   |
| 92  | G38  | 0  | 4   | 0   | 2   | 28 | 34  | 0   | 120  | 0    | 12   | 168 | 300  | 600   |
| 93  | Z4   | 0  | 4   | 0   | 7   | 23 | 34  | 0   | 120  | 0    | 42   | 138 | 300  | 600   |
| 94  | G40  | 8  | 4   | 0   | 2   | 20 | 34  | 48  | 120  | 0    | 12   | 120 | 300  | 600   |
| 95  | S40  | 0  | 4   | 2   | 0   | 27 | 33  | 0   | 120  | 40   | 0    | 162 | 322  | 644   |
| 96  | V6   | 2  | 4   | 1   | 2   | 24 | 33  | 12  | 120  | 20   | 12   | 144 | 308  | 616   |
| 97  | Y2   | 7  | 4   | 0   | 6   | 16 | 33  | 42  | 120  | 0    | 36   | 96  | 294  | 588   |
| 98  | V4   | 13 | 4   | 0   | 5   | 11 | 33  | 78  | 120  | 0    | 30   | 66  | 294  | 588   |
| 99  | N18  | 19 | 4   | 0   | 2   | 8  | 33  | 114 | 120  | 0    | 12   | 48  | 294  | 588   |
| 100 | N36  | 2  | 4   | 2   | 4   | 20 | 32  | 12  | 120  | 40   | 24   | 120 | 316  | 632   |



|     | Code | FG | FON | MAN | SEG | FF | SUM | FGa | FONa | MANa | SEGa | FFa | SUM2 | Final |
|-----|------|----|-----|-----|-----|----|-----|-----|------|------|------|-----|------|-------|
| 101 | S38  | 0  | 4   | 0   | 0   | 28 | 32  | 0   | 120  | 0    | 0    | 168 | 288  | 576   |
| 102 | Z7   | 4  | 4   | 0   | 20  | 4  | 32  | 24  | 120  | 0    | 120  | 24  | 288  | 576   |
| 103 | N31  | 17 | 4   | 2   | 5   | 3  | 31  | 102 | 120  | 40   | 30   | 18  | 310  | 620   |
| 104 | W11  | 5  | 4   | 0   | 2   | 20 | 31  | 30  | 120  | 0    | 12   | 120 | 282  | 564   |
| 105 | F4   | 4  | 4   | 0   | 4   | 18 | 30  | 24  | 120  | 0    | 24   | 108 | 276  | 552   |
| 106 | W18  | 7  | 4   | 0   | 2   | 17 | 30  | 42  | 120  | 0    | 12   | 102 | 276  | 552   |
| 107 | G39  | 21 | 4   | 0   | 5   | 0  | 30  | 126 | 120  | 0    | 30   | 0   | 276  | 552   |
| 108 | X7   | 0  | 4   | 0   | 1   | 24 | 29  | 0   | 120  | 0    | 6    | 144 | 270  | 540   |
| 109 | G14  | 2  | 4   | 1   | 2   | 19 | 28  | 12  | 120  | 20   | 12   | 114 | 278  | 556   |
| 110 | E1   | 7  | 4   | 1   | 1   | 15 | 28  | 42  | 120  | 20   | 6    | 90  | 278  | 556   |
| 111 | Z3   | 0  | 3   | 0   | 12  | 13 | 28  | 0   | 90   | 0    | 72   | 78  | 240  | 480   |
| 112 | F32  | 1  | 4   | 0   | 2   | 20 | 27  | 6   | 120  | 0    | 12   | 120 | 258  | 516   |
| 113 | A30  | 0  | 4   | 0   | 8   | 15 | 27  | 0   | 120  | 0    | 48   | 90  | 258  | 516   |
| 114 | L2   | 0  | 4   | 2   | 1   | 19 | 26  | 0   | 120  | 40   | 6    | 114 | 280  | 560   |
| 115 | D39  | 2  | 4   | 0   | 2   | 18 | 26  | 12  | 120  | 0    | 12   | 108 | 252  | 504   |
| 116 | V7   | 5  | 4   | 0   | 2   | 15 | 26  | 30  | 120  | 0    | 12   | 90  | 252  | 504   |
| 117 | F18  | 6  | 4   | 2   | 6   | 7  | 25  | 36  | 120  | 40   | 36   | 42  | 274  | 548   |
| 118 | T28  | 2  | 4   | 0   | 1   | 18 | 25  | 12  | 120  | 0    | 6    | 108 | 246  | 492   |
| 119 | O29  | 1  | 4   | 0   | 6   | 14 | 25  | 6   | 120  | 0    | 36   | 84  | 246  | 492   |
| 120 | N8   | 0  | 4   | 2   | 2   | 16 | 24  | 0   | 120  | 40   | 12   | 96  | 268  | 536   |
| 121 | W22  | 2  | 4   | 0   | 2   | 16 | 24  | 12  | 120  | 0    | 12   | 96  | 240  | 480   |
| 122 | P8   | 16 | 4   | 0   | 4   | 0  | 24  | 96  | 120  | 0    | 24   | 0   | 240  | 480   |
| 123 | S27  | 0  | 3   | 0   | 1   | 20 | 24  | 0   | 90   | 0    | 6    | 120 | 216  | 432   |
| 124 | M2   | 0  | 4   | 2   | 1   | 16 | 23  | 0   | 120  | 40   | 6    | 96  | 262  | 524   |
| 125 | G37  | 3  | 4   | 1   | 4   | 11 | 23  | 18  | 120  | 20   | 24   | 66  | 248  | 496   |
| 126 | F12  | 1  | 4   | 0   | 2   | 16 | 23  | 6   | 120  | 0    | 12   | 96  | 234  | 468   |
| 127 | A42  | 0  | 4   | 0   | 5   | 14 | 23  | 0   | 120  | 0    | 30   | 84  | 234  | 468   |
| 128 | V20  | 0  | 3   | 0   | 3   | 17 | 23  | 0   | 90   | 0    | 18   | 102 | 210  | 420   |
| 129 | I1   | 0  | 4   | 2   | 1   | 15 | 22  | 0   | 120  | 40   | 6    | 90  | 256  | 512   |
| 130 | M42  | 5  | 4   | 2   | 2   | 9  | 22  | 30  | 120  | 40   | 12   | 54  | 256  | 512   |
| 131 | T21  | 3  | 4   | 1   | 5   | 9  | 22  | 18  | 120  | 20   | 30   | 54  | 242  | 484   |
| 132 | V29  | 0  | 4   | 2   | 1   | 14 | 21  | 0   | 120  | 40   | 6    | 84  | 250  | 500   |
| 133 | F26  | 4  | 4   | 0   | 0   | 13 | 21  | 24  | 120  | 0    | 0    | 78  | 222  | 444   |
| 134 | T22  | 9  | 4   | 0   | 2   | 6  | 21  | 54  | 120  | 0    | 12   | 36  | 222  | 444   |
| 135 | S19  | 0  | 4   | 0   | 0   | 16 | 20  | 0   | 120  | 0    | 0    | 96  | 216  | 432   |
| 136 | A24  | 0  | 4   | 0   | 4   | 12 | 20  | 0   | 120  | 0    | 24   | 72  | 216  | 432   |
| 137 | F34  | 10 | 4   | 0   | 5   | 1  | 20  | 60  | 120  | 0    | 30   | 6   | 216  | 432   |
| 138 | O28  | 10 | 4   | 2   | 3   | 0  | 19  | 60  | 120  | 40   | 18   | 0   | 238  | 476   |
| 139 | M20  | 3  | 4   | 1   | 0   | 11 | 19  | 18  | 120  | 20   | 0    | 66  | 224  | 448   |
| 140 | D52  | 5  | 4   | 1   | 2   | 7  | 19  | 30  | 120  | 20   | 12   | 42  | 224  | 448   |
| 141 | V10  | 0  | 4   | 0   | 0   | 15 | 19  | 0   | 120  | 0    | 0    | 90  | 210  | 420   |
| 142 | Y3   | 3  | 4   | 0   | 1   | 11 | 19  | 18  | 120  | 0    | 6    | 66  | 210  | 420   |
| 143 | F13  | 8  | 5   | 2   | 1   | 2  | 18  | 48  | 150  | 40   | 6    | 12  | 256  | 512   |
| 144 | R7   | 0  | 4   | 2   | 2   | 10 | 18  | 0   | 120  | 40   | 12   | 60  | 232  | 464   |
| 145 | E23  | 10 | 4   | 2   | 0   | 2  | 18  | 60  | 120  | 40   | 0    | 12  | 232  | 464   |
| 146 | Q2   | 0  | 4   | 1   | 0   | 13 | 18  | 0   | 120  | 20   | 0    | 78  | 218  | 436   |
| 147 | S28  | 2  | 4   | 1   | 2   | 9  | 18  | 12  | 120  | 20   | 12   | 54  | 218  | 436   |
| 148 | N30  | 12 | 3   | 2   | 1   | 0  | 18  | 72  | 90   | 40   | 6    | 0   | 208  | 416   |
| 149 | N42  | 0  | 4   | 0   | 2   | 12 | 18  | 0   | 120  | 0    | 12   | 72  | 204  | 408   |
| 150 | D56  | 3  | 4   | 2   | 2   | 6  | 17  | 18  | 120  | 40   | 12   | 36  | 226  | 452   |



|     | Code | FG | FON | MAN | SEG | FF | SUM | FGa | FONa | MANa | SEGa | FFa | SUM2 | Final |
|-----|------|----|-----|-----|-----|----|-----|-----|------|------|------|-----|------|-------|
| 151 | E9   | 10 | 4   | 2   | 1   | 0  | 17  | 60  | 120  | 40   | 6    | 0   | 226  | 452   |
| 152 | N16  | 1  | 4   | 0   | 6   | 6  | 17  | 6   | 120  | 0    | 36   | 36  | 198  | 396   |
| 153 | P1   | 5  | 4   | 0   | 5   | 3  | 17  | 30  | 120  | 0    | 30   | 18  | 198  | 396   |
| 154 | U2   | 0  | 4   | 0   | 13  | 0  | 17  | 0   | 120  | 0    | 78   | 0   | 198  | 396   |
| 155 | N17  | 8  | 4   | 0   | 5   | 0  | 17  | 48  | 120  | 0    | 30   | 0   | 198  | 396   |
| 156 | G7   | 11 | 4   | 0   | 2   | 0  | 17  | 66  | 120  | 0    | 12   | 0   | 198  | 396   |
| 157 | Aa13 | 0  | 3   | 0   | 2   | 12 | 17  | 0   | 90   | 0    | 12   | 72  | 174  | 348   |
| 158 | A19  | 0  | 4   | 2   | 0   | 10 | 16  | 0   | 120  | 40   | 0    | 60  | 220  | 440   |
| 159 | A50  | 0  | 4   | 1   | 0   | 11 | 16  | 0   | 120  | 20   | 0    | 66  | 206  | 412   |
| 160 | N27  | 0  | 4   | 1   | 5   | 6  | 16  | 0   | 120  | 20   | 30   | 36  | 206  | 412   |
| 161 | F21  | 1  | 4   | 0   | 0   | 11 | 16  | 6   | 120  | 0    | 0    | 66  | 192  | 384   |
| 162 | W14  | 1  | 4   | 0   | 0   | 11 | 16  | 6   | 120  | 0    | 0    | 66  | 192  | 384   |
| 163 | H8   | 0  | 3   | 1   | 3   | 9  | 16  | 0   | 90   | 20   | 18   | 54  | 182  | 364   |
| 164 | M44  | 7  | 4   | 2   | 2   | 0  | 15  | 42  | 120  | 40   | 12   | 0   | 214  | 428   |
| 165 | O6   | 0  | 4   | 1   | 0   | 10 | 15  | 0   | 120  | 20   | 0    | 60  | 200  | 400   |
| 166 | S24  | 2  | 4   | 1   | 0   | 8  | 15  | 12  | 120  | 20   | 0    | 48  | 200  | 400   |
| 167 | M40  | 3  | 4   | 0   | 7   | 1  | 15  | 18  | 120  | 0    | 42   | 6   | 186  | 372   |
| 168 | M17a | 0  | 4   | 0   | 11  | 0  | 15  | 0   | 120  | 0    | 66   | 0   | 186  | 372   |
| 169 | O3   | 0  | 3   | 0   | 2   | 10 | 15  | 0   | 90   | 0    | 12   | 60  | 162  | 324   |
| 170 | E10  | 0  | 4   | 1   | 1   | 8  | 14  | 0   | 120  | 20   | 6    | 48  | 194  | 388   |
| 171 | N35a | 0  | 4   | 1   | 4   | 5  | 14  | 0   | 120  | 20   | 24   | 30  | 194  | 388   |
| 172 | W15  | 1  | 4   | 0   | 0   | 9  | 14  | 6   | 120  | 0    | 0    | 54  | 180  | 360   |
| 173 | P3   | 0  | 4   | 0   | 2   | 8  | 14  | 0   | 120  | 0    | 12   | 48  | 180  | 360   |
| 174 | M22  | 0  | 4   | 0   | 2   | 8  | 14  | 0   | 120  | 0    | 12   | 48  | 180  | 360   |
| 175 | A17  | 0  | 4   | 0   | 3   | 7  | 14  | 0   | 120  | 0    | 18   | 42  | 180  | 360   |
| 176 | W23  | 0  | 3   | 0   | 0   | 11 | 14  | 0   | 90   | 0    | 0    | 66  | 156  | 312   |
| 177 | Z4a  | 0  | 3   | 0   | 4   | 7  | 14  | 0   | 90   | 0    | 24   | 42  | 156  | 312   |
| 178 | F16  | 7  | 4   | 2   | 0   | 0  | 13  | 42  | 120  | 40   | 0    | 0   | 202  | 404   |
| 179 | E16  | 0  | 4   | 1   | 1   | 7  | 13  | 0   | 120  | 20   | 6    | 42  | 188  | 376   |
| 180 | Z9   | 0  | 4   | 1   | 1   | 7  | 13  | 0   | 120  | 20   | 6    | 42  | 188  | 376   |
| 181 | N23  | 0  | 4   | 1   | 1   | 7  | 13  | 0   | 120  | 20   | 6    | 42  | 188  | 376   |
| 182 | G26  | 2  | 4   | 1   | 6   | 0  | 13  | 12  | 120  | 20   | 36   | 0   | 188  | 376   |
| 183 | E7   | 0  | 4   | 0   | 0   | 9  | 13  | 0   | 120  | 0    | 0    | 54  | 174  | 348   |
| 184 | N19  | 1  | 4   | 0   | 4   | 4  | 13  | 6   | 120  | 0    | 24   | 24  | 174  | 348   |
| 185 | M29  | 3  | 4   | 0   | 2   | 4  | 13  | 18  | 120  | 0    | 12   | 24  | 174  | 348   |
| 186 | U36  | 0  | 4   | 0   | 8   | 1  | 13  | 0   | 120  | 0    | 48   | 6   | 174  | 348   |
| 187 | G4   | 8  | 4   | 0   | 1   | 0  | 13  | 48  | 120  | 0    | 6    | 0   | 174  | 348   |
| 188 | R8a  | 0  | 0   | 1   | 5   | 7  | 13  | 0   | 0    | 20   | 30   | 42  | 92   | 184   |
| 189 | W10  | 0  | 4   | 2   | 1   | 5  | 12  | 0   | 120  | 40   | 6    | 30  | 196  | 392   |
| 190 | F40  | 2  | 4   | 2   | 2   | 2  | 12  | 12  | 120  | 40   | 12   | 12  | 196  | 392   |
| 191 | U31  | 0  | 4   | 1   | 4   | 3  | 12  | 0   | 120  | 20   | 24   | 18  | 182  | 364   |
| 192 | D41  | 0  | 4   | 0   | 2   | 6  | 12  | 0   | 120  | 0    | 12   | 36  | 168  | 336   |
| 193 | P5   | 0  | 4   | 0   | 8   | 0  | 12  | 0   | 120  | 0    | 48   | 0   | 168  | 336   |
| 194 | Aa21 | 0  | 3   | 1   | 0   | 8  | 12  | 0   | 90   | 20   | 0    | 48  | 158  | 316   |
| 195 | Q7   | 3  | 4   | 2   | 1   | 1  | 11  | 18  | 120  | 40   | 6    | 6   | 190  | 380   |
| 196 | T31  | 0  | 4   | 2   | 5   | 0  | 11  | 0   | 120  | 40   | 30   | 0   | 190  | 380   |
| 197 | D53  | 1  | 4   | 2   | 4   | 0  | 11  | 6   | 120  | 40   | 24   | 0   | 190  | 380   |
| 198 | K4   | 0  | 4   | 1   | 0   | 6  | 11  | 0   | 120  | 20   | 0    | 36  | 176  | 352   |
| 199 | A28  | 0  | 4   | 1   | 3   | 3  | 11  | 0   | 120  | 20   | 18   | 18  | 176  | 352   |
| 200 | P6   | 3  | 4   | 1   | 0   | 3  | 11  | 18  | 120  | 20   | 0    | 18  | 176  | 352   |

## G Klassenweise Evaluation des Klassifikators

| Code | Rang | Summe | Genauigk. | GL.Gr. | And.Gr. |
|------|------|-------|-----------|--------|---------|
| G17  | 8    | 1356  | 0,778     | 1,000  | 0,000   |
| M23  | 16   | 1114  | 0,333     | 1,000  | 0,000   |
| D58  | 19   | 1058  | 0,991     | 0,000  | 1,000   |
| W24  | 42   | 1024  | 0,960     | 0,500  | 0,500   |
| Z11  | 62   | 872   | 0,444     | 0,000  | 1,000   |
| N37  | 54   | 852   | 0,941     | 1,000  | 0,000   |
| O4   | 49   | 852   | 0,866     | 0,667  | 0,333   |
| Z2   | 53   | 852   | 0,941     | 0,167  | 0,833   |
| R4   | 26   | 798   | 0,630     | 1,000  | 0,000   |
| Aa1  | 51   | 752   | 0,988     | 0,000  | 1,000   |
| H6   | 59   | 696   | 0,444     | 1,000  | 0,000   |
| B1   | 61   | 676   | 0,926     | 0,000  | 1,000   |
| D60  | 82   | 648   | 0,847     | 0,636  | 0,364   |
| N25  | 65   | 648   | 0,979     | 0,000  | 1,000   |
| U6   | 67   | 600   | 0,981     | 0,000  | 1,000   |
| Y4   | 91   | 600   | 0,984     | 0,000  | 1,000   |
| F39  | 69   | 588   | 0,857     | 0,000  | 1,000   |
| N26  | 73   | 588   | 0,838     | 0,000  | 1,000   |
| Y2   | 97   | 588   | 0,986     | 1,000  | 0,000   |
| W11  | 104  | 564   | 0,929     | 0,143  | 0,857   |
| E1   | 110  | 556   | 0,966     | 1,000  | 0,000   |
| G14  | 109  | 556   | 0,833     | 1,000  | 0,000   |
| N8   | 120  | 536   | 0,982     | 0,000  | 1,000   |
| V7   | 116  | 504   | 0,939     | 0,000  | 1,000   |
| V29  | 132  | 500   | 0,847     | 0,029  | 0,971   |
| G37  | 125  | 496   | 0,974     | 1,000  | 0,000   |
| R7   | 144  | 464   | 0,762     | 1,000  | 0,000   |
| M44  | 164  | 428   | 0,970     | 1,000  | 0,000   |
| V10  | 141  | 420   | 0,947     | 0,000  | 1,000   |
| O6   | 165  | 400   | 0,970     | 0,000  | 1,000   |
| P1   | 153  | 396   | 0,714     | 1,000  | 0,000   |
| W10  | 189  | 392   | 0,795     | 0,852  | 0,148   |
| F21  | 161  | 384   | 0,739     | 1,000  | 0,000   |
| Q7   | 195  | 380   | 0,889     | 0,000  | 1,000   |
| E16  | 179  | 376   | 0,956     | 0,000  | 1,000   |
| Z9   | 180  | 376   | 0,962     | 0,000  | 1,000   |
| M15  | 212  | 368   | 0,935     | 0,000  | 1,000   |
| T18  | 214  | 368   | 0,941     | 0,000  | 1,000   |
| H8   | 163  | 364   | 0,972     | 0,000  | 1,000   |
| U31  | 191  | 364   | 0,977     | 1,000  | 0,000   |
| P3   | 173  | 360   | 0,444     | 1,000  | 0,000   |
| O22  | 228  | 356   | 0,958     | 0,000  | 1,000   |
| U36  | 186  | 348   | 0,987     | 0,000  | 1,000   |
| D10  | 216  | 340   | 0,821     | 1,000  | 0,000   |
| E17  | 296  | 332   | 0,950     | 0,000  | 1,000   |
| F46a | 288  | 332   | 0,690     | 1,000  | 0,000   |

| Code | Rang | Summe | Genauigk. | GL.Gr. | And.Gr. |
|------|------|-------|-----------|--------|---------|
| K1   | 232  | 328   | 0,929     | 0,000  | 1,000   |
| O42  | 204  | 324   | 0,915     | 0,000  | 1,000   |
| V24  | 207  | 324   | 0,500     | 1,000  | 0,000   |
| W5   | 203  | 324   | 0,930     | 0,875  | 0,125   |
| D59  | 352  | 320   | 0,825     | 0,667  | 0,333   |
| G49  | 346  | 320   | 0,962     | 1,000  | 0,000   |
| R15  | 349  | 320   | 0,964     | 0,000  | 1,000   |
| T10  | 334  | 320   | 0,967     | 0,000  | 1,000   |
| T19  | 348  | 320   | 0,958     | 0,000  | 1,000   |
| V26  | 329  | 320   | 0,375     | 1,000  | 0,000   |
| F20  | 267  | 316   | 0,966     | 1,000  | 0,000   |
| W23  | 176  | 312   | 0,984     | 0,000  | 1,000   |
| E15  | 308  | 304   | 0,924     | 0,833  | 0,167   |
| O7   | 299  | 304   | 0,806     | 0,083  | 0,917   |
| T3   | 243  | 300   | 0,600     | 0,000  | 1,000   |
| D26  | 373  | 292   | 0,538     | 1,000  | 0,000   |
| D42  | 272  | 288   | 0,988     | 0,000  | 1,000   |
| E19  | 269  | 288   | 0,986     | 1,000  | 0,000   |
| Z2c  | 271  | 288   | 0,966     | 1,000  | 0,000   |
| B3   | 436  | 280   | 0,810     | 0,250  | 0,750   |
| C6   | 431  | 280   | 0,966     | 0,000  | 1,000   |
| D13  | 428  | 280   | 0,607     | 1,000  | 0,000   |
| D24  | 409  | 280   | 0,818     | 1,000  | 0,000   |
| D25  | 439  | 280   | 0,304     | 1,000  | 0,000   |
| D34a | 433  | 280   | 0,893     | 0,000  | 1,000   |
| E12  | 427  | 280   | 0,925     | 1,000  | 0,000   |
| E25  | 424  | 280   | 0,667     | 0,000  | 1,000   |
| H5   | 443  | 280   | 0,957     | 0,500  | 0,500   |
| O18  | 447  | 280   | 0,977     | 0,000  | 1,000   |
| P9   | 450  | 280   | 0,974     | 0,000  | 1,000   |
| S23  | 440  | 280   | 0,952     | 0,000  | 1,000   |
| E13  | 317  | 276   | 0,864     | 0,667  | 0,333   |
| G29  | 322  | 276   | 0,881     | 0,250  | 0,750   |
| N40  | 318  | 276   | 0,902     | 0,250  | 0,750   |
| D18  | 386  | 264   | 0,815     | 1,000  | 0,000   |
| H2   | 388  | 264   | 0,897     | 0,000  | 1,000   |
| N28  | 379  | 264   | 0,880     | 0,667  | 0,333   |
| V22  | 395  | 264   | 0,893     | 0,000  | 1,000   |
| B5   | 463  | 260   | 0,857     | 0,200  | 0,800   |
| M11  | 462  | 260   | 0,933     | 0,000  | 1,000   |
| Aa3  | 468  | 260   | 0,979     | 0,000  | 1,000   |
| Aa32 | 466  | 260   | 0,976     | 0,000  | 1,000   |
| Aa5  | 323  | 256   | 0,907     | 1,000  | 0,000   |
| D12  | 469  | 252   | 0,867     | 1,000  | 0,000   |
| D44  | 471  | 252   | 0,923     | 0,083  | 0,917   |
| D62  | 507  | 252   | 0,933     | 1,000  | 0,000   |

| Code | Rang | Summe | Genauigk. | Gl.Gr. | And.Gr. |
|------|------|-------|-----------|--------|---------|
| E29  | 478  | 252   | 0,901     | 0,000  | 1,000   |
| F52  | 494  | 252   | 0,967     | 0,000  | 1,000   |
| G15  | 482  | 252   | 0,353     | 1,000  | 0,000   |
| O11  | 504  | 252   | 0,817     | 0,000  | 1,000   |
| P2   | 492  | 252   | 0,929     | 1,000  | 0,000   |
| R24  | 479  | 252   | 0,895     | 0,000  | 1,000   |
| V25  | 505  | 252   | 0,714     | 1,000  | 0,000   |
| M22a | 397  | 244   | 0,760     | 1,000  | 0,000   |
| C17  | 560  | 240   | 0,409     | 1,000  | 0,000   |
| C20  | 571  | 240   | 0,917     | 0,000  | 1,000   |
| D11  | 632  | 240   | 0,750     | 1,000  | 0,000   |
| D50  | 665  | 240   | 0,979     | 0,000  | 1,000   |
| D63  | 635  | 240   | 0,992     | 0,000  | 1,000   |
| E2   | 604  | 240   | 0,949     | 0,000  | 1,000   |
| E3   | 521  | 240   | 0,934     | 0,000  | 1,000   |
| F6   | 584  | 240   | 0,939     | 1,000  | 0,000   |
| F46  | 606  | 240   | 0,737     | 1,000  | 0,000   |
| G7b  | 626  | 240   | 0,971     | 1,000  | 0,000   |
| G13  | 705  | 240   | 0,600     | 1,000  | 0,000   |
| G16  | 659  | 240   | 0,600     | 1,000  | 0,000   |
| G18  | 655  | 240   | 0,538     | 1,000  | 0,000   |
| G45  | 687  | 240   | 0,986     | 1,000  | 0,000   |
| H3   | 558  | 240   | 0,952     | 0,667  | 0,333   |
| H4   | 709  | 240   | 0,889     | 1,000  | 0,000   |
| K5   | 699  | 240   | 0,964     | 0,000  | 1,000   |
| L3   | 522  | 240   | 0,971     | 0,000  | 1,000   |
| M43  | 641  | 240   | 0,984     | 0,500  | 0,500   |
| N9   | 645  | 240   | 0,976     | 0,000  | 1,000   |
| N37a | 533  | 240   | 0,633     | 0,069  | 0,931   |
| O8   | 525  | 240   | 0,833     | 0,000  | 1,000   |
| O14  | 531  | 240   | 0,960     | 1,000  | 0,000   |
| O19  | 640  | 240   | 0,973     | 0,000  | 1,000   |
| P1a  | 627  | 240   | 0,667     | 1,000  | 0,000   |
| R1   | 590  | 240   | 0,750     | 1,000  | 0,000   |
| R2   | 730  | 240   | 0,500     | 1,000  | 0,000   |
| R5   | 637  | 240   | 0,857     | 1,000  | 0,000   |
| R6   | 554  | 240   | 0,481     | 1,000  | 0,000   |
| R20  | 542  | 240   | 0,872     | 0,000  | 1,000   |
| T6   | 611  | 240   | 0,925     | 0,077  | 0,923   |
| T16a | 697  | 240   | 0,925     | 0,000  | 1,000   |
| V9   | 566  | 240   | 0,968     | 0,000  | 1,000   |
| W10a | 575  | 240   | 0,833     | 1,000  | 0,000   |
| Aa26 | 280  | 240   | 0,960     | 1,000  | 0,000   |
| A11  | 512  | 232   | 0,985     | 1,000  | 0,000   |
| O41  | 510  | 232   | 0,960     | 0,000  | 1,000   |
| N7   | 325  | 228   | 0,906     | 0,000  | 1,000   |
| M25  | 744  | 220   | 0,958     | 1,000  | 0,000   |
| Aa6  | 745  | 220   | 0,982     | 0,000  | 1,000   |

| Code | Rang | Summe | Genauigk. | Gl.Gr. | And.Gr. |
|------|------|-------|-----------|--------|---------|
| Aa8  | 736  | 220   | 0,728     | 0,250  | 0,750   |
| Aa17 | 740  | 220   | 0,948     | 0,600  | 0,400   |
| Aa19 | 741  | 220   | 0,667     | 0,000  | 1,000   |
| Aa22 | 735  | 220   | 0,919     | 1,000  | 0,000   |
| Aa30 | 748  | 220   | 0,987     | 0,000  | 1,000   |
| Aa31 | 743  | 220   | 0,667     | 0,000  | 1,000   |
| G2   | 519  | 204   | 0,952     | 0,000  | 1,000   |
| O47  | 515  | 204   | 0,947     | 0,000  | 1,000   |
| Z5   | 518  | 204   | 0,963     | 1,000  | 0,000   |
| B6   | 859  | 180   | 0,946     | 0,000  | 1,000   |
| D65  | 824  | 180   | 0,970     | 0,000  | 1,000   |
| F31a | 815  | 180   | 0,989     | 0,000  | 1,000   |
| I10a | 800  | 180   | 0,948     | 0,000  | 1,000   |
| M33b | 782  | 180   | 0,882     | 0,280  | 0,720   |
| M40a | 760  | 180   | 0,931     | 1,000  | 0,000   |
| N22  | 858  | 180   | 0,975     | 0,000  | 1,000   |
| N32  | 822  | 180   | 0,847     | 0,136  | 0,864   |
| O6a  | 801  | 180   | 0,962     | 0,000  | 1,000   |
| O6b  | 840  | 180   | 0,972     | 0,000  | 1,000   |
| O10a | 784  | 180   | 0,983     | 1,000  | 0,000   |
| Q6   | 817  | 180   | 0,707     | 0,000  | 1,000   |
| R3b  | 844  | 180   | 0,500     | 1,000  | 0,000   |
| S46  | 809  | 180   | 0,974     | 0,000  | 1,000   |
| U14  | 848  | 180   | 0,939     | 0,000  | 1,000   |
| V12a | 768  | 180   | 0,972     | 0,000  | 1,000   |
| V23a | 830  | 180   | 0,872     | 1,000  | 0,000   |
| Z2d  | 831  | 180   | 0,462     | 1,000  | 0,000   |
| Z5a  | 835  | 180   | 0,750     | 1,000  | 0,000   |
| Z6   | 804  | 180   | 0,978     | 0,000  | 1,000   |
| Aa4  | 798  | 180   | 0,694     | 1,000  | 0,000   |
| Aa25 | 839  | 180   | 0,981     | 0,000  | 1,000   |
| Z16a | 866  | 132   | 0,987     | 0,000  | 1,000   |
| C16  | 952  | 120   | 0,833     | 1,000  | 0,000   |
| D64  | 886  | 120   | 0,940     | 0,750  | 0,250   |
| L6a  | 907  | 120   | 0,981     | 0,000  | 1,000   |
| M28a | 892  | 120   | 0,986     | 0,000  | 1,000   |
| O5a  | 937  | 120   | 0,984     | 0,000  | 1,000   |
| O10c | 914  | 120   | 0,937     | 0,250  | 0,750   |
| O20a | 880  | 120   | 0,983     | 0,000  | 1,000   |
| O50a | 898  | 120   | 0,984     | 0,000  | 1,000   |
| S26a | 876  | 120   | 0,870     | 0,000  | 1,000   |
| U6a  | 929  | 120   | 0,970     | 0,000  | 1,000   |
| V11b | 962  | 120   | 0,894     | 0,000  | 1,000   |
| V20a | 956  | 120   | 0,500     | 1,000  | 0,000   |
| V20b | 945  | 120   | 0,476     | 1,000  | 0,000   |
| V20i | 947  | 120   | 0,987     | 1,000  | 0,000   |
| Z16  | 917  | 120   | 0,983     | 0,000  | 1,000   |
| Aa10 | 919  | 120   | 0,989     | 0,000  | 1,000   |

## H Segmentierung, Sequenzierung und Klassifikation für ausgewählte Beispiele

Für 12 Beispiele aus der Liste `Datensatz_Gesamtprozess.csv` wurde ein detaillierter Vergleich zwischen tatsächlicher und vorhergesagter Gardiner-Sequenz erstellt. Die Fehler bei der maschinellen Ausgabe wurden dabei folgendermaßen im Bild markiert:

- Überschüssige Bounding Boxen wurden in der Abbildung mit einem roten „x“ markiert und in der vorhergesagten Gardiner-Sequenz rot markiert und durchgestrichen.
- Fehlende Boxen wurden mit einem roten Oval gekennzeichnet und in der vorhergesagten Gardiner-Sequenz mit einem roten Platzhalter „-“ vermerkt.
- Fehlklassifikationen wurden mit einer roten rechteckigen Bounding Box eingerahmt und in der Ausgabesequenz rot markiert.
- Vertauschte Elemente in der vorhergesagten Gardiner-Sequenz sind mit einem Doppelpfeil verbunden.




---

## H.1 Sethe, Urkunden III, S. 886 unten (aus Sethe (1909))

SetheIII\_S886unten.jpg

Links-Rechts-Leserichtung: LR

Arrangement: Zeilen



Tatsächliche Sequenz:

S34 G5 E1 D40 N28 G17 R19 X1 O49 G16 V29 M23 X1 M17a N5 Z1 W19 G17  
Q3 X1 N1  
S42 G8 F3 F3 D45 N28 Z2 M23 X1 L2 X1 N5 Y5 L1  
R8 F35 V30 F40 X1 F34 V30 N28 D36 G43 Z2  
V15 X1 F35 S1 W9 G17 S42 Aa1 X1 Z4

Vorhergesagte Sequenz:

S34 ~~G36~~ E1 D40 N28 G17 R19 X1 O49 ~~E20a~~ ~~I12~~ ~~G48~~ V29 M23 X1 M17a ~~D12~~  
~~Z2~~ W19 G17 Q3 X1 ~~G37~~  
~~R2a~~ G8 ~~M11~~ F3 ~~D34a~~ ~~D44~~ N28 Z2 M23 X1 L2 X1 ~~D12~~ Y5 L1  
R8 F35 V30 ~~Y3~~ X1 F34 V30 N28 D36 G43 Z2  
V15 X1 F35 S1 ~~F34~~ G17 ~~R2a~~ ~~O49~~ X1 Z4

Levenshtein-Distanz: 16

Länge der korrekten Sequenz: 57


---

## H.2 Sethe, Urkunden III, S. 887 Mitte (aus Sethe (1909))

SetheIII\_S887mitte.jpg

Links-Rechts-Leserichtung: LR

Arrangement: Zeilen



Tatsächliche Sequenz:

M17 G43 I9 G17 F32 X1 Z1

D21 D37 M17a N35 I9 I6 G17 X1 O49 G28 X1 N25 M26 N16 M15 O49 O49 G17

Aa1 I9 D36 I9

G30 I9 G17 Q3 X1 N1

G54 I9 M3 Aa1 X1 N17

D2 D21 M17a X1 Aa19 D40 Z2 I9 M3 Aa1 X1 N25 X1 Z1 V30 X1

M23 X1 N35 A42 Z3

S38 N29 S38 S38 S38 M17 V13 N25 N5 N35 N16 N16 N16 V30

G38 N5 G26 F31a F35 L1 Z2

---

Vorhergesagte Sequenz:

M17 G43 I9 G17 **D40** X1 Z1

D21 D37 M17a **I14 D13 T24** G17 X1 O49 G28 X1 N25 M26 **F18** M15 O49 O49

G17 **O48** I9 **N36 S17a** I9

G30 I9 G17 Q3 X1 **D53**

G54 I9 M3 **O48** X1 **F46a**

D2 D21 M17a X1 Aa19 **D37 Z3** I9 M3 **O48** X1 N25 X1 Z1 V30 X1

M23 X1 N35 A42 **Z2**

S38 N29 **R8a - -** M17 V13 N25 **D12** N35 N16 **E25** N16 V30

G38 **D12 G7b** F31a F35 L1 **-**

Levenshtein-Distanz: 23

Länge der korrekten Sequenz: 83




---

### H.3 Der beredte Bauer (Version R, Episode 1, Teil 2, aus Allen (2014b))

Allen\_BeredterBauer\_Teil2.jpg

Links-Rechts-Leserichtung: RL

Arrangement: Zeilen



Tatsächliche Sequenz:

P6 D36 N35 M12 G1 D36 N35 I9 N35 S29 U10 U11 N33a N33a  
I10 D46 M17 N35 M20 X1 Z4 A1 Q3 N35 N35 N41 X1 B1 I9 X1 N35 G17 D36  
X1 D36 A1 N35 X1 U10 U11 Z4a D21 G35 Z7 X4 Z2 V28 N35 D36 A17 Z7  
A1 B1 Z2 X1  
D4 D21 X1 N35 A1 M23 Z7 X1 X1 G1 U10 U11 N33a N33a G17 X1 X2 X4 Z2  
V28 N29 X1 W24 (eigentlich W22) Z2 N35 O4 D21 Z7 N5 Z1 V30 V31a G1  
S34 N35 Aa1 A1 M17 G17 I9

Vorhergesagte Sequenz:

P6 I9 N35 M12 G1 D36 N35 I9 N35 S29 U10 U11 I14 N6  
I10 X1 M17 N35 M20 X1 Z4 A1 Q3 N35 N35 N42 X1 B1 - X1 S24 G17 I9 X1  
D36 A1 N35 X1 U10 U11 S27 D21 G35 Z7 V13 S29 Z2 V28 N35 D36 A17a -  
A1 B1 - X1  
D4 D21 X1 N35 A1 M23 Z7 X1 X1 G1 U10 R7 I14 N6 G17 X1 X2 V13 S29 Z2  
Z1 V28 N29 X1 W24 S29 Z1 S29 N35 O4 D21 Z7 S21 - V30 V30 G9 S34 N35  
Aa21 A2 M17 G17 -


Levenshtein-Distanz: 30

Länge der korrekten Sequenz: 95

## H.4 Die Geschichte des Schiffbrüchigen (Episode 1, Teil 2, aus Allen (2014b))

Allen\_Schiffsbrüchiger2.jpg

Links-Rechts-Leserichtung: RL  
Arrangement: Spalten



Tatsächliche Sequenz:

F21 G17 D21 V31 N35 A1 F4 D36 A1  
W24 V31 A1 H6 Z7 G37 M16 G1 G43 Y2 Z2  
M17 D36 N35a D36 X1 Z7 M17 Aa15 G17 D36 N35a D2 Z1 D50 Z2 V31  
M17 Aa1 Y2 G43 N37 D58 A2 V31 G43 F30 D46 X1 A2 V31  
S43 D46 G43 A2 V31 N35 M23 X1 N35 G7 F34 Z1 V31 G17 D36 V31  
G43 N37 D58 A2 V31 D35 N35 N35 M17 X1 M17 X1 A2  
M17 G43 D21 Z1 N35 O34 A1 Z1 N35 N41 G17 D36 I9 M23 G43  
M17 G43 S43 D46 G43 A2 I9 D36 I9 G47 G1 G17  
S28 N35 I9 D2 Z1 D4 D21 V31 G17 Aa1 D21 X1 Y2 Z2 F34 Z1 V31  
S29 G36 D21 D46 G37 Q3 Z7 I10 D46 N35 V31

---

Vorhergesagte Sequenz:

F21 G17 D21 V30 N35 A1 F4 T1 A1  
W24 V30 A1 M17 Z7 G37 M16 G1 G43 D46 S28  
M17 D40 N35 ~~N35~~ ~~N35~~ N17 X1 Z7 M17 Aa13 G17 T1 N35 ~~N35~~ ~~N35~~ D2 Z1 Z1  
Z1 V30  
M17 Aa1 Y2 G43 N23 D58 A2 V30 G43 F30 D46 X1 A2 V30  
S46 D46 G43 A2 V30 N35 X1 ↔ M23 N35 G7 F34 Z1 V30 G17 T1 V30  
G43 N23 D58 A2 V30 D35 N35 N35 M17 X1 M17 X1 A2  
- G43 D21 Z1 N35 O34 A1 Z1 N35 N42 G17 D37 I9 M23 G43  
- G43 S46 D46 G43 A2 I9 D37 I9 G47 G1 G17  
S28 N35 I9 D2 Z1 D4 D21 V30 G17 Aa1 D21 X1 Y2 Z1 F34 Z1 V30  
S29 G36 D21 D46 G37 Q3 Z7 I11a D46 N35 V30

Levenshtein-Distanz: 42

Länge der korrekten Sequenz: 134

## H.5 Stele des Maati (Ausschnitt)<sup>1</sup>

SteleMontu\_horizontal.jpg

Links-Rechts-Leserichtung: RL

Arrangement: Zeilen



Tatsächliche Sequenz:

M23 X1 R4 X8 E16 D1 N26 Z1 I9 Z11 G43 Aa2 X1 V30 N16 D45 O3 M12 X2 W22  
M12 F1a H1 M12 V33 S115 M12 Aa1 X1 V30 F35 D60 X1 X2 D60 N35 O1 Z1

Vorhergesagte Sequenz:

M23 X1 R4 X8 E16 D1 N26 Z1 D36 Z11 G43 Y3 X1 V30 F18 - O3 M17 S29 F35  
M12 X2 W22 M12 F1 H1 M12 F34 S27 M12 N33 X1 V30 F35 D60 X1 A40 D60  
S29 N35 O1 Z1

Levenshtein-Distanz: 13

Länge der korrekten Sequenz: 38

---

<sup>1</sup><https://www.metmuseum.org/collections/search-the-collections/100000189>, besucht am 22.03.2025


---

## H.6 Stele des Antef (Ausschnitt)<sup>2</sup>

SteleAntef\_Teil1.jpg

Links-Rechts-Leserichtung: LR (falsch!)

Arrangement: Zeilen



Tatsächliche Sequenz:

M4 X1 O50 Z1 Z1 Z1 Z1 Z1 Z1 Z1 Z1 Z1 Aa1 D21 U36 Z1 N35 G5 V28 V31 N35  
G17 U1 Aa12 G16 V28 V31 N35 G17 U1 Aa12 M23 L2 X1 X1 N5 S12 D28 D28  
D28

Vorhergesagte Sequenz:

M6 - W24 Z2 Z2 - - - - - W24 D21 Aa26 Z3 N35 G1 V28 V30 N35 G17  
U1 - G1 ~~I13~~ V28 V30 N35 G17 U1 - M23 ~~F1~~ M2 N37 X1 N16 - D36 - -

Levenshtein-Distanz: 29

Länge der korrekten Sequenz: 40

---

<sup>2</sup><https://www.rmo.nl/collectie/collectiezoeker/collectiestuk/?object=883>, besucht am 22.03.2025




## H.7 Stele des Amenemhat (Ausschnitt)<sup>3</sup>

SteleAmenemhat\_3.jpg

Links-Rechts-Leserichtung: LR (falsch!)

Arrangement: Spalten



Tatsächliche Sequenz:

T22 N35 D19 N16 N23 Z1 N35 W17 N35 X1  
G130 A40 G17 O1 D21 X1 D54 O29 X1  
D21 D36 X1 M17 G1 A30 N35 O10 D2 D21  
X1 D1 O34 X1 N25 Z2 W10 X1 V30 X1 O1  
Z2 D2 D21 G43 M17 N35 F39 Aa1 F20 N37  
N35 D36 V37 Z2b M17 Y5 N35 G17  
F4 X1 Z1

Vorhergesagte Sequenz:

M23 N35 D55 N16 N36 Z1 N35 W17 N35 -  
N33 V10 A40 G17 O1 D21 - D55 O29 X1  
D21 D36 X1 M17 G1 A28 X1 N35 O10 D2 D21  
X1 D1 O34 D21 N25 Z1 Z1 Z1 Q3 X1 V30  
F18 O1  
Q3 Z2 D2 D21 G43 M17 G43 F39 N33 D52  
V13 N35 D36 F1 Z2 Z1 Z1 Y5 - G1  
A50 X1 -

Levenshtein-Distanz: 28

Länge der korrekten Sequenz: 61


<sup>3</sup>[https://www.britishmuseum.org/collection/Y\\_EA567](https://www.britishmuseum.org/collection/Y_EA567), besucht am 22.03.2025

## H.8 Stele des Ameny (Ausschnitt)<sup>4</sup>

SteleAmeny\_unten.jpg

Links-Rechts-Leserichtung: RL

Arrangement: Zeilen



Tatsächliche Sequenz:

W24 V31 V30 M1 X1 Y1 D58 N35 D21 M30 U6 G43 X1 M17 F39 Aa1 M17a Aa1  
D21 Q3 D40 D28 X1 A9 S19 G43  
N35 T18 S29 M17 Y5 N35 M17 M17 I10 D46 I9 M17 A26 D21 V13 A1 B1 Z2 V30  
X1 S29 V4 D54 X1 S29 N35 D2 G17 P6 X1 O1  
X1 N35 G17 Aa1 D46 P1 G17 Aa1 U35 M17 M17 X1 P2 G17 U6 M17 M6 V13 N35  
V28 W14 O34 O34 V13 N35 W17  
R13 G4a A40 V30 U23 D58 N26 O49 I10 D46 V13 N35 M12 G17 Aa1 X1 V30 N35  
F39 Aa1 S19 G43 N35 T18 S29 M17 Y5 N35 M17a Aa11 P8

Vorhergesagte Sequenz:

W24 V30 V30 M1 X1 M3 D58 N35 D21 Z1 U6 G43 I9 M17 F39 N33 M20 N33 D21  
Q3 D37 D28 I9 A2 D1 G43  
O34 M17 S29 M17 Y5 N35 S29 S29 D46 ↔ I10 I9 S29 R11 D21 V13 A1 B1 Z2  
V30 X1 S29 V4 D54 I9 S29 N35 D2 G17 M17 X1 O1  
X1 N35 G17 N33 D46 P1 G17 N33 ~~P31~~ W14 M17 M17 X1 P2 G17 U6 M17 M6 V13  
N35 V28 W14 O34 - V13 O34 W18  
F1 G1 A40 V30 V24 D58 ~~P8~~ N26 O49 E16 - V13 D10 M12 G17 N33 X1 V30 N35  
F39 N33 S19 G36 N35 Z1 S29 M17 Y5 N35 M17 S29 Z1 F35

Levenshtein-Distanz: 43

Länge der korrekten Sequenz: 114


<sup>4</sup><https://collections.louvre.fr/en/ark:/53355/cl010022918>, besucht am 22.03.2025

## H.9 Stele des Dedusobek (Ausschnitt)<sup>5</sup>

SteleDedusobek\_rechts.jpg

Links-Rechts-Leserichtung: LR

Arrangement: Spalten



Tatsächliche Sequenz:

M17 F39 X1 Aa1 D21 Q1 D4 W17 R14 G4 V30 U23 D58 N26  
O49 Aa1 D21 F13 N31 N31 N31 R8 O29 V30 U23 D58 N26  
O49  
N42 X1 I9 U7 D21 X1 I9 N35 X1 Q1 X1 F34 I9 N42 X1 B1  
B3 Z2 X1 N35 M17 A2 M17 M17 B1 Aa11 X1 D36 P8 V30  
X1 F39

Vorhergesagte Sequenz:

M17 F39 N1 N33 D21 Q1 D4 W18 R14 G35 V30 U23 D58 N25  
O49 N33 D21 F13 V13 N31 N31 R8 U33 V30 U23 D58 N26  
O49  
N42 X1 D36 U7 D21 X1 I9 N35 X1 X1 ↔ Q1 F34 I9 N42 X1  
B1 A1 Z2 X1 N35 M17 A2 M17 M17 A40 O29 X1 X1 O29  
V30 X1 F39

Levenshtein-Distanz: 16

Länge der korrekten Sequenz: 59

<sup>5</sup>[https://www.britishmuseum.org/collection/object/Y\\_EA566](https://www.britishmuseum.org/collection/object/Y_EA566), besucht am 22.03.2025




## H.10 Stele des Nebipusenwosret (Ausschnitt)<sup>6</sup>

SteleNebipusenwosret\_gezeichnet.jpg

Links-Rechts-Leserichtung: LR

Arrangement: Spalten



Tatsächliche Sequenz:

E34 N35 O31 D2 N35 A48 F35 F4 X1 T18 G43 O1 O29  
O1 V30 Q3 G43 F12 S29 D21 X1 O34 N35 U1 D4  
I9 F35 F35 F35 F13 N31 X1 Z2 E18 G17 O1 D21 X1  
D54 I9 F35 D21 X1 D54 G43 I9 G17 R4  
D21 O11 I9 N35 M29 G17 F34 E34 N35 X1 N14 R8 O7  
O1 G17 V28 D36 D36 A28 G43 X1

Vorhergesagte Sequenz:

E34 N35 O39 D2 N35 A48 F35 F4 X1 O10b G43 O1 F18  
O1 V30 Q3 G43 F12 S29 D21 V13 O34 N35 U2 D4  
I9 F35 F35 F35 F13 N31 I9 Z2 E19 G17 O1 D21 X1  
D54 I9 D21↔F35 I9 D54 G43 I9 G17 R4  
D21 Q3 I9 N35 - G17 - E34 N35 X1 N14 R8 O6 O1  
G17 D36↔V28 D36 A28 G43 X1

Levenshtein-Distanz: 16

Länge der korrekten Sequenz: 69

<sup>6</sup>[https://www.britishmuseum.org/collection/Y\\_EA101](https://www.britishmuseum.org/collection/Y_EA101), besucht am 22.03.2025


---

## H.11 Stele des Qemnen (Ausschnitt)<sup>7</sup>

SteleQemnen\_Ausschnitt.jpg

Links-Rechts-Leserichtung: RL

Arrangement: Zeilen



Tatsächliche Sequenz:

U28 G1 P1 I9 D58 N42 N21 N35 T34 G17 D54 I9 Q3 X1 N1 O34 U1 G1 F36 I9  
N17 N36 D21 N27 X1 Z1 R14 X1 X1 N25 M17 D36 D21 N31 I9 N35 R8 O29a  
O1 D21 D54 I9 O4 G1 D54  
I9 V28 N35 D36 T18 S29 D54 A40 Z2 V30 G43 Z3 R4 X1 Q3 X1 X4 Z2 G17 U23  
D58 N26 O49 D37 X1 N35 I9 D36 D36 Z4 G17 N35 N37 G17 X1 P3 I10 D46  
X1 N35 I9  
M18 G17 R4 X1 Q3 M17 N35 G36 D21 A40 Z3 W24 Z1 U23 D58 N26 O49 F39 Aa1  
R8 U36 N29 G17 N35 N35 A1 D21 N35 I9 F35 D21 I9 E145a N35 M3 Aa1 X1  
A1 Aa11 P8

Vorhergesagte Sequenz:

U29 G1 P1 I9 D58 N42 N35↔Aa14 R8 G17 D54 I9 Q3 N1↔X1 O34 U1 G1 F36  
I9 N17 N36 D21 N27 X1 R14↔D2 N25↔X1↔X1 S29 D36 D21 N31 I9 N35 D58  
O29a O1 D21 D54 I9 O4 G1 D54  
I9 V28 N35 D36 T18 D54 S29 B1↔D55 V30↔Z3 G43 Z1 X1↔R4 Q3 O47↔X1  
Z2 G17 A2 D58 N26 O49 V30 X1 N35 I9 D36 D36 Z4 G17 N35 N37 G17 X1  
P3 D46↔I10 X1 N35 I9  
M18 G17 R4 X1 Q3 D12 M17 N35 G36 D21 B1 W24↔Z3 Z1 U23 D58 N26 O49 F39  
N33 Y1 U36 N29 G17 N35 N35 A1 N35↔D21 I9 F35 D21 I9 E18 N35 M3 Aa1  
X1 A1 Aa14 P8

Levenshtein-Distanz: 37

Länge der korrekten Sequenz: 125

---

<sup>7</sup>[https://collezioni.museoegizio.it/en-GB/material/Cat\\_1513](https://collezioni.museoegizio.it/en-GB/material/Cat_1513), besucht am 22.03.2025



# Abbildungsverzeichnis

|     |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |    |
|-----|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1 | Überblick über die Sprachstufen des Ägyptischen abhängig von der zeitlichen Dimension und vom Register, aus Werning (2015). . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | 6  |
| 2.2 | Textproben für die verschiedenen Schriftsysteme im Alten Ägypten aus Allen (2014a). A: Auszug aus einem Sargtext (CT IV, 255b-257a T1Be), linke Spalte in Hieroglyphisch, rechte Spalte in Kursiv-Hieroglyphen, Lesung jeweils von rechts nach links und von oben nach unten. B: Aus der Lehre des Ptahhotep (Ptahhotep 277-278), obere Zeile in Hieratisch, untere Zeile in hieroglyphischer Transliteration, Lesung von rechts nach links. C: Demotischer Text (Erichsen, Lesestücke I, 73), Lesung von rechts nach links. D: Beginn des „Vater Unser“ in Koptisch, Lesung von links nach rechts mit lateinischer Umschrift. . . . . | 7  |
| 2.3 | Gruppe L der Gardinerliste, aus Allen (2014a). . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 | 8  |
| 2.4 | Doppelt logarithmische Auftragung der relativen Häufigkeit eines Wortes als Funktion seines Rangs für die Werke fünf europäischer alphabetischer Sprachen (links) sowie der Häufigkeit der Schriftzeichen für die Werke dreier asiatischer syllabischer Sprachen (rechts). . . . .                                                                                                                                                                                                                                                                                                                                                     | 9  |
| 2.5 | Doppelt logarithmische Auftragung der relativen Häufigkeit einer Hieroglyphe als Funktion ihres Rangs auf Basis der Absolutwerte in Werning (2021). Es wurden nur Hieroglyphen im Ranking behalten, die unter den etwa 1,7 Mio. gezählten Zeichen mind. zehn Mal vorkamen. . . . .                                                                                                                                                                                                                                                                                                                                                     | 10 |
| 2.6 | Abbildung aus Allen (2014a) mit eigenen farbigen Markierungen, die alle vier möglichen Schreibrichtungen der Hieroglyphenschrift darstellt. Gelb markierte Zeichen sind gute Indikatoren zur Erkennung der Links-Rechts-Leserichtung. . . . .                                                                                                                                                                                                                                                                                                                                                                                          | 11 |
| 2.7 | Darstellung des Gesamtprozesses von der Inschrift hin zur Übersetzung. Die Schritte i) bis iii) beschreiben den Einleseprozess, die Schritte iv) und v) den Übersetzungsprozess. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                               | 12 |
| 3.1 | Pipeline für die Hieroglyphenerkennung nach Franken und van Gemert (2013). . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | 16 |
| 3.2 | Links: Auszug aus <i>Urkunden IV</i> von Sethe (1909), S. 998. Rechts: OCR-Anwendung von Nederhof (2016). . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      | 17 |
| 3.3 | Startseite der Anwendung Fabricius von Google Arts & Culture. . . . .                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  | 18 |

---

|      |                                                                                                                                                                                                                                                                                                                                                                                                                      |    |
|------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 3.4  | Links: Ausschnitt aus der durch vertikale Trennlinien strukturierten Inschrift aus der Pyramide des Unas aus dem Datensatz von Franken und van Gemert (2013). Rechts: Beispiel eines Übersetzungsversuchs Hieroglyphe für Hieroglyphe aus dem Paper von Hossam et al. (2018). . . . .                                                                                                                                | 20 |
| 3.5  | Links: Polygonale Einrahmung der Hieroglyphen mit dem Tool VIA. Rechts: Ergebnis der Objekterkennung durch das Mask R-CNN. Aus Barucci et al. (2021). . . . .                                                                                                                                                                                                                                                        | 21 |
| 3.6  | Auszug aus dem Wörterbuch von <i>Ancient Egypt and Archaeology</i> . Von links nach rechts: Hieroglyphische Schreibung, Gardiner-Sequenz, Transkription, englische Übersetzung, Kommentar. . . . .                                                                                                                                                                                                                   | 24 |
| 3.7  | Originalbilder ausgewählter Kartuschen sowie deren Zwischenstufen bei der Bildverarbeitung bis hin zur Erkennung der Kartusche, aus Duque-Domingo et al. (2017). . . . .                                                                                                                                                                                                                                             | 27 |
| 3.8  | Segmentierungsprozess mithilfe des SAM an einem Beispiel, aus Fuentes-Ferrer et al. (2025). . . . .                                                                                                                                                                                                                                                                                                                  | 28 |
| 3.9  | Tabelle handgeschriebener Beispiele aus Aneesh et al. (2024). . . . .                                                                                                                                                                                                                                                                                                                                                | 30 |
| 3.10 | Von links nach rechts: Hauptmenü, Scan-Funktion und Übersetzungsfenster der App Scriba, aus Moustafa et al. (2022). . . . .                                                                                                                                                                                                                                                                                          | 31 |
| 3.11 | Oben von links nach rechts: Erkennung von Hieroglyphen in Echtzeit durch die App über die Kamera des Smartphones, Vereinigung zu Sätzen, Zerlegung in Wörter. Unten von links nach rechts: Die beiden unterschiedlichen Erkennungsmodi in der App mit den Details, die im unteren Teil des Bildschirms angezeigt werden, wenn das erkannte Wort/der erkannte Satz angetippt wird. Aus Plecher et al. (2020). . . . . | 34 |
| 3.12 | Von links nach rechts: Startbildschirm, zwei Beispiele für die direkte Übersetzung von Hieroglyphen, aus Mohsen et al. (2023). . . . .                                                                                                                                                                                                                                                                               | 35 |
| 3.13 | Beispiel einer manuellen Überprüfung auf unterschiedlichen Ebenen, aus De Cao et al. (2024). . . . .                                                                                                                                                                                                                                                                                                                 | 38 |
| 3.14 | Beispielhafte Anwendung des Codes aus dem Git-Repository von De Cao et al. (2024), einerseits bei Eingabe der Transkription (oben), andererseits der Gardiner-Sequenz (unten). Die korrekte Übersetzung lautet: „ <i>Sie hat (die) Menschen im Tempel gesehen.</i> “ . . . . .                                                                                                                                       | 39 |
| 4.1  | Beispiele für jeden der vier Schrifttypen. Ausschnitte von links nach rechts, von oben nach unten: Stele des Pay aus dem Museo Egizio (GOD), Relief des Nebhepetre Mentuhotep aus dem Metropolitan Museum (GMD), Handschrift aus Sethes <i>Urkunden II</i> (HS) und Hieroglyphen-Font aus Allen (2014a) (CG). . . . .                                                                                                | 43 |
| 4.2  | Links: Definition von Region Attributes in VIA mit beispielhafter Belegung. Rechts: Auszug aus dem JSON-File, dass die Annotationen speichert. . . . .                                                                                                                                                                                                                                                               | 44 |
| 4.3  | Vollständig annotiertes Teilbild der Stele des Qemnen aus dem Museo Egizio in Turin mit Attributen zu einer ausgewählten Box. . . . .                                                                                                                                                                                                                                                                                | 45 |

---

|      |                                                                                                                                                                                                                                                                                            |       |
|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------|
| 4.4  | Rekonstruktion der Annotationen für ein Bild aus der Sammlung von Franken und van Gemert (2013). . . . .                                                                                                                                                                                   | 45    |
| 4.5  | Originalbild (ganz oben) und neun Varianten erzeugt durch unterschiedliche Operations aus Albumentations. . . . .                                                                                                                                                                          | 49    |
| 4.6  | 30 Patches aus dem Klassifikator-Datensatz nach Data Augmentation. . . . .                                                                                                                                                                                                                 | 50    |
| 4.7  | Sechs Patches aus dem Datensatz für die Links-Rechts-Leserichtung vor Data Augmentation. . . . .                                                                                                                                                                                           | 51    |
| 4.8  | Ausschnitt einer Inschrift aus der Stele des Amenemhat aus dem British Museum (BM EA 567) inklusive der Gardiner-Sequenz, der Transkription und der deutschen Übersetzung. . . . .                                                                                                         | 52    |
| 5.1  | Links: Anwendung des originalen Mask R-CNN auf eine Inschrift. Rechts: Beispiel für eine Vorhersage des Segmentierungsmodells mit inhärenter Klassifikation. Einige Beispiele von N35, M17 oder X1 sind bereits korrekt vorhergesagt. . . . .                                              | 55    |
| 5.2  | Links: Mit Gardiner-Codes gelabelte Bounding Boxen. Rechts: Mit der einzigen Klasse „Hieroglyph“ gelabelte Boxen. . . . .                                                                                                                                                                  | 57    |
| 5.3  | Evaluationsmetriken für das Training mit einer Lernrate von 0,001 bei maximal 4000 Epochen. . . . .                                                                                                                                                                                        | 58    |
| 5.4  | Evaluationsmetriken für das Training mit einer Lernrate von 0,01 (0,001 ab Epoche 4000) bei maximal 5000 Epochen. . . . .                                                                                                                                                                  | 59    |
| 5.5  | Vorhersage auf einer kürzeren Inschrift aus Sethe (1909). . . . .                                                                                                                                                                                                                          | 60    |
| 5.6  | Vorhersage auf einer Inschrift mit sehr vielen Zeichen. . . . .                                                                                                                                                                                                                            | 61    |
| 5.7  | Entwicklung des gesamten Loss sowie der Top1-Genauigkeit beim Training des LRL-Klassifikators im Verlauf der 10 Epochen. . . . .                                                                                                                                                           | 62    |
| 5.8  | Weiterverarbeitung von Abb. 5.5 mit reduzierten Bounding Boxen und den längsten Linien im Bild (rot), die keine dieser Boxen schneiden. . . . .                                                                                                                                            | 64    |
| 5.9  | Ergebnis der Sequenzierung der separierten Teillisten aus Abb. 5.9. . . . .                                                                                                                                                                                                                | 65    |
| 5.10 | Entwicklung des gesamten Loss, der Top1- und Top5-Genauigkeit im Verlauf der 15 Epochen bei Verwendung der Varianten $n$ , $m$ bzw. $l$ von YOLO11. Für die final gewählte Modellvariante YOLO11m (YOLO11m_15_01_000001) sind die Genauigkeitswerte pro Epoche explizit angegeben. . . . . | 67    |
| 5.11 | Fortsetzung des Beispiels aus Abb. 5.8 mit den vorhergesagten Klassenlabels der Bounding Boxen als Feedback. . . . .                                                                                                                                                                       | 70    |
| 6.1  | Anwendung der entwickelten Verfahren auf einen kursivhieroglyphischen Text (links) und ein hieratisches Beispiel (rechts). . . . .                                                                                                                                                         | 77    |
| E.1  | Grundlegende Architektur eines CNN, aus AnalytixLabs (2024). . . . .                                                                                                                                                                                                                       | xvii  |
| E.2  | Architekturen von R-CNN, SPP-Net, Fast R-CNN, Faster R-CNN, FPN, R-FCN, Mask R-CNN und YOLO, aus Zaidi et al. (2021). . . . .                                                                                                                                                              | xviii |

---





# Tabellenverzeichnis

- 3.1 Beiträge zur Hieroglyphenerkennung und -übersetzung ausgewählter Arbeitsgruppen im Vergleich . . . . . 41
- 5.1 Übersicht über die bei den verschiedenen Detectron2-Modellen variabel gewählten Parameter. . . . . 56
- 5.2 Evaluation ausgewählter Detectron-Modelle. . . . . 58
- 5.3 Übersicht über die trainierten YOLO-Modelle mit den gewählten Parametern. . . . . 66



# Literaturverzeichnis

## Allen 2014a

ALLEN, James P.: *Middle Egyptian: An Introduction to the Language and Culture of Hieroglyphs*. 3. Edition. Cambridge University Press, 2014. <http://dx.doi.org/10.1017/CB09781107283930>. <http://dx.doi.org/10.1017/CB09781107283930>

## Allen 2014b

ALLEN, James P.: *Middle Egyptian Literature: Eight Literary Works of the Middle Kingdom*. Cambridge University Press, 2014

## AnalytixLabs 2024

ANALYTIXLABS: *Convolutional Neural Networks Definition, Architecture, Types, Applications, and more*. <https://tinyurl.com/27s7jy8s>. Version: 2024. – Zuletzt modifiziert am 25.09.2024

## Aneesh et al. 2024

ANEESH, N A. ; SOMASUNDARAM, Anush ; AMEEN, Azhar ; GARIMELLA, Govind S. ; JAYASHREE, R: Exploring Hieroglyph Recognition: A Deep Learning Approach. In: *2024 2nd International Conference on Computer, Communication and Control (IC4)*. Indore, India, 2024, p. 1–5

## Barucci et al. 2021

BARUCCI, Andrea ; CUCCI, Costanza ; FRANCI, Massimiliano ; LOSCHIAVO, Marco ; ARGENTI, Fabrizio: A Deep Learning Approach to Ancient Egyptian Hieroglyphs Classification. In: *IEEE Access* 9 (2021), p. 123438–123447. <http://dx.doi.org/10.1109/ACCESS.2021.3110082>. – DOI 10.1109/ACCESS.2021.3110082

## Belongie und Malik 2000

BELONGIE ; MALIK: Matching with shape contexts. In: *2000 Proceedings Workshop on Content-based Access of Image and Video Libraries*. Hilton Head, SC, USA, 2000, p. 20–26

## De Cao et al. 2024

DE CAO, Mattia ; DE CAO, Nicola ; COLONNA, Angelo ; LENCI, Alessandro: Deep Learning Meets Egyptology: a Hieroglyphic Transformer for Translating Ancient Egyptian. In: PAVLOPOULOS, John (Hrsg.) ; SOMMERSCHIED, Thea (Hrsg.) ; ASSAEL, Yannis (Hrsg.) ; GORDIN, Shai (Hrsg.) ; CHO, Kyunghyun (Hrsg.) ; PASSAROTTI, Marco (Hrsg.) ; SPRUGNOLI, Rachele (Hrsg.) ; LIU, Yudong (Hrsg.) ; LI, Bin (Hrsg.) ; ANDERSON, Adam (Hrsg.): *Proceedings of the 1st Workshop on Machine*

---

*Learning for Ancient Languages (ML4AL 2024)*. Hybrid in Bangkok, Thailand and online : Association for Computational Linguistics, August 2024, 71–86

**Duque-Domingo et al. 2017**

DUQUE-DOMINGO, Jaime ; HERRERA, Pedro J. ; VALERO, Enrique ; CERRADA, Carlos: Deciphering Egyptian Hieroglyphs: Towards a New Strategy for Navigation in Museums. In: *Sensors* 17 (2017), Nr. 3. <http://dx.doi.org/10.3390/s17030589>. – DOI 10.3390/s17030589. – ISSN 1424–8220

**Dutta und Zisserman 2019**

DUTTA, Abhishek ; ZISSERMAN, Andrew: The VIA Annotation Software for Images, Audio and Video. In: *Proceedings of the 27th ACM International Conference on Multimedia*. Nice, France : ACM, 2019 (MM '19). – ISBN 978–1–4503–6889–6/19/10

**Erman und Grapow 1971**

ERMAN, Adolf ; GRAPOW, Hermann: *Wörterbuch der Aegyptischen Sprache - Band I*. Berlin : Akademie-Verlag, 1971

**Fan et al. 2020**

FAN, Angela ; BHOSALE, Shruti ; SCHWENK, Holger ; MA, Zhiyi ; EL-KISHKY, Ahmed ; GOYAL, Siddharth ; BAINES, Mandeep ; CELEBI, Onur ; WENZKE, Guillaume ; CHAUDHARY, Vishrav ; GOYAL, Naman ; BIRCH, Tom ; LIPTCHINSKY, Vitaliy ; EDUNOV, Sergey ; GRAVE, Edouard ; AULI, Michael ; JOULIN, Armand: Beyond English-Centric Multilingual Machine Translation. In: *CoRR* abs/2010.11125 (2020). <https://arxiv.org/abs/2010.11125>

**Franken und van Gemert 2013**

FRANKEN, Morris ; GEMERT, Jan C.: Automatic Egyptian hieroglyph recognition by retrieving images as texts. In: *Proceedings of the 21st ACM International Conference on Multimedia*. New York, NY, USA : Association for Computing Machinery, 2013 (MM '13). – ISBN 9781450324045, 765768

**Fuentes-Ferrer et al. 2025**

FUENTES-FERRER, Raúl ; DUQUE-DOMINGO, Jaime ; HERRERA, Pedro J.: Recognition of Egyptian hieroglyphic texts through focused generic segmentation and cross-validation voting. In: *Applied Soft Computing* 171 (2025), 112793. <http://dx.doi.org/https://doi.org/10.1016/j.asoc.2025.112793>. – DOI <https://doi.org/10.1016/j.asoc.2025.112793>. – ISSN 1568–4946

**Gardiner 1927**

GARDINER, A.H.: *Egyptian Grammar: Being an Introduction to the Study of Hieroglyphs*. Clarendon Press, 1927

**Gardiner 1957**

GARDINER, Sir A.: *Egyptian Grammar: Being an Introduction to the Study of Hieroglyphs*. 3rd ed. rev. Griffith Institute, 1957

---

**Hannig 1995**

HANNIG, Rainer: *Grosses Handwörterbuch Ägyptisch-Deutsch: (2800-950 v. Chr.) : die Sprache der Pharaonen*. P. von Zabern, 1995 (Die Sprache der Pharaonen). – ISBN 9783805317719

**Hossam et al. 2018**

HOSSAM, Reham ; SALEM, Mohammed Abdel-Megeed M. ; ELIAS, Rimon: Image Based Hieroglyphic Character Recognition. In: *2018 14th International Conference on Signal-Image Technology and Internet-Based Systems (SITIS)*. Las Palmas de Gran Canaria, Spain : IEEE, 2018, p. 32–39

**Koch et al. 2015**

KOCH, Gregory ; ZEMEL, Richard ; SALAKHUTDINOV, Ruslan: Siamese Neural Networks for One-shot Image Recognition. In: *Proceedings of the 32nd International Conference on Machine Learning (ICML)* Bd. 37. Lille, France : JMLR: W&CP, 2015, p. 1–10

**Levenshtein 1965**

LEVENSHTEIN, Vladimir I.: Binary codes capable of correcting deletions, insertions, and reversals. In: *Doklady Akademii Nauk SSSR* 163 (1965), Nr. 4, p. 845–848. – Englische Übersetzung in: *Soviet Physics Doklady*, 10(8), S. 707–710, 1966

**Liu et al. 2017**

LIU, Chao-Lin ; ZHANG, Shuhua ; GENG, Yuanli ; LAI, Huei ling ; WANG, Hongsu: *Character Distributions of Classical Chinese Literary Texts: Zipf’s Law, Genres, and Epochs*. <https://arxiv.org/abs/1709.05587>. Version: 2017

**Mohsen et al. 2023**

MOHSEN, Shehab ; MANSOUR, Reem ; BASSEM, Ahmed ; DESSOUKY, Basma ; REFAAT, Samira ; GHANIM, Taraggy: Aegyptos: Mobile Application for Hieroglyphs Detection, Translation and Pronunciation. In: *2023 International Mobile, Intelligent, and Ubiquitous Computing Conference (MIUCC)*, 2023, p. 1–8

**Moustafa et al. 2022**

MOUSTAFA, Ragaa ; HESHAM, Farida ; HUSSEIN, Samiha ; AMR, Badr ; REFAAT, Samira ; SHORIM, Nada ; GHANIM, Taraggy: Hieroglyphs Language Translator using deep learning techniques (Scriba). In: *2022 2nd International Mobile, Intelligent, and Ubiquitous Computing Conference (MIUCC)*. Cairo, Egypt : IEEE, 2022, p. 125–132

**Nederhof 2016**

NEDERHOF, Mark-Jan: OCR of handwritten transcriptions of Ancient Egyptian hieroglyphic text. In: *Alturtumswissenschaften in a Digital Age: Egyptology, Papyrology and Beyond*, Leipzig, 2016

---

**Piankoff 1968**

PIANKOFF, A.: *ERTR*. Bd. 5: *The Pyramid of Unas, Texts Translated with Commentary*. Princeton, 1968

**Piantadosi 2014**

PIANTADOSI, Steven T.: Zipfs word frequency law in natural language: A critical review and future directions. In: *Psychonomic Bulletin & Review* 21 (2014), 1112 - 1130. <https://api.semanticscholar.org/CorpusID:14264582>

**Plecher et al. 2020**

PLECHER, David A. ; EICHHORN, Christian ; SEYAM, Khaled M. ; KLINKER, Gudrun: ARsinoë - Learning Egyptian Hieroglyphs with Augmented Reality and Machine Learning. In: *2020 IEEE International Symposium on Mixed and Augmented Reality Adjunct (ISMAR-Adjunct)*, 2020, p. 326–332

**Richter et al. 2018**

RICHTER, Tonio S. ; HAFEMANN, Ingelore ; FISCHER-ELFERT, Hans-Werner ; DILS, Peter: *Teilauszug der Datenbank des Vorhabens "Strukturen und Transformationen des Wortschatzes der ägyptischen Sprache" vom Januar 2018*. 2018

**Richter et al. 2024**

RICHTER, Tonio S. ; WERNING, Daniel A. ; FISCHER-ELFERT, Hans-Werner ; DILS, Peter: *Thesaurus Linguae Aegyptiae*. Korpus-Ausgabe 19, Web-App-Version 2.2.0, 5.11.2024, hrsg. im Auftrag der Berlin-Brandenburgischen Akademie der Wissenschaften und der Sächsischen Akademie der Wissenschaften zu Leipzig, 2024 <https://thesaurus-linguae-aegyptiae.de>. – besucht am 03.02.2025

**Roman-Rangel et al. 2011**

ROMAN-RANGEL, Edgar ; PALLAN GAYOL, Carlos ; ODOBEZ, Jean-Marc ; GATICA-PEREZ, Daniel: Searching the past: an improved shape descriptor to retrieve maya hieroglyphs. In: *Proceedings of the 19th ACM International Conference on Multimedia*. New York, NY, USA : Association for Computing Machinery, 2011 (MM '11). – ISBN 9781450306164, 163172

**Schenkel 1995**

SCHENKEL, Wolfgang: Die Lexikographie des Altägyptisch-Koptischen. In: *Studi epigrafici e linguistici sul Vicino Oriente antico* Bd. 12. 1995, p. 191–203

**Sethe 1909**

SETHE, Kurt: *Urkunden der 18. Dynastie, Band I*. Hinrichs, Leipzig, 1909

**Sobhy et al. 2023**

SOBHY, Asmaa ; HELMY, Mahmoud ; KHALIL, Michael ; ELMASRY, Sarah ; BOULES, Youtham ; NEGIED, Nermin: An AI Based Automatic Translator for Ancient Hieroglyphic Language From Scanned Images to English Text. In: *IEEE Access* 11 (2023), p. 38796–38804. <http://dx.doi.org/10.1109/ACCESS.2023.3267981>. – DOI 10.1109/ACCESS.2023.3267981

---

**Tian et al. 2024**

TIAN, J. ; JIN, Q. ; WANG, Y. et al.: Performance analysis of deep learning-based object detection algorithms on COCO benchmark: a comparative study. In: *J. Eng. Appl. Sci.* 71 (2024), 76. <http://dx.doi.org/10.1186/s44147-024-00411-z>. – DOI 10.1186/s44147-024-00411-z

**Werning 2015**

WERNING, Daniel A.: *Einführung in die hieroglyphisch-ägyptische Schrift und Sprache. Propädeutikum mit Zeichen- und Vokabellektionen, Übungen und Übungshinweisen.* 3. verb. Ausg. Humboldt-Universität zu Berlin, Exzellenzcluster 264 Topoi, 2015. <http://dx.doi.org/10.20386/HUB-42129>. <http://dx.doi.org/10.20386/HUB-42129>

**Werning 2021**

WERNING, Daniel A.: *Egyptian Hieroglyphic Signs in the Thesaurus Linguae Aegyptiae and in the Pyramid Texts: Evaluation for an Expansion of the Unicode Set.* <https://osf.io/ys8hj>. Version: 2021. – Zuletzt modifiziert am 13.09.2022

**Wiesenbach und Riezler 2019**

WIESENBACH, Philipp ; RIEZLER, Stefan: Multi-Task Modeling of Phonographic Languages: Translating Middle Egyptian Hieroglyphs. In: NIEHUES, Jan (Hrsg.) ; CATTONI, Rolando (Hrsg.) ; STÜKER, Sebastian (Hrsg.) ; NEGRI, Matteo (Hrsg.) ; TURCHI, Marco (Hrsg.) ; HA, Thanh-Le (Hrsg.) ; SALESKY, Elizabeth (Hrsg.) ; SANABRIA, Ramon (Hrsg.) ; BARRAULT, Loic (Hrsg.) ; SPECIA, Lucia (Hrsg.) ; FEDERICO, Marcello (Hrsg.): *Proceedings of the 16th International Conference on Spoken Language Translation.* Hong Kong : Association for Computational Linguistics, November 2019

**Zaidi et al. 2021**

ZAIDI, Syed Sahil A. ; ANSARI, Mohammad S. ; ASLAM, Asra ; KANWAL, Nadia ; ASGHAR, Mamoon ; LEE, Brian: A Survey of Modern Deep Learning based Object Detection Models. (2021). <https://arxiv.org/abs/2104.11892>